Ch1 矩阵代数基础

1.矩阵的基本运算

$$\frac{dA}{dt}=\begin{bmatrix}\frac{da_{11}}{dt} & \frac{da_{12}}{dt} & \cdots & \frac{da_{1n}}{dt}\\ \vdots & \vdots & & \\ \frac{da_{m1}}{dt} & \frac{da_{m2}}{dt} & \cdots & \frac{da_{mn}}{dt}\end{bmatrix}$$

$\sin(A)=\sum_{n=0}^{\infty}\frac{(-1)^nA^{2n+1}}{(2n+1)!}$ / $\cos(A)=\sum_{n=0}^{\infty}\frac{(-1)^nA^{2n}}{(2n)!}$ $\frac{d(AB)}{dt}=\frac{dA}{dt}B+A\frac{dB}{dt}$

$e^A=\sum_{n=0}^{\infty}\frac{1}{n!}A^n$ / $e^{-A}=\sum_{n=0}^{\infty}\frac{1}{n!}(-1)^nA^n$

$e^{At}=I+At+\frac{1}{2!}A^2t^2+\frac{1}{3!}A^3t^3+\cdots$ / $\ln(I+A)=\sum_{n=1}^{\infty}\frac{(-1)^{n-1}}{n}A^n$ / $\frac{de^{At}}{dt}=Ae^{At}$

2.非奇异矩阵 A: $Ax=0$ 只有零解 / 奇异 $\det(A)=0$

3.复矩阵方程求解 $(A_r+jA_i)(x_r+jx_i)=b_r+jb_i$ $\begin{bmatrix}A_r & -A_i & b_r\\ A_i & A_r & b_i\end{bmatrix}\xrightarrow{初等行变换}\begin{bmatrix}I_n & O_n & x_r\\ O_n & I_n & x_i\end{bmatrix}$ （求逆: $b_r\to I_n, b_i\to O_n$）

4.典范内积 $\langle x,y\rangle=x^Hy=\sum_{i=1}^n x_i^*y_i$ 加权内积 $\langle x,y\rangle=x^HGy$ 正定H阵（$\forall\lambda_i>0$, 二次型大于0）

连续函数内积 $\langle x(t),y(t)\rangle=\int_a^b x^*(t)y(t)dt$ 正交→内积=0（不相关）/ 内积=-1（强负相关）

‖·‖指L2范数 $\|x\|^2=\langle x,x\rangle$ $\langle x,y\rangle^*=\langle y,x\rangle$, $\langle cx,y\rangle=c^*\langle x,y\rangle$

性质: $\begin{cases}\langle x,y\rangle=\frac{1}{4}(\|x+y\|^2-\|x-y\|^2-j\|x+jy\|^2+j\|x-jy\|^2) & 复\\ \langle x,y\rangle=\frac{1}{4}(\|x+y\|^2-\|x-y\|^2) & 实\ (极化恒等式)\end{cases}$ $\begin{cases}\|x+y\|\le\|x\|+\|y\|\\ \|x+y\|^2+\|x-y\|^2=2(\|x\|^2+\|y\|^2)\end{cases}$

Cauchy-Schwartz不等式: $|\langle x,y\rangle|\le\|x\|\cdot\|y\|$ 等号成立→$y=cx$

L0范数(0): $\|x\|_0$=非零元素个数 L1(和1): $\|x\|_1=\sum_{i=1}^m|x_i|$ $\min_e\|e\|_\infty$ 控制最坏情况(误差)

L2(Euclidean/Frobenius) $\|x\|_2=\sqrt{|x_1|^2+\cdots+|x_m|^2}$ L∞(无穷/极大): $\|x\|_\infty=\max\{|x_1|,\cdots,|x_m|\}$

Lp(Hölder): $\|x\|_p=(\sum_{i=1}^m|x_i|^p)^{\frac{1}{p}}$, $p\ge1$ $\cos\theta=\frac{\langle x,y\rangle}{\sqrt{\langle x,x\rangle}\sqrt{\langle y,y\rangle}}=\frac{x^Hy}{\|x\|\|y\|}$

函数向量 $\langle x(t),y(t)\rangle=\int_a^b x^H(t)y(t)dt$ / $\cos\theta=\frac{\int_a^b x^H(t)y(t)dt}{\|x(t)\|\cdot\|y(t)\|}$

随机向量 $\langle x(\xi),y(\xi)\rangle=E\{x^H(\xi)y(\xi)\}$ / $\|x(\xi)\|^2=E\{x^H(\xi)x(\xi)\}$

(互相关矩阵)外积 $E\{x(\xi)y^H(\xi)\}=0_{m\times n}\to x(\xi)\perp y(\xi)$ 两个向量互不含有任何成分,不存在任何相互作用/干扰

矩阵 $A=[a_1,\cdots,a_n]_{m\times n}$, $a=\mathrm{vec}(A)=\begin{bmatrix}a_1\\ \vdots\\ a_n\end{bmatrix}_{mn\times1}$ $\langle A,B\rangle=\mathrm{vec}(A)^H\mathrm{vec}(B)=\mathrm{tr}(A^HB)$ $=\langle\mathrm{vec}(A),\mathrm{vec}(B)\rangle=\sum_{i=1}^n a_i^Hb_i=\sum_{i=1}^n\langle a_i,b_i\rangle$

诱导范数 $\|A\|=\max\{\|Ax\|:x\in K^n,\|x\|=1\}=\max\{\frac{\|Ax\|}{\|x\|}:x\in K^n,x\ne0\}$ A→系统/线性放大算子

p-范数/Lp: $\|A\|_p=\max_{x\ne0}\frac{\|Ax\|_p}{\|x\|_p}$ 绝对列和范数/L1: $\|A\|_1=\max_{1\le j\le n}\sum_{i=1}^m|a_{ij}|$ (行) L∞ $\|A\|_\infty=\max_{1\le i\le m}\sum_{j=1}^n|a_{ij}|$

谱范数 $\|A\|_{spec}=\|A\|_2$ →矩阵的最大奇异值

元素形式 $\|A\|_p=(\sum_{i=1}^m\sum_{j=1}^n|a_{ij}|^p)^{\frac{1}{p}}$ $\|A\|_\infty=\max_{i=1,\cdots,m;j=1,\cdots,n}\{|a_{ij}|\}$ 最大范数

5.随机向量 $\begin{cases}\text{noise } n\sim N(0,I)\\ \text{parameter } \theta\ p(\theta)\ 贝叶斯定理\end{cases}$ $\begin{cases}联合累积分布函数\ F(x)=P\{\xi:x_1(\xi)\le x_1,\cdots,x_m(\xi)\le x_m\}\\ 概率密度函数\ f(x)=\frac{\partial^m}{\partial x_1\cdots\partial x_m}F_x(x_1,\cdots,x_m)\end{cases}$

(复)$\begin{cases}F(x)=P\{x(\xi)\le x\}=P\{x_R(\xi)\le x_R,x_I(\xi)\le x_I\}\\ f(x)=\frac{\partial^{2m}F(x)}{\partial x_{R1}\partial x_{I1}\cdots\partial x_{Rm}\partial x_{Im}}\end{cases}$ 外积 $x\circ y=xy^H$, $C_x=R_x-\mu_x\mu_x^H$

均值向量 $\mu_x=E\{x(\xi)\}=\begin{bmatrix}E\{x_1(\xi)\}\\ \vdots\\ E\{x_m(\xi)\}\end{bmatrix}=\begin{bmatrix}\mu_1\\ \vdots\\ \mu_m\end{bmatrix}=\int_{-\infty}^{\infty}x f(x)dx$

自相关 $\overset{\text{Hermisian}=\mathrm{Var}(x)}{\vec{R}_x}=E\{x(\xi)x^H(\xi)\}=\begin{bmatrix}r_{11}&\cdots&r_{1m}\\ \vdots\\ r_{m1}&\cdots&r_{mm}\end{bmatrix}$ $\begin{cases}对角: 自相关函数\ r_{ii}=E\{|x_i(\xi)|^2\}\\ 非对: 互相关函数\ r_{ij}=E\{x_i(\xi)x_j^*(\xi)\}\end{cases}$

自协方差 $\overset{\text{Hermisian}}{\vec{C}_x}=E\{[x(\xi)-\mu_x][x(\xi)-\mu_x]^H\}=\begin{bmatrix}c_{11}&\cdots&c_{1m}\\ \vdots&&\vdots\\ c_{m1}&&c_{mm}\end{bmatrix}$ $\begin{cases}对角: c_{ii}=E\{|x_i(\xi)-\mu_i|^2\}=\sigma_i^2\ 方差\\ 非对: x_i(\xi)与x_j(\xi)协方差\ c_{ij}=c_{ji}^*\end{cases}$

互相关 $R_{xy}=E\{x(\xi)y^H(\xi)\}$（正交 $R_{xy}=0$） 互协方差 $C_{xy}=E\{[x(\xi)-\mu_x][y(\xi)-\mu_y]^H\}$

$C_{xy}=R_{xy}-\mu_x\mu_y^H$

性质: $\mathrm{Var}(Ax+b)=\mathrm{Var}(Ax)=A\mathrm{Var}(x)A^H$, $\mathrm{Cov}(x,y)=[\mathrm{Cov}(y,x)]^H$

$\mathrm{Var}(x+y)=\mathrm{Var}(x)+\mathrm{Var}(y)+\mathrm{Cov}(x,y)+\mathrm{Cov}(y,x)$ / $\mathrm{Cov}(Ax,By)=A\mathrm{Cov}(x,y)B^H$

相关系数 $\rho_{xy}=\frac{c_{xy}}{\sigma_x\sigma_y}\in[0,1]$ 高斯白噪声向量 $\begin{cases}实\ E\{x(t)\}=0,\ E\{x(t)x^T(t)\}=\sigma^2I\ 实/虚部不相关\\ 虚\ E\{x(t)\}=0,\ E\{x(t)x^H(t)\}=\sigma^2I,\ E\{x(t)x^T(t)\}=0\end{cases}$

$x\sim N(\mu,\sigma^2)$ $p(x)=\frac{1}{\sqrt{2\pi\sigma^2}}\exp[-\frac{(x-\mu)^2}{2\sigma^2}]$

6.二次型 $x^HAx=f(x_1,\cdots,x_m)=\sum_{k=1}^n\sum_{l=1}^n a_{kl}x_kx_l$ 仅实对称/复共轭矩阵满足唯一性

$(x^HAx)^*=(x^HAx)^H=x^HA^Hx=x^HAx$（实值） 正定 $A\succ0\Leftrightarrow$ 二次型>0 $\Leftrightarrow\forall\lambda_i>0$

特征值 $Au=\lambda u$ / $(A-\lambda I)u=0$ 有非零解→$\det(A-\lambda I)=0$ $\mathrm{eig}(AB)=\mathrm{eig}(BA)$, $\mathrm{eig}(A^{-1})=\frac{1}{\mathrm{eig}(A)}$

Hadamard不等式: A(半)正定, $\det(A)\le\prod_i A_{ii}$

行列式 $A_{ij}=(-1)^{i+j}\det(A_{ij})$, $\det(A)=a_{1j}A_{1j}+\cdots+a_{nj}A_{nj}$ / $\det(AB)=\det(A)\det(B)$

奇异性 3×3: $a_{11}(a_{22}a_{33}-a_{23}a_{32})-a_{12}(a_{21}a_{33}-a_{23}a_{31})+a_{13}(a_{21}a_{32}-a_{22}a_{31})$

迹 $\mathrm{tr}(A)=\sum_{i=1}^n a_{ii}=\sum_{i=1}^n\lambda_i$ / $\mathrm{tr}(AB)=\mathrm{tr}(BA)$ / $\mathrm{tr}(A^HA)=0\Rightarrow A=0$ $|A^{-1}|=\frac{1}{|A|}$

$x^HAx=\mathrm{tr}(Axx^H)$ / $y^Hx=\mathrm{tr}(xy^H)$ / $\mathrm{tr}(A^k)=\sum\lambda_i^k$, $\|A\|_F=\sqrt{\mathrm{tr}(A^HA)}$

秩: 线性无关的行/列数目 适定: $m=n$, $\mathrm{rank}(A)=n$(非奇异)→$Ax=b$ 解唯一

欠定: 独立方程<独立未知数 $\mathrm{rank}(A)=r$, $r\le m<n\to Ax=b$ 无穷解 超定: $n\ge r>m$, 无解

$\mathrm{rank}(A+B)\le\mathrm{rank}[A,B]\le\mathrm{rank}(A)+\mathrm{rank}(B)$ $A^2=A$ 幂等→$\mathrm{rank}(A)=\mathrm{tr}(A)$

$\mathrm{rank}(A^H)=\mathrm{rank}(A^T)=\mathrm{rank}(A^*)=\mathrm{rank}(A)$ 左右乘非奇异阵,秩不变

7.非奇异. A^{-1}存在, $\mathrm{rank}(A)=n$, 行/列线性无关, $Ax=b$ 解唯一 / 求逆定理 $(A+xy^H)^{-1}=A^{-1}-\frac{A^{-1}xy^HA^{-1}}{1+y^HA^{-1}x}$

$(A+UBV)^{-1}=A^{-1}-A^{-1}U(I+BVA^{-1}U)^{-1}BVA^{-1}$, $(A-UV)^{-1}=A^{-1}+A^{-1}U(I-VA^{-1}U)^{-1}VA^{-1}$

$(A-UD^{-1}V)^{-1}=A^{-1}+A^{-1}U(D-VA^{-1}U)^{-1}VA^{-1}$

仅 $m\ge n$ 时, 可能有左逆 $L=(A^HA)^{-1}A^H$ / $m\le n$, $R=A^H(AA^H)^{-1}$

8.Moore-Penrose逆矩阵(广义): $AA^+A=A$, $A^+AA^+=A^+$, AA^+/A^+A 为Hermitian

计算: $A^+=(A^HA)^{+}A^H=A^H(AA^H)^{+}$

9.直和 $A_{m\times m}\oplus B_{n\times n}=\begin{bmatrix}A_{m\times m}&O_{m\times n}\\ O_{n\times m}&B\end{bmatrix}$ $(A\oplus C)(B\oplus D)=AB\oplus CD$

Hadamard积 $(A*B)_{ij}=a_{ij}b_{ij}$ Kronecker积 右 $A_{m\times n}\otimes B_{p\times q}=\begin{bmatrix}a_{11}B&\cdots&a_{1n}B\\ \vdots&&\vdots\\ a_{m1}B&&a_{mn}B\end{bmatrix}_{mp\times nq}$

10.按列堆栈 $\mathrm{vec}(A)=[a_{11},\cdots,a_{m1},\cdots,a_{1n},\cdots,a_{mn}]^T$ 左 $[A\otimes B]_{left}=\begin{bmatrix}Ab_{11}&Ab_{12}&\cdots&Ab_{1q}\\ Ab_{p1}&Ab_{p2}&\cdots&Ab_{pq}\end{bmatrix}$

按行 $\mathrm{rvec}(A)=[a_{11},\cdots,a_{1n},\cdots,a_{m1},\cdots,a_{mn}]$ $\mathrm{vec}(A^T)=(\mathrm{rvec}A)^T$

$\mathrm{tr}(A^TB)=(\mathrm{vec}(A))^T\mathrm{vec}(B)$ / $\mathrm{tr}(ABC)=(\mathrm{vec}(A))^T(I_p\otimes B)\mathrm{vec}(C)$

$\mathrm{vec}(A*B)=\mathrm{vec}(A)*\mathrm{vec}(B)=\mathrm{diag}(\mathrm{vec}A)\mathrm{vec}B$ / $a\otimes b=\mathrm{vec}(ba^T)$

$\mathrm{vec}(ABC)=(C^T\otimes A)\mathrm{vec}(B)$

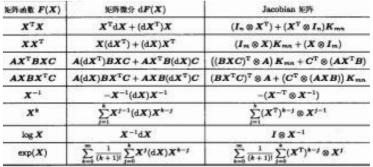

矩阵函数 $F(X)$	矩阵微分 $dF(X)$	Jacobian 矩阵
X^TX	$X^TdX+(dX^T)X$	$(I_n\otimes X^T)+(X^T\otimes I_n)K_{mn}$
XX^T	$X(dX^T)+(dX)X^T$	$(I_m\otimes X)K_{mn}+(X\otimes I_m)$
AX^TBXC	$A(dX^T)BXC+AX^TB(dX)C$	$((BXC)^T\otimes A)K_{mn}+C^T\otimes(AX^TB)$
$AXBX^TC$	$A(dX)BX^TC+AXB(dX^T)C$	$(BX^TC)^T\otimes A+(C^T\otimes(AXB))K_{mn}$
X^{-1}	$-X^{-1}(dX)X^{-1}$	$-(X^{-T}\otimes X^{-1})$
X^k	$\sum_{j=1}^k X^{j-1}(dX)X^{k-j}$	$\sum_{j=1}^k(X^T)^{k-j}\otimes X^{j-1}$
$\log X$	$X^{-1}dX$	$I\otimes X^{-1}$
$\exp(X)$	$\sum_{k=0}^{\infty}\frac{1}{(k+1)!}\sum_{j=0}^k X^j(dX)X^{k-j}$	$\sum_{k=0}^{\infty}\frac{1}{(k+1)!}\sum_{j=0}^k(X^T)^{k-j}\otimes X^j$

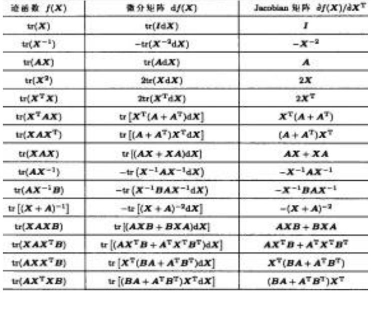

迹函数 $f(X)$	微分矩阵 $df(X)$	Jacobian 矩阵 $\partial f(X)/\partial X^T$
$\mathrm{tr}(X)$	$\mathrm{tr}(IdX)$	I
$\mathrm{tr}(X^{-1})$	$-\mathrm{tr}(X^{-2}dX)$	$-X^{-2}$
$\mathrm{tr}(AX)$	$\mathrm{tr}(AdX)$	A
$\mathrm{tr}(X^2)$	$2\mathrm{tr}(XdX)$	$2X$
$\mathrm{tr}(X^TX)$	$2\mathrm{tr}(X^TdX)$	$2X^T$
$\mathrm{tr}(X^TAX)$	$\mathrm{tr}[X^T(A+A^T)dX]$	$X^T(A+A^T)$
$\mathrm{tr}(XAX^T)$	$\mathrm{tr}[(A+A^T)X^TdX]$	$(A+A^T)X^T$
$\mathrm{tr}(XAX)$	$\mathrm{tr}[(AX+XA)dX]$	$AX+XA$
$\mathrm{tr}(AX^{-1})$	$-\mathrm{tr}(X^{-1}AX^{-1}dX)$	$-X^{-1}AX^{-1}$
$\mathrm{tr}(AX^{-1}B)$	$-\mathrm{tr}(X^{-1}BAX^{-1}dX)$	$-X^{-1}BAX^{-1}$
$\mathrm{tr}[(X+A)^{-1}]$	$-\mathrm{tr}[(X+A)^{-2}dX]$	$-(X+A)^{-2}$
$\mathrm{tr}(XAXB)$	$\mathrm{tr}[(AXB+BXA)dX]$	$AXB+BXA$
$\mathrm{tr}(XAX^TB)$	$\mathrm{tr}[(AX^TB+A^TX^TB^T)dX]$	$AX^TB+A^TX^TB^T$
$\mathrm{tr}(AXX^TB)$	$\mathrm{tr}[X^T(BA+A^TB^T)dX]$	$X^T(BA+A^TB^T)$
$\mathrm{tr}(AX^TXB)$	$\mathrm{tr}[(BA+A^TB^T)X^TdX]$	$(BA+A^TB^T)X^T$

Ch2 特殊矩阵

1.反Hermitian阵 $A=-A^H$. 中心H阵 $r_{ij}=r^*_{n-j+1,n-i+1}$

2.置换阵: 正交 $P^TP=PP^T=I$, P_nA 对行重排, AP_n 对列重排, P^TAP 对角相同

互换阵 $J=\begin{bmatrix}0&\cdots&1\\ 1&\cdots&0\end{bmatrix}$ $J^2=I$, $J^T=J$

广义置换矩阵 G=置换阵·非奇异对角阵 →盲信号分离 $x(t)=As(t)$

广义逆矩阵 $A^+=(A^TA)^{-1}A^T$, $s(t)=A^+x(t)$ $\begin{cases}累加导致信号顺序不确定\\ 信号幅度不确定\quad A=\hat{A}G\end{cases}$

交换阵 $K_{mn}\mathrm{vec}(A_{m\times n})=\mathrm{vec}(A^T)$

3.正交 $QQ^T=Q^TQ=I$, 酉 $UU^H=U^HU=I$ 酉变换 $\langle x,y\rangle=\langle Ax,Ay\rangle$

$\Leftrightarrow U=[u_1\cdots u_n]$ 的列标准正交组 $u_i^Hu_j=\delta(i-j)\Leftrightarrow|\det(U)|=1\Leftrightarrow A^T$ 酉

$\|Ax\|^2=\|x\|^2$, $\cos\theta=\frac{\langle Ax,Ay\rangle}{\|Ax\|\|Ay\|}=\frac{\langle x,y\rangle}{\|x\|\|y\|}$

4.上三角U, 下L, 特殊值为对角元素

5.相似: $B=S^{-1}AS$ (S非奇异) $B\sim A$ $\begin{cases}特值值相同. & Bx=\lambda x\\ 特征向量线性变换 & ASx=\lambda Sx\end{cases}$

$|B|=|A|$, $\mathrm{tr}(B)=\mathrm{tr}(A)$

6.Vandermonde阵 $\begin{bmatrix}1&\cdots&1\\ x_1&\cdots&x_n\\ \vdots\\ x_1^{n-1}&\cdots&x_n^{n-1}\end{bmatrix}$ / $\begin{bmatrix}1&x_1&\cdots&x_1^{n-1}\\ 1&x_2&\cdots&x_2^{n-1}\\ \vdots&\vdots\\ 1&x_n&\cdots&x_n^{n-1}\end{bmatrix}$ $x_i\ne x_j$→非奇异 $\det=\prod_{i,j=1,i>j}^n(x_i-x_j)$

7.Fourier阵 $F=\begin{bmatrix}1&1&\cdots&1\\ 1&w&\cdots&w^{N-1}\\ \vdots&\vdots&&\vdots\\ 1&w^{N-1}&\cdots&w^{(N-1)(N-1)}\end{bmatrix}$ $w=e^{-j2\pi/N}$ $F^T=F$. $F^HF=NI$, $x=F^{-1}\hat{x}=\frac{1}{N}F^*\hat{x}$

8.Hadamard阵 H_n: 所有元素1/-1且 $H_nH_n^T=H_n^TH_n=nI_n$

(1行1列均为+1→规范化Hadamard阵) $n=2$ / $n=4k$, Hadamard阵存在 构造高维正交基

$\frac{1}{\sqrt{n}}H_n$ 标准正交; $\det(H_n)=n^{\frac{n}{2}}$

$n=2^k$, 规范化标准正交Hadamard阵 $H_n=\frac{1}{\sqrt{2}}\begin{bmatrix}H_{n/2}&H_{\frac{n}{2}}\\ H_{\frac{n}{2}}&-H_{\frac{n}{2}}\end{bmatrix}$ $H_2=\frac{1}{\sqrt{2}}\begin{bmatrix}1&1\\ 1&-1\end{bmatrix}$

9.Toeplitz矩阵 任何对角线取值同 $\begin{bmatrix}a_0&a_{-1}&a_{-2}&\cdots&a_{-n}\\ a_1&a_0&&&a_{-1}\\ \vdots\\ a_n&&&a_1&a_0\end{bmatrix}=[a_{i-j}]_{i,j=0}^n$ 对称Toep阵 $A=[a_{|i-j|}]_{i,j=0}^n$

$a_{-i}=a_i^*\to$ Hermitian Toeplitz $A=\begin{bmatrix}a_0&a_1^*&\cdots&a_n^*\\ a_1&a_0&&a_1^*\\ a_n&a_{n-1}&\cdots a_1&a_0\end{bmatrix}$

10.Hankel阵 $A=\begin{bmatrix}a_0&a_1&\\ a_1&&\\ a_n&a_{n+1}&\cdots a_{2n}\end{bmatrix}$

Ch3 矩阵微分

1.行偏导 $D_x=\frac{\partial}{\partial x^T}=[\frac{\partial}{\partial x_1},\cdots,\frac{\partial}{\partial x_m}]$ $D_xf(x)=\frac{\partial f(x)}{\partial x^T}=[\frac{\partial f(x)}{\partial x_1}\cdots\frac{\partial f(x)}{\partial x_m}]$

Jacobian阵 $D_Xf(X)=\frac{\partial f(X)}{\partial X^T_{m\times n}}=\begin{bmatrix}\frac{\partial f(X)}{\partial x_{11}}&\cdots&\frac{\partial f(X)}{\partial x_{m1}}\\ \vdots&&\vdots\\ \frac{\partial f(X)}{\partial x_{1n}}&&\frac{\partial f(X)}{\partial x_{mn}}\end{bmatrix}\in R^{n\times m}$

行偏导向量 $D_{\mathrm{vec}X}f(X)=\frac{\partial f(X)}{\partial\mathrm{vec}^T(X)}=[\frac{\partial f(X)}{\partial x_{11}}\cdots\frac{\partial f(X)}{\partial x_{m1}}\cdots\frac{\partial f(X)}{\partial x_{1n}}\cdots\frac{\partial f(X)}{\partial x_{mn}}]$

$D_{\mathrm{vec}X}f(X)=\mathrm{rvec}(D_Xf(X))=(\mathrm{vec}(D_X^Tf(X)))^T$ / $D_XF(X)=\frac{\partial\mathrm{vec}(F(X))}{\partial(\mathrm{vec}X)^T}\in R^{pq\times mn}$

2.列偏导(梯度算子) $\nabla_x=\frac{\partial}{\partial x}=[\frac{\partial}{\partial x_1}\cdots\frac{\partial}{\partial x_m}]^T$

矩阵变元梯度算子 $\nabla_{\mathrm{vec}X}=\frac{\partial}{\partial\mathrm{vec}X}=[\frac{\partial}{\partial x_{11}}\cdots\frac{\partial}{\partial x_{m1}}\cdots\frac{\partial}{\partial x_{1n}}\cdots\frac{\partial}{\partial x_{mn}}]^T$

梯度矩阵 $\nabla_Xf(X)=\frac{\partial f(X)}{\partial X}=D_X^Tf(X)$ 梯度方向负方向 $-\nabla_xf(x)$→梯度流 $\dot{x}=-\nabla_xf(x)$ / $\dot{X}=-\nabla_{\mathrm{vec}X}f(X)$

$\nabla_XF(X)=\frac{\partial\mathrm{vec}^TF(X)}{\partial\mathrm{vec}X}=(\frac{\partial\mathrm{vec}F(X)}{\partial\mathrm{vec}^TX})^T=(D_XF(X))^T$

3. $\frac{\partial[f(X)g(X)]}{\partial X}=g(X)\frac{\partial f(X)}{\partial X}+f(X)\frac{\partial g(X)}{\partial X}$ $\frac{\partial[f(X)g(X)h(X)]}{\partial X}=g(X)h(X)\frac{\partial f(X)}{\partial X}+f(X)h(X)\frac{\partial g(X)}{\partial X}+f(X)g(X)\frac{\partial h}{\partial X}$

$\frac{\partial[f(X)/g(X)]}{\partial X}=\frac{1}{g^2(X)}[g(X)\frac{\partial f(X)}{\partial X}-f(X)\frac{\partial g(X)}{\partial X}]$ $\frac{\partial g(f(X))}{\partial X}=\frac{dg(y)}{dy}\frac{\partial f(X)}{\partial X}$ $D_XX=I_n\otimes I_m=I_{mn}$

$a^TXX^Tb\to D_Xf(X)=X^T(ba^T+ab^T)$. $\nabla_Xf(X)=(ab^T+ba^T)X$ / $D_X\mathrm{tr}(XB)=D_X\mathrm{tr}(BX)=B$. $\nabla_X\mathrm{tr}(XB)=B^T$

$D_X(AXB)=B^T\otimes A$. $\nabla_X(AXB)=B\otimes A^T$ / $D_X(AX^TB)=(B^T\otimes A)K_{mn}$ $\nabla_X(AX^TB)=K_{nm}(B\otimes A^T)$

$D_X(XX^T)=(K_{mm}+I_{m^2})(X\otimes I_m)$, $\nabla_X(XX^T)=(X^T\otimes I_m)(K_{mm}+I_{m^2})$ / X^TX: $(K_{nn}+I_{n^2})(I_n\otimes X^T)$

$D_X(X^TBX)=((BX)^T\otimes I_n)K_{mn}+(I_n\otimes(X^TB))$. $\nabla_X(X^TBX)=K_{nm}((BX)\otimes I_n)+(I_n\otimes(B^TX))$

4. $\mathrm{tr}(dU)=d(\mathrm{tr}U)$, $d(UV)=dU\cdot V+UdV$, $d(X^T)=(dX)^T$, $d(AXB)=A(dX)B$

$d|X|=|X|\mathrm{tr}(X^{-1}dX)$, $d|F(X)|=|F(X)|\mathrm{tr}(F^{-1}(X)d(F(X)))$. $d(U\otimes V)=(dU)\otimes V+U\otimes dV$

$d(U*V)=(dU)*V+U*dV$, $d(\mathrm{vec}(X))=\mathrm{vec}(dX)$, $d(X^{-1})=-X^{-1}(dX)X^{-1}$

标量函数Jaco辨识 $df(x)=[\frac{\partial f(x)}{\partial x_1},\cdots,\frac{\partial f(x)}{\partial x_m}]\begin{bmatrix}dx_1\\ \vdots\\ dx_m\end{bmatrix}=\frac{\partial f(x)}{\partial x^T}dx=Adx=\mathrm{tr}(Adx)$

$df(x)=\mathrm{tr}(Adx)\Rightarrow D_xf(x)=\frac{\partial f(x)}{\partial x^T}=A$, $df(X)=\mathrm{tr}(AdX)\Rightarrow D_Xf(X)=\frac{\partial f(X)}{\partial X^T}=A\Rightarrow\nabla_Xf(X)=A^T$

$\nabla_x(x^TAx)=(A^T+A)x$, $\mathrm{tr}[A(dX)B]=\mathrm{tr}[BAdX]$, $\mathrm{tr}[A(dX)^TB]=\mathrm{tr}(A^TB^TdX)$

$\nabla_XF(X)=(B\otimes A^T)+K_{nm}(D\otimes C^T)$

$dF(X)=A(dX)B+C(dX^T)D\Rightarrow D_XF(X)=(B^T\otimes A)+(D^T\otimes C)K_{mn}$

5.Hessian阵 $H[f(x)]=\frac{\partial^2f(x)}{\partial x\partial x^T}=\frac{\partial}{\partial x}[\frac{\partial f(x)}{\partial x^T}]=\nabla_x^2f(x)=\nabla_x(D_xf(x))=\begin{bmatrix}\frac{\partial^2f}{\partial x_1\partial x_1}&\cdots&\frac{\partial^2f}{\partial x_1\partial x_m}\\ \frac{\partial^2f}{\partial x_m\partial x_1}&\cdots&\frac{\partial^2f}{\partial x_m\partial x_m}\end{bmatrix}$ 实对称

$d^2f(x)=(dx)^TBdx\Rightarrow H[f(x)]=\frac{1}{2}(B^T+B)$, $d^2f(X)=(d(\mathrm{vec}X))^TBd(\mathrm{vec}X)\Rightarrow H[f(X)]=\frac{1}{2}(B^T+B)$

$d^2f(X)=\mathrm{tr}(V(dX)U(dX)^T)\Rightarrow H[f(X)]=\frac{1}{2}(U^T\otimes V+U\otimes V^T)$ / $\mathrm{rank}(A^HA)=\mathrm{rank}(AA^H)=\mathrm{rank}(A)$

$f(X)=\mathrm{tr}(X^TAX)\to H[f(X)]=I\otimes(A+A^T)$

形式偏导 $\frac{\partial}{\partial z}=\frac{1}{2}(\frac{\partial}{\partial x}-j\frac{\partial}{\partial y})$, $\frac{\partial}{\partial z^*}=\frac{1}{2}(\frac{\partial}{\partial x}+j\frac{\partial}{\partial y})$ 实/虚部独立性假设 $\frac{\partial x}{\partial y}=\frac{\partial y}{\partial x}=0$ | $\frac{\partial z}{\partial z^*}=\frac{\partial z^*}{\partial z}=0$ (z, z^* 相互独立)

$\nabla_zf(z,z^*)=\frac{\partial f(z,z^*)}{\partial z}\Big|_{z^*=常}=(D_zf(z,z^*))^T$ $z\to z^*$ / $df(z,z^*)=\frac{\partial f(z,z^*)}{\partial z^T}dz+\frac{\partial f(z,z^*)}{\partial z^H}dz^*$

$$\begin{cases}\frac{\partial z^T}{\partial z}=I,\ \frac{\partial z^H}{\partial z}=0,\ \frac{\partial z}{\partial z^T}=I,\ \frac{\partial z}{\partial z^H}=0\\ \frac{\partial z^T}{\partial z^*}=0,\ \frac{\partial z^H}{\partial z^*}=I,\ \frac{\partial z^*}{\partial z^T}=0,\ \frac{\partial z^*}{\partial z^H}=I\end{cases}$$

例: $\phi(x)=(f(x))^TAg(x)$ 证 $D_x\phi(x)=(g(x))^TA^TD_xf(x)+(f(x))^TAD_xg(x)$

$[D_x\phi(x)]_i=\frac{\partial(f(x))^TAg(x)}{\partial x_i}=\frac{\partial(f(x))^T}{\partial x_i}Ag(x)+(f(x))^TA\frac{\partial g(x)}{\partial x_i}=(g(x))^TA^T\frac{\partial f(x)}{\partial x_i}+\cdots$

$d(f(x))^T=dx^T\frac{\partial f(x)}{\partial x}$, $dg(x)=\frac{\partial g(x)}{\partial x^T}dx$

$(Ax+b)^T(Dx+e)\to H=A^TD+D^TA$

$d|X|=|X|\mathrm{tr}(X^{-1}dX)$, $D_X|X|=|X|X^{-1}$, $\nabla_X|X|=|X|X^{-T}$

估计误差的协方差阵 $E\{(\theta-\hat{\theta}_{WLS})(\theta-\hat{\theta}_{WLS})^T\}$, 最优一致方差误差 min, $\frac{\partial\mathrm{tr}(K)}{\partial W}=0$

相似化: 特征值重复次数(代数多重度k) / 几何多重度 $n-\mathrm{rank}(A-\lambda I)$

实阵/单根 ✓ $\mathrm{rank}(A-\lambda I)=n-k$ ✓

等价: 优化问题+约束条件

$A\theta+\varepsilon=x$, ε 为加性有色噪向. $E\{\varepsilon\}=0$. $E\{\varepsilon\varepsilon^T\}=R$(已知)

加权误差函数 $Q(\theta)=\varepsilon^TW\varepsilon$ (W对称阵), $\frac{\partial Q}{\partial\theta}=2A^TWA\theta-2A^TWx=0$

$\hat{\theta}_{WLS}=(A^TWA)^{-1}A^TWx$. $K=E\{(\theta-\hat{\theta}_{WLS})(\theta-\hat{\theta}_{WLS})^T\}$ 令 $\frac{\partial\mathrm{tr}(K)}{\partial W}=0\Rightarrow W_{opt}=R^{-1}$

方程解情况: $m\ge n$ $\mathrm{rank}(A)=\mathrm{rank}[A\ b]=n$, 唯一解

$\mathrm{rank}(A)=\mathrm{rank}[A\ b]<n$, 无穷

$\mathrm{rank}(A)<\mathrm{rank}[A\ b]$, 无

ch4 梯度分析与最优化

- 无约束优化：松弛（$f(x_{k+1}) \le f(x_k)$）/逼近

全局极小点 $f(x^*) \le f(x), \forall x \in D, x \ne x^*$

(开)邻域 $B_o(c;r)=\{x \mid x\in D, |x-c|<r\}$ 闭 $B_c(c;r)$：$\le$

平稳点 $f'(c)=0 \begin{cases} f''(c)\ge 0 & \text{局部极小} \\ f''(c)\le 0 & \text{极大}\end{cases}$

鞍点 $f'(c)=0$，$f''(c)=0$．$f'(c+\Delta x)\ge 0$ $f'(c-\Delta x)\le 0$

多变量 $\min_{x\in S} f(x)$ 闭合邻域 $B(\bar{x};r)=\{x \mid \|x-\bar{x}\|_2\le r\}$

二阶泰勒级数逼近：$f(c+\Delta x)=f(c)+(\nabla f(c))^T\Delta x+\frac{1}{2}(\Delta x)^T H[f(c)]\Delta x$

$\nabla f(c)=\frac{\partial f(c)}{\partial c}$，$H[f(c)]=\frac{\partial^2 f(c)}{\partial c\,\partial c^T}$

$(\Delta x)^T H[f(c)]\Delta x\ge 0$ 对$\forall\ 0<\|\Delta x\|_2<r$ / $H[f(c)]\succeq 0$ **局部极小**

$f(X)$ 邻域 $B(C;r)=\{X \mid X\in R^{m\times n}, \|\mathrm{vec}X-\mathrm{vec}C\|_2<r\}$

泰勒：$f(C+\Delta X)=f(C)+\overset{\nabla_{\mathrm{vec}C} f(C)}{\left(\frac{\partial f(C)}{\partial \mathrm{vec}(C)}\right)^T}\mathrm{vec}(\Delta X)+\frac12(\mathrm{vec}(\Delta X))^T\overset{=H[f(C)]}{\frac{\partial^2 f(C)}{\partial\mathrm{vec}(C)\,\partial(\mathrm{vec}C)^T}}\mathrm{vec}(\Delta X)$

1. **闭式解**：超定$Az=b$的最小二乘法，$J(z)=\|Az-b\|_2^2=(Az-b)^H(Az-b)$为准则函数

令$\nabla_{z^*}J(z)=A^HAz-A^Hb=0\Rightarrow z=(A^HA)^{-1}A^Hb$

梯度向量 $\nabla f(z,z^*)=\left[\frac{\partial f(z,z^*)}{\partial z}\ \frac{\partial f(z,z^*)}{\partial z^*}\right]^T$

最大似然法 $l(\hat z)=C-\frac{1}{\sigma^2}e^He=C-\frac{1}{\sigma^2}(b-A\hat z)^H(b-A\hat z)$

$\nabla_{\hat z^*}l(\hat z)=\frac{1}{\sigma^2}A^Hb-\frac{1}{\sigma^2}A^HA\hat z=0$

2. **极值点辨识** $H_{z^*,z}=\frac{\partial^2 f(z,z^*)}{\partial\mathrm{vec}\,z^*\,\partial(\mathrm{vec}\,z)^T}$

局部极小：共轭梯度为0且全Hermi阵半正定 $\begin{cases}\left.\frac{\partial f(z,z^*)}{\partial z^*}\right|_{z=z_0}=0\\ \begin{bmatrix}H_{z^*,z}&H_{z^*,z^*}\\H_{z,z}&H_{z,z^*}\end{bmatrix}_{z=z_0}\succeq 0\end{cases}$

3. **最速下降方向** $-\nabla_{z^*}f(z,z^*)$

凸优化理论 $\min_x f_0(x)$ s.t. $f_i(x)\le 0$，$h_i(x)=0$

决策变量x很大，多局部解，收敛速度差，收敛停止准则失效

凸函数Jensen不等式：$f(\alpha x+(1-\alpha)y)\le\alpha f(x)+(1-\alpha)f(y)$．$x,y\in S$．$\alpha\in[0,1]$

辨识的二阶充要：$f(x)$凸仅当 $H_x f(x)=\frac{\partial^2 f(x)}{\partial x\,\partial x^T}\succeq 0$．$\forall x\in S$ $\arg\min f(x)=x_{opt}$

下降法/线搜索法：$\min_{x\in R^n} f(x)$ 无约束．$x_{k+1}=x_k+\mu_k\Delta x_k$．k迭代次数．$\mu_k\ge0$步长，$\Delta x$步行/搜索方向

一阶泰近似 $f(x_{k+1})\approx f(x_k)+[\nabla f(x_k)]^T\Delta x_k\Rightarrow[\nabla f(x_k)]^T\Delta x_k<0$．$\Delta x_k=-\nabla f(x_k)\cos\theta$．$\theta\in[0,\frac{\pi}{2})$

$\max_{\Delta x_k}\|\Delta x_k\|_2\Rightarrow\theta=0$．$\Delta x_k=-\nabla f(x_k)\to$最速下降法/Newton法．$\Delta x_k=-(\nabla^2 f(x_k))^{-1}\nabla f(x_k)$

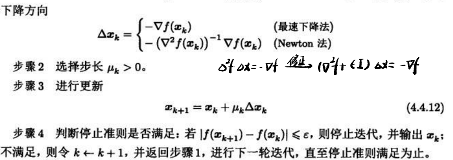

初始化　选择一个起始点 $x_1\in\mathrm{dom}\,f$ 和允许精度 $\varepsilon>0$，并且令 $k=1$。

步骤 1　计算目标函数在点 x_k 的梯度 $\nabla f(x_k)$ (以及 Hessian 矩阵 $\nabla^2 f(x_k)$)，并选择下降方向

$$\Delta x_k=\begin{cases}-\nabla f(x_k) & \text{(最速下降法)}\\ -\left(\nabla^2 f(x_k)\right)^{-1}\nabla f(x_k) & \text{(Newton 法)}\end{cases}$$

步骤 2　选择步长 $\mu_k>0$。

步骤 3　进行更新

$$x_{k+1}=x_k+\mu_k\Delta x_k \tag{4.4.12}$$

步骤 4　判断停止准则是否满足：若 $|f(x_{k+1})-f(x_k)|\leqslant\varepsilon$，则停止迭代，并输出 x_k；若不满足，则令 $k\leftarrow k+1$，并返回步骤1，进行下一轮迭代，直至停止准则满足为止。

$\nabla^2 f\,\Delta x=-\nabla f \xrightarrow{\text{修正}} (\nabla^2 f+\epsilon I)\Delta x=-\nabla f$

① **固定步长**：$\mu_k=\mu$ / $\mu_k=\frac{h}{\sqrt{k+1}}$ ② **全松弛** $\mu_k=\arg\min_{\mu\ge0} f(x_k-\mu\nabla f(x_k))$ costly

③ **Armijo准则**：$c_1\in(0,1)$．$f(x_k-\mu\nabla f(x_k))\le f(x_k)-c_1\mu\nabla f_k^T\nabla f(x_k)$

$f(x_k-\mu\nabla f(x_k))\ge f(x_k)-(1-c)\mu\nabla f_k^T\nabla f(x_k)$

④ **Goldstein准则**：$c\in(0,\frac12)$．$f(x_k-\mu\nabla f(x_k))\le f(x_k)-c\mu\nabla f_k^T\nabla f(x_k)$

约束$x\in C\subset R^n$-梯度投影法．$x_{k+1}=P_C(x_k-\mu_k\nabla f(x_k))$ **投影算子** $P_C(y)=\arg\min_{x\in C}\frac12\|x-y\|_2^2$

$a^Tx=b$．$P_C(x)=x+\frac{b-a^Tx}{\|a\|_2^2}a$ / $Ax=b$．$P_C(x)=x+A^T(AA^T)^{-1}(b-Ax)$ / $\|x\|_2\le1$．$P_C(x)=\begin{cases}x, &\|x\|_2\le1\\ \frac{x}{\|x\|_2}, &\|x\|_2>1\end{cases}$

算法结束：$\|\nabla f_k\|^2<\epsilon$，$\|f_{k+1}-f_k\|<\epsilon$

约束-Lagrangian乘子法 $L(\underline{x},\underline{\lambda},\underline{\nu})=f_0(x)+\sum_{i=1}^m\lambda_if_i(x)+\sum_{i=1}^q\nu_ih_i(x)$ $\lambda_i\ge0$，ν_i无约束

$\min_x f(x)$ s.t. $Ax=b$．$L(x,\lambda)=f(x)+\lambda^T(Ax-b)$ $\begin{cases}\text{固定}\lambda_k\text{，更新}x_k\text{：}x_{k+1}=\arg\min_x L(x,\lambda_k)\\ \text{固定}x_k\text{，更新}\lambda_k\text{：}\nabla_\lambda L=Ax-b\text{．}\lambda_{k+1}=\lambda_k+\mu_k(Ax_k-b)\end{cases}$

罚函数 $\min_x f_0(x)$ s.t. $f_i(x)\ge0$．$h_j(x)=0$．$x\in F\subseteq S\subseteq R^n$ 有约→无约

加性 $L(x)=\begin{cases}f_0(x), & x\in F\\ f_0(x)+p(x), & \text{else }(p(x)>0)\end{cases}$ **乘性** $L(x)=\begin{cases}f_0(x), & x\in F\\ f_0(x)p(x), & \text{else }(p(x)>1)\end{cases}$

等式 $\min_x f_0(x)$ s.t. $h_i(x)=0\to p(x)=\sum_{i=1}^q|h_i(x)|^2$．$L_p(x)=f_0(x)+\rho\sum_{i=1}^q|h_i(x)|^2$

不等式 s.t. $f_i(x)\ge0\to$ 外罚 $p(x)=\sum_{i=1}^m(\max\{0,-f_i(x)\})^r$ $r=1,2$ / 内罚 $\phi(x)=\begin{cases}0, & x\in\mathrm{int}(F)\\ \infty, & x\to\mathrm{bnd}(F)\end{cases}$

$p(x)=\sum_{i=1}^m\left[\frac{1}{f_i(x)}\right]^p_{(p\ge1)}$ / $\sum_{i=1}^m\frac{1}{f_i(x)}\log(f_i(x))$ / $\sum_{i=1}^m\exp\left[\frac{1}{f_i(x)}\right]$ 启动点要求高，收敛快

ch6 矩阵方程求解

rank[A b]>rank(A)．b无法被A中列线性组合表示．$b\ne Ax$ 无解 (m>n)

rank[A b]=rank(A)．b=Ax有解 $\begin{cases}=n & \text{唯一解}(m=n)\\ <n & \text{无穷解}(m<n)\end{cases}$

普通最小二乘OLS：$Ax=b+\Delta b$．$\min_x\|\Delta b\|_2^2=\min_x\|Ax-b\|_2^2=\min_x f(x)$

$f(x)=(Ax-b)^T(Ax-b)$．$\nabla_x f(x)=2A^TAx-2A^Tb=0\Rightarrow A^TAx=A^Tb$

① A：m≥n．rank(A)=n列满秩．A^TA可逆．$\boxed{\hat x_{LS}=(A^TA)^{-1}A^Tb}$

② m≥n．rank(A)<n．$\boxed{x_{LS}=(A^TA)^{\dagger}A^Tb=A^{\dagger}b=(V\Sigma^{\dagger}U^T)b}$ (秩亏最小二乘解)

③ rank(A)=m<n．欠定．不可辨识

Gauss-Markov定理：$Ax=b+e\to$随机误差向量零均值白噪声 $Cov(e)=E(ee^H)=\sigma^2I$

$\hat x_{LS}$是待估参向x的最小方差无偏估计 $E(\hat x_{LS})=x$ $Var(\hat x_{LS})\le Var(\tilde x)$

极大似然：$Ax=b+e$．$b=Ax+e$（来自模型Ax的数据向量b受到e的污染）

$e\sim N(0,\sigma^2I)$．似然函数 $L(x)=p(b|Ax)=N(b|Ax,\sigma^2I)=\overset{\text{(N归一化因子)}}{\frac{1}{N}}\exp\left[-\frac{(b-Ax)^T(b-Ax)}{\sigma^2}\right]$

$\ln L(x)=\ln\frac1N-\frac{(b-Ax)^T(b-Ax)}{\sigma^2}$，$\max_x p(b|Ax)=\max_x L(x)=\min_x\|Ax-b\|_2^2$ 等价OLS

Tikhonov正则化：$A^TAx=A^Tb$

$\begin{cases}\text{列满秩}\ \mathrm{cond}(A^TA)=[\mathrm{cond}(A^2)]\\ \text{秩亏．min奇异值}=0\text{，}\mathrm{cond}(A^TA)=\frac{\sigma_{max}}{\sigma_{min}}=\frac{\sigma_1}{0}\to\infty\ \text{稳定性低}\end{cases}$

条件数：描述求解方法数值稳定性 $\mathrm{cond}(A)=\|A\|\cdot\|A^{-1}\|$ $\mathrm{cond}(A^TA+\lambda I)<\infty$ 稳↑

$J(x)=\|Ax-b\|_2^2+\lambda\|x\|_2^2$．$\lambda\ge0$ 正则化系数$\to\hat x_{Tik}=(A^TA+\lambda I)^{-1}A^Hb=U\Sigma U^T+\lambda UU^T=U(\Sigma+\lambda I)U^T$

数据最小二乘DLS：$A_0x=b$．$A=A_0+E$．$E_{ij}\sim N(0,\sigma^2)$ $\min_x\|\Delta A\|_F^2$ s.t. $(A+\Delta A)x=b$

$L(\Delta A,x,\lambda)=\|\Delta A\|_F^2+\lambda^H[(A+\Delta A)x-b]=\mathrm{tr}(\Delta A\Delta A^H)+\lambda^H[(A+\Delta A)x-b]$ $\frac{\partial L}{\partial\Delta A}=\frac{\partial L}{\Delta\lambda^H}=0$

$\lambda=\frac{Ax-b}{x^Hx}$，$\Delta A=-\frac{(Ax-b)x^H}{x^Hx}$，$\hat x_{DLS}=\arg\min_x\frac{(Ax-b)^H(Ax-b)}{x^Hx}$

总体最小二乘TLS：$A_0x=b_0$．$b=b_0+e$．$A=A_0+E$，$\min_{\Delta A,\Delta b,x}\|\Delta A\|_F^2+\|\Delta b\|_2^2$ s.t. $(A+\Delta A)x=b+\Delta b$

约束 $[A\ b]\begin{bmatrix}x\\-1\end{bmatrix}+[\Delta A\ \Delta b]\begin{bmatrix}x\\-1\end{bmatrix}=(B+D)z=0$ ↘ $\min_{D,z}\|D\|_F^2$ s.t. $(B+D)z=0$

$B=[A\ b]$数据增广．$D=[\Delta A\ \Delta b]$校正增广 $\hat z=\arg\min_z\frac{z^HB^HBz}{z^Hz}$（Reyleigh商取min时z）

$\rho(B^HB)=\frac{z^HB^HBz}{z^Hz}$，$\lambda_{min}\le\rho(B^HB)\le\lambda_{max}$ λ_{min}对应特征向量

$\begin{cases}\text{对}B^HB\text{特征分解}\to\lambda_{min}\text{对应的特向}\\ \text{对}B\text{奇异分解}\to\sigma_{min}\text{对应的奇向}\end{cases}$

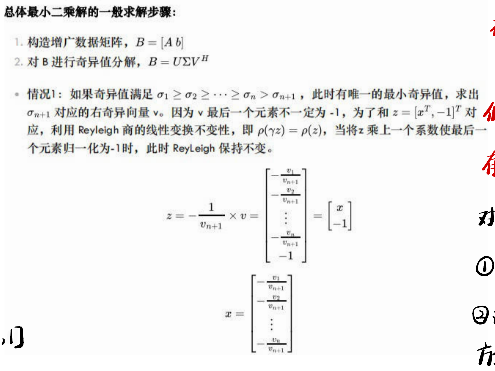

总体最小二乘解的一般求解步骤：

1. 构造增广数据矩阵，$B=[A\ b]$
2. 对 B 进行奇异值分解，$B=U\Sigma V^H$

- 情况1：如果奇异值满足 $\sigma_1\ge\sigma_2\ge\cdots\ge\sigma_n>\sigma_{n+1}$，此时有唯一的最小奇异值，求出 σ_{n+1} 对应的右奇异向量 v。因为 v 最后一个元素不一定为 -1，为了和 $z=[x^T,-1]^T$ 对应，利用 Reyleigh 商的线性变换不变性，即 $\rho(\gamma z)=\rho(z)$，当将z 乘上一个系数使最后一个元素归一化为-1时，此时 ReyLeigh 保持不变。

$$z=-\frac{1}{v_{n+1}}\times v=\begin{bmatrix}-\frac{v_1}{v_{n+1}}\\-\frac{v_2}{v_{n+1}}\\ \vdots\\-\frac{v_n}{v_{n+1}}\\-1\end{bmatrix}=\begin{bmatrix}x\\-1\end{bmatrix}$$

$$x=\begin{bmatrix}-\frac{v_1}{v_{n+1}}\\-\frac{v_2}{v_{n+1}}\\ \vdots\\-\frac{v_n}{v_{n+1}}\end{bmatrix}$$

ch5 奇异值分析SVD：非方阵 $Y=U\Sigma V^H$

方阵 $Y=U\Sigma U^H$，$Y^2=U\Sigma^2U^H$ $\det(Y)=\det(\Sigma)=\prod\sigma_i$

非方 $Y=U\Sigma V^H$，$YY^H=U\Sigma^2U^H$，$Y^HY=V\Sigma^2V^H$ 对YY^HEVD得 U、λ_i，$\sigma_i=\sqrt{\lambda_i}$

伪逆：m>n，A列满秩$=U\begin{bmatrix}\Sigma_n\\0\end{bmatrix}V^H$，$L=V\Sigma^{\dagger}U^H=(A^HA)^{-1}A$

m≤n，行满，$R=V\Sigma^{\dagger}U^H$ / 秩亏 $\mathrm{rank}(A)<\min\{m,n\}$．$A^{\dagger}=V\Sigma^{\dagger}U^H$

$\Sigma^{\dagger}=\begin{bmatrix}\Sigma^{-1}&0\\0&0\end{bmatrix}$，$\Sigma^{-1}=\mathrm{diag}(\frac{1}{\sigma_1},\frac{1}{\sigma_2},\cdots\frac{1}{\sigma_r})$

范数：$\|A\|_2=\|A\|_{spec}=\max_{x\ne0}\frac{\|Ax\|_2}{\|x\|_2}=\sigma_1$

$\max_x\|Ax\|_2^2$ s.t. $\|x\|_2=I$，$x_{opt}\begin{cases}A^HA\ \max\lambda\to u\\ \max\sigma\to v\end{cases}$

$\|Ax_{opt}\|^2=\lambda_{max}=\sigma_{max}^2$，$\|A\|_F=\sqrt{\sum\sigma_i^2}$

复共轭转置/酉变换奇异值不变

数据降噪 $X=U\Sigma_rV_r^H=\sum_{i=1}^r\sigma_iu_iv_i^T$（由r个rank-1分量相加），$Y=X+\overset{\text{噪}}{N}=\sum_{i=1}^{k\gg r}\tilde\sigma_i\tilde u_i\tilde v_i^T$

近似 $\hat X=\sum_{i=1}^r\hat\sigma_i\hat u_i\hat v_i^T$

截断 $Y_{m\times n}=U_{m\times m}\begin{bmatrix}\Sigma_r&0\\0&0\end{bmatrix}V_{n\times n}^H$ U、V酉矩阵．$\sigma_1>\sigma_2>\cdots>\sigma_r\ge0$ $r=\mathrm{rank}(Y)$

$=[\underset{m\times n}{U_r}\ A]\begin{bmatrix}\Sigma_r&0\\0&0\end{bmatrix}[\underset{n\times r}{V_r}\ B]^H=U_r\Sigma_rV_r^H$（数据压缩）$\begin{cases}U_{m\times m}\ \text{标准正交变换}\\ U_{r\,m\times r}\ \text{PCA/KL}\end{cases}$

低秩逼近：p≤r，找$\mathrm{rank}(\hat Y)=p$矩阵逼近Y，$\min_{\hat Y}\|Y-\hat Y\|_2=\sigma_{p+1}$ / $\|Y-\hat Y\|_F=\sqrt{\sum_{i=p+1}^r\sigma_i^2}$ s.t. $\mathrm{rank}(\hat Y)=p<r$

有效秩确定 $\bar Y=Y+N$ (m≥n)．$\mathrm{rank}(Y)=r$．$\mathrm{rank}(N)=\mathrm{rank}(\bar Y)=n$

对r的估计(有效秩$\hat r$) $\begin{cases}\text{过大，过拟合，造成拟合噪声}\\ \text{过小，欠拟合，丢失信号分量}\end{cases}$

① 归一化奇异值：$\bar Y$ SVD，$\bar\sigma_i=\frac{\sigma_i}{\sigma_1}$ $\begin{cases}\text{信号>噪声，SNR大}\ 1\ge\frac{\sigma_2}{\sigma_1}\ge\cdots\ge\frac{\sigma_k}{\sigma_1}\gg\frac{\sigma_{k+1}}{\sigma_1}\ge\cdots\ge0\text{，}\hat r=k\\ \epsilon>\frac{\sigma_{k+1}}{\sigma_1}\ge\cdots\ge0\text{，}\hat r=k\ (\epsilon=0.1/0.05)\end{cases}$

② 范数比法 $v(r)=\frac{\|\bar Y_k\|_F}{\|\bar Y\|_F}\le1$，$v(k)\ge\alpha=0.9/0.95\cdots$ 最小k

方程解的稳定性(条件数)：A，b扰动→x影响 $A(x+\delta x)=b+\delta b$

A方．$A\delta x=\delta b$．$\delta x=A^{-1}\delta b$．$\|\delta x\|_2\le\|A^{-1}\|_2\|\delta b\|_2$，$\|b\|_2\le\|A\|_2\|x\|_2$

$\frac{\|\delta x\|_2}{\|x\|_2}\le(\|A\|_2\|A^{-1}\|_2)\frac{\|\delta b\|_2}{\|b\|_2}$ / $\frac{\|\delta x\|_2}{\|x+\delta x\|_2}\le(\|A\|_2\|A^{-1}\|_2)\frac{\|\delta A\|_2}{\|A\|_2}$

右边解向量相对误差，$\mathrm{cond}(A)=\|A\|_2\|A^{-1}\|_2=\frac{\sigma_{max}}{\sigma_{min}}$

ch7 特征分析EVD：Hermitian方阵 $A=U\Sigma U^H\to$降维(PCA/KL定理)，去相关

$Au=\lambda u$，$(A-\lambda I)u=0$，$\det(A-\lambda I)=0$ $A=A^H\to\forall\lambda_n\in R$．$A=U\Sigma U^H$

同特征值重复次数：多重度 特征矩阵 $(A-\lambda_iI)u=Du=0\to$非零解u

性质：实对称/Hermi阵，∀λ实；$\lambda=\mathrm{eig}(A)\Rightarrow\lambda=\mathrm{eig}(A^T)$，$\lambda^*=\mathrm{eig}(A^H)$．$\lambda+\sigma^2=\mathrm{eig}(A+\sigma^2I)$，$\frac1\lambda=\mathrm{eig}(A^{-1})$

$\mathrm{eig}(A^2=A)=0/1$；$\mathrm{tr}(A)=\sum\lambda_i$，$\det(A)=\prod\lambda_i$ / $A^nu=\lambda^nu$．$[e^A]u=\sum_{i=0}^\infty\frac{1}{i!}A^iu=\sum_{i=0}^\infty\frac{1}{i!}\lambda^iu=e^\lambda u$

矩阵谱λ(A)：所有特征值集合．谱半径 $\rho(A)=\max|\lambda_i|$

$f(A)=A^n+c_1A^{n-1}+\cdots+c_{n-1}A+c_nI$ $[f(A)]u=\overbrace{(\lambda^n+c_1\lambda^{n-1}+\cdots+c_n)}^{f(A)\text{的特征值}}u$ $\{p_n\}$来自$\det(A-xI)$

Cayley-Hamilton定理：$p_nA^n+p_{n-1}A^{n-1}+\cdots+p_0I=0\Rightarrow A^{-1}=-\frac{1}{p_0}(p_nA^{n-1}+p_{n-1}A^{n-2}+\cdots+p_2A+p_1I)$

EVD：$X=U\Sigma U^H=[u_1u_2\cdots u_n]\begin{bmatrix}\lambda_1&&\\&\lambda_2&\\&&\ddots\ \lambda_n\end{bmatrix}\begin{bmatrix}u_1^H\\ \vdots\\ u_n^H\end{bmatrix}=\sum_{i=1}^n\lambda_i\underline{u_i}\underline{u_i}^H$ $(\lambda_1\ge\lambda_2\cdots\ge\lambda_n)$

线性降维 $\underset{M\times D}{W}\underset{D\times1}{x_n}=\underset{M\times1}{z_n}$ opt．W 使$Var(z_n)$ max $\underset{D\times1}{\{x_n\}_{n=1}^N}$，$\mu=\frac1N(\sum_{n=1}^N x_n)$，$\underset{D\times D}{C}=\frac1N\sum_{n=1}^N(x_n-\mu)(x_n-\mu)^H$估计协方差阵

$C=U\Sigma U^H=[u_1u_2\cdots u_D]\begin{bmatrix}\lambda_1&&\\&\ddots&\\&&\lambda_D\end{bmatrix}\begin{bmatrix}u_1^H\\ \vdots\\ u_D^H\end{bmatrix}$ $(\lambda_1\ge\lambda_2\ge\cdots\ge\lambda_D)$．取 $\begin{bmatrix}u_1^H\\ \vdots\\ u_M^H\end{bmatrix}_{M\times D}\cdot x_n=z_n$ [PCA]

M=1．$Var(z_n)=\phi_1^HC\phi_1$，$\max_{\phi_1}\phi_1^HC\phi_1$ s.t. $\phi_1^H\phi_1=1\to\max_{\phi_1}\phi_1^HC\phi_1+\lambda(1-\phi_1^H\phi_1)=f(\phi_1)$

$\nabla_{\phi_1}f(\phi_1)=0\Rightarrow C\phi_1=\lambda\phi_1$．$f(\phi_1)=\lambda$

标准正交变换：$x_{m\times1}$随机向量．均值向量m_x．协方差阵C_x / $x_0=x-m_x$ 0均值．$R_{x_0}=C_x$

$C_x=U_x\Sigma_xU_x^H$，线性变换 $w=U_x^Hx_0=U_x^H(x-m_x)\Rightarrow m_w=0$．$C_w=C_x=E\{ww^H\}=\Sigma_x$

0均值的正态向量 正交=统计不相关=统计独立 / U_x标准正交阵 / 白化

迷向圆变换：$C_x=I$．$\Sigma^{-\frac12}\Sigma\Sigma^{-\frac12}=I$ / $y=\Sigma_x^{-\frac12}U_x^H(x-m_x)$，$R_y=C_x=I$

离散KL变换（降维．本质PCA．信号重构）$\underset{D\times1}{x}\to\underset{M\times1}{\tilde w}=U_M^Hx\to\hat x=U_M\tilde w$

重构最优性 $\underline e=\underline x-\underline{\hat x}=\underline U\underline w-U_M\tilde w=\sum_{i=1}^D\underline{u_i}w_i-\sum_{i=1}^M\underline{u_i}\underline{w_i}=\sum_{i=M+1}^Du_iw_i=[\underline{u_{M+1}}\cdots\underline{u_D}]\underline{w_e}$

$E[e^He]=\sum_{i=M+1}^D\lambda_i$ 广义特征值分解 $Au=\lambda Bu$，$\det(A-\lambda B)=0$

Rayleigh商 $R(x)=\frac{x^HAx}{x^Hx}$（TLS $\min_xR(x)$ / PCA $\max_xR(x)$）

$\max_xR(x)\Leftrightarrow\max_x x^HAx$ s.t. $x^Hx=I\Leftrightarrow A=U\Sigma U^H$，$x^*=u_1$．$[R(x)]_{max}=\lambda_1$

设计滤波器x^H，对$r(t)=Bs(t)+n(t)$滤波．输出SNRmax

$x^Hr(t)=x^HBs(t)+x^Hn(t)$．$SNR=\frac{E(|x^HBs(t)|^2)}{E(|x^Hn(t)|^2)}=\frac{\alpha x^HBB^Hx}{\beta x^Hx}$

$E(s(t)s^H(t))=\alpha I$．$E(n(t)n^H(t))=\beta I$ 最小特征值对应特向

TLS $\min_zR(z)=\frac{z^HB^HBz}{z^Hz}$，$B^HB=V\Sigma V^H$，$z_{opt}=\underline{V}_{min}=\begin{bmatrix}x\\-1\end{bmatrix}$

$=\frac{\|Ax-b\|_2^2}{\|x\|_2^2+1}=\frac{\sum_{i=1}^m(a_i^Tx-b_i)^2}{\|x\|_2^2+1}$

TLS拟合直线：均值 $\bar x=\frac1n\sum x_i$ (y)；$M=\begin{bmatrix}x_1-\bar x&y_1-\bar y\\ \cdots&\cdots\\x_n-\bar x&y_n-\bar y\end{bmatrix}$；对$M^HM$ EVD$=U\Sigma U^T$

λ_{min}对应$u=\begin{bmatrix}a\\b\end{bmatrix}$；直线 $a(x-\bar x)+b(y-\bar y)=0$；距离平方和 $D_{LS}=\|Mu\|_2^2$

一般最小二乘 $D_{LS}^{(1)}=\sum[m(x_i-\bar x)+(y_i-\bar y)]^2$，$\frac{\partial D_{LS}^{(1)}}{\partial m}=0\Rightarrow m_1$；直线 $m_1(x-\bar x)+(y-\bar y)=0$；$d_{LS}^{(1)}=\frac{D_{LS}^{(1)}}{1+m_1^2}$

$A=U\Sigma V^H$，$A^{-1}=U\Sigma^{-1}V^H$

$\|A\|_2=\sigma_{max}$，$\|A^{-1}\|_2=\frac{1}{\sigma_{min}}$

良态：$\mathrm{cond}(A)\to1$，小扰→小扰 病态 $\mathrm{cond}(A)\ \infty$

A非方 $A^HAx=A^Hb$，$\mathrm{cond}(A^HA)=\left(\frac{\sigma_{max}}{\sigma_{min}}\right)^2=[\mathrm{cond}A]^2$

QR分解，正交分解 $A=QR$ ($Q^HQ=I$，$\sigma_i=1$)

(稳↑) $\mathrm{cond}(Q)=1$，$\mathrm{cond}(QR)=\mathrm{cond}(R)$
$=\mathrm{cond}(Q^HA)$

稳定点：

$\nabla f(\bar x)=\frac{\partial f(\bar x)}{\partial\bar x}=\begin{bmatrix}\frac{\partial f(\bar x)}{\partial x_1}\\ \frac{\partial f(\bar x)}{\partial x_2}\end{bmatrix}=\begin{bmatrix}4x_1-2x_2+6x_1^2+4x_1^3\\ 2x_2-2x_1\end{bmatrix}=\begin{bmatrix}0\\0\end{bmatrix}$

⇒ 所有一阶稳定点 $\bar x_1=[0\ 0]^T$，$\bar x_2=[-1\ -1]^T$，$\bar x_3=[-\frac12\ -\frac12]$

$H(f(\bar x))=\frac{\partial^2 f(\bar x)}{\partial\bar x\,\partial\bar x^T}=\begin{bmatrix}4+12x_1+12x_1^2&-2\\-2&2\end{bmatrix}$

$H(f(\bar x_1))=\begin{bmatrix}4&-2\\-2&2\end{bmatrix}\succ0$ $\bar x_1$是局部极小点

$H(f(\bar x_2))=\begin{bmatrix}4&-2\\-2&2\end{bmatrix}\succ0$ $\bar x_2$是局部极小点

$H(f(\bar x_3))=\begin{bmatrix}1&-2\\-2&2\end{bmatrix}$不定 $\bar x_3$是鞍点

滤波器：

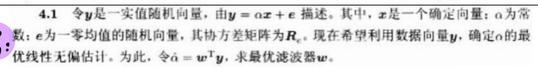

4.1　令y是一实值随机向量，由$y=\alpha x+e$ 描述。其中，x是一个确定向量；α为常数；e为一零均值的随机向量，其协方差矩阵为R_e。现在希望利用数据向量y，确定α的最优线性无偏估计。为此，令$\hat\alpha=w^Ty$，求最优滤波器w。

$E_w=e^HWe=(y-A\theta)^HW(y-A\theta)$，$\nabla_{\theta^*}=A^HWA\theta-A^HWy=0\Rightarrow\hat\theta_{LS}=(A^HWA)^{-1}A^HWy$

$Re(w^Hx)=b\Rightarrow w^Hx+x^Hw=2b$

$\hat a=\hat aw^Tx+w^Te$ 无偏估计约束$w^Tx=1$．方差 $\sigma_{\hat a}^2=E[w^Tee^Tw]=w^TR_ew$．$\min w^TR_ew$ s.t. $w^Tx=1$

$J(w,\lambda)=w^TR_ew+2\lambda(1-w^Tx)\Rightarrow R_ew=\lambda x$，$w^Tx=1$ $\begin{cases}R_e\text{满秩，}w=\lambda R_e^{-1}x\text{ 代入}w^Tx=1\text{．}\lambda=\frac{1}{x^TR_e^{-1}x}\text{，}w=\frac{R_e^{-1}x}{x^TR_e^{-1}x}\\ R_e\text{非满/奇异，}w\text{为}R_e\text{零特征值对应的特向，}\sigma_{\hat a}^2=0\end{cases}$