## U1 Introduction

晶状体与视网膜距离是固定的

**人眼**：感光器官——杆状暗，锥状亮。可适应的亮度范围较窄。感知亮度不是简单的强度函数。是变焦系统（$\frac{1}{u}+\frac{1}{v}=\frac{1}{f}$） 韦伯比表征辨别亮度变化能力

低亮度 ⇒ 韦伯比大 ⇒ 辨别差　量化位数每加1 bit，信噪比提升 6dB.

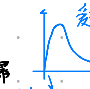

## U2. Fundamentals

我们看见的颜色是由物体reflect自然光决定的. 灰度级一般取2的整数次幂

图像的动态范围定义为最大可度量灰度与最小的比值. In fact 上限饱和度 下限噪声

对比度：最高和最低灰度级的灰度差. 空间分辨率(Resolution) DPI (dots per inch)

bpp (bits per pixel)　人脸识别分辨率至少 64×64. 最好 128×128.

$N_4(p)$　$N_8(p)$　m-adjacency：优先四邻，若无则对角线（消除 N8 歧义）

Distance：街区距 $D_4=|x-s|+|y-t|$　棋盘 $D_8=\max\{|x-s|,|y-t|\}$　欧氏距离

Array Product 直接乘. Matrix Product 矩阵乘　仿射变化（旋转. 放大. 错切. 置换）

Arnold 变换 有周期性(可复原)　$[x,y,1]=[v,w,1]\cdot T$　缩放 $\begin{bmatrix}c_x&&\\&c_y&\\&&1\end{bmatrix}$　旋转 $\begin{bmatrix}\cos\theta&\sin\theta&0\\-\sin\theta&\cos\theta&0\\0&0&1\end{bmatrix}$

几何校正：三角形线性法 $\begin{cases}x_1=au_1+bv_1+c\\x_2\\x_3\end{cases}$ $\begin{cases}y_1=\\y_2\\y_3\end{cases}$　平移 $\begin{bmatrix}1&&\\&1&\\t_x&t_y&1\end{bmatrix}$　Shear $\begin{bmatrix}1&s_h&\\s_v&1&\\&&1\end{bmatrix}$

图像放大 ↑ 反向映射 (x,y)⇐(u,v) 确保遍历所有目标图像

插值算法：① 最近邻. 反向(x,y)可能不在格点上. 取最近　② 双线性内插　引入低通效应

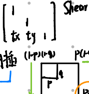

③ 三次卷积法 └ 连续性　边沿模糊 ←　非线性　多次处理

图像相减 用于增强差别. 图像相乘/相除 来校正阴影.

## U3 Intensity Transmations

点处理：$s=T(r)$ ① 灰度倒置：$s=1.0-r$ ⇒ 暗区转亮区 ② 阈值处理 ③ 对数 $s=c\times\log(1+r)$（r<1 相当于对数）窄input转为宽output. 压缩大像素. ④ 幂律：$s=c\cdot r^{\gamma}$　γ<1 压大　γ>1 压小　应对整体过亮　↳ 适用暗图.

Bit Plane：高bit 含有最主要信息. 低bit 有细节.　高对比度图的直方图很 evenly ↳ 因为离散性. 不能完全平衡 → 无用性

直方图均衡化：$p_s(s)\cdot ds=p_r(r)\cdot dr \Rightarrow s=T(r)=(L-1)\cdot\int_0^r p_r(w)\cdot dw \Rightarrow s_k=(L-1)\cdot T(r_k)=(L-1)\cdot\sum\frac{n_j}{n}$

直方图规定化：$s_k=(L-1)\cdot\sum\frac{n_j}{n}$，$G(z_q)=(L-1)\cdot\sum p_z(z_i)=s_k \Rightarrow z_q=G^{-1}(s_k)$

└ 本质：均衡结果相同.

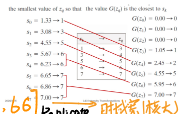

the smallest value of $z_q$ so that　the value $G(z_q)$ is the closest to $s_k$

$s_0=1.33\to1$
$s_1=3.08\to3$
$s_2=4.55\to5$
$s_3=5.67\to6$
$s_4=6.23\to6$
$s_5=6.65\to7$
$s_6=6.86\to7$
$s_7=7.00\to7$

| $s_k$ | → | $z_q$ |
|---|---|---|
| 1 | → | 3 |
| 3 | → | 4 |
| 5 | → | 5 |
| 6 | → | 6 |
| 7 | → | 7 |

$G(z_0)=0.00\to0$
$G(z_1)=0.00\to0$
$G(z_2)=0.00\to0$
$G(z_3)=1.05\to1$
$G(z_4)=2.45\to2$
$G(z_5)=4.55\to5$
$G(z_6)=5.95\to6$
$G(z_7)=7.00\to7$

2026/3/16　L03 Intensity Transformations　88

## U4. Spatial Filtering

Correlation vs Convolution

$g(x,y)=T[f(x,y)]$　Min, Max, Median.　滤波是对应位置直接求

盒式滤波：所有系数都相等的均值滤波. 加权 Smoothing Filter.　[66, 66] Replicate → 时域宽(核大)　频域窄

低通高斯滤波：各向同性. 唯一可分离的圆对称核.　Padding：① 零~：直接填0 ② 复制~：将边界复制 ③ 镜像~ Wrap Around：上补下. 左补右. 为保留大平滑滤波可去除小物.　低通滤~ 估计阴影模式的相法

锐化空间滤波 (highlight fine detail)　1st：前向 $f(x+1)-f(x)$　后向 $f(x)-f(x-1)$　2st $f(x+1)+f(x-1)-2f(x)$

拉普拉斯算子：$\nabla^2 f=\frac{\partial^2 f}{\partial x^2}+\frac{\partial^2 f}{\partial y^2}=f(x+1,y)+\cdots-4f(x,y) \Rightarrow \begin{bmatrix}0&1&0\\1&-4&1\\0&1&0\end{bmatrix}$　提取结果 $g(x,y)=f-$对 $\Rightarrow \begin{matrix}0&-1&0\\-1&5&-1\\0&-1&0\end{matrix}$　核拆中心 加正1相加!

Laplacian 变体：$\begin{bmatrix}1&1&1\\1&-8&1\\1&1&1\end{bmatrix}$ $\begin{bmatrix}1&0&1\\0&-4&0\\1&0&1\end{bmatrix}$ 对角提供锐化

非锐化掩蔽 Unsharp Masking：① 模糊：$\bar f$ ② Mask：$g_m=f-\bar f$ ③ Add：$g=f+k\cdot g_m$　(k>1 highboost)　(k=1 Unsharp)

1st Filtering $|\nabla f|=|G_x|+|G_y|$　Sobel　垂直 梯度 $\begin{bmatrix}-1&-2&-1\\0&0&0\\1&2&1\end{bmatrix}$ $\begin{bmatrix}-1&0&1\\-2&0&2\\-1&0&1\end{bmatrix}$　Robert 交叉：$\begin{matrix}-1&0\\0&1\end{matrix}$　$\begin{matrix}0&-1\\1&0\end{matrix}$

1st 更宽的 edge，2st 对 fine 有强响应

空间增强混合法：对Image平滑(去噪后)与Laplacian增强后的相乘. 这样noise未被增强

## U5 Filter in Frequency

周期Noise本质是一种固定f的Noise

连续 $F(u,v)=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} f(t,z)\cdot e^{-j2\pi(ut+vz)}\cdot dt\,dz \;\|\; f(t,z)=\iint F(u,v)\cdot e^{j2\pi(ut+vz)}du\,dv$　带限要求 $f(t)\in(-\infty,+\infty)$

频率域间隔(分辨率) $\Delta u=\frac{1}{T}$.　频域跨越范围：$\frac{1}{\Delta T}$　. 频率分辨率←空域时间，范围←采样间隔

DFT：$F(u,v)=\sum_{x=0}^{M-1}\sum_{y=0}^{N-1} f(x,y)\cdot e^{-j2\pi(\frac{ux}{M}+\frac{vy}{N})}$

IDFT：$f(x,y)=\frac{1}{M\cdot N}\sum_{u=0}^{M}\sum_{v=0}^{N} F(u,v)\cdot e^{j2\pi(\frac{ux}{M}+\frac{vy}{N})}$

Y=fftshift(X) 将f=0移至中心，X→vector → 左右交换，X→matrix → Ⅰ.Ⅲ换，Ⅱ.Ⅳ换

相比幅度谱，相位谱对图像起支配性作用.　DFT执行前补足周期再变换，补0会有块效应　截断效应 ↳ 由于频谱泄漏(高斯窗)

频域Filter过程 ① $f(x,y)$：M×N，补0至P×Q（一般 P=2M，Q=2N）$f_p(x,y)$

② 用 $(-1)^{x+y}$ $f_p(x,y)$ 进行平移　$F[f(x,y)\cdot e^{j2\pi(\frac{u_0}{P}x+\frac{v_0}{Q}y)}]=F(u-u_0,v-v_0)$ 令 $u_0=\frac{P}{2}$ $v_0=\frac{Q}{2}$ 即可　DFT是可分离且对称的!

③ DFT得到 $F(u,v)$ ④ 生成一个实对称的，P×Q 中心在 $(\frac{P}{2},\frac{Q}{2})$ 的 $H(u,v)$.　$F(u,v)\cdot H(u,v)$

⑤ $g_p(x,y)=\{real[F^{-1}(H(u,v)\cdot F(u,v))]\}(-1)^{x+y}$　提取左上角 M×N 即可

低通与高斯低通：频域的高斯傅里叶变换也为高斯，因此没有振铃效应，用于医学.

Butterworth $H(u,v)=\frac{1}{1+[D(u,v)/D_0]^{2n}}$　Gaussian $H(u,v)=e^{-D^2(u,v)/2D_0^2}$　D=D₀时 0.607　Highpass = 1 − Lowpass　高斯无振铃

n阶巴特沃斯振铃现象少. 但n↑ 振铃↑　n=1 无振铃

Laplacian 在 frequency　$H(u,v)=-4\pi^2(u^2+v^2) \Leftarrow F[\frac{df(x)}{dx}]=(j2\pi u)F(u)$ → 连续FT

$F[\frac{d^2f(x)}{dx^2}]=(j2\pi u)^2F(u)=-4\pi^2u^2F(u)$

图像增强 $g(x,y)=F^{-1}[F(u,v)-H(u,v)\cdot F(u,v)]$
$=F^{-1}[(1+4\pi^2D^2(u,v))\cdot F(u,v)]$　图像增强是主观过程

高频强调滤波　$g_m=f(x,y)-f_{LP}(x,y)$　$g=f(x,y)+g_m$
$\Rightarrow g(x,y)=F^{-1}[[k_1+k_2H_{HP}(u,v)]\cdot F(u,v)]$　阴影.背景光表现为低频

同态滤波. $f(x,y)=i(x,y)\cdot r(x,y) \Rightarrow i(x,y)$ 光照分量. 表现低频；$r(x,y)$ 反射.高~
$\Rightarrow z(x,y)=\ln f(x,y)=\ln i(x,y)+\ln r(x,y) \Rightarrow Z(u,v)=F_i(u,v)+F_r(x,y)$

特点：进行对数.指数运算. 计算量大；对于加性噪声 不可用同态滤除.

选择性滤波：Bandreject 带阻 Bandpass 带通 ⇒ n阶高斯 带阻filter $H(u,v)=1-e^{-[\frac{D^2-D_0^2}{DW}]^2}$　↑ 不是低通与高通的简单组合

陷波Notch filter：消除以(u,v)为中心. D为半径
⇒ 为防止相移. 通常按频谱上关于原点对称的点

0相移filters：零相位、不偏移之真. 则必有 $h(x,y)$ 关于原点对称.
若 $h(x,y)$ 为实数 则有 $H^*(u,v)=H(-u,-v)$

ps. 滤波器零填充：振铃效应：空域矩形窗 $\xrightarrow{F}$ 频域Sinc　因此图像尺寸变了. 要构建相应尺寸Filter而非补0.

离散FT 时频转化例子　$T=\begin{bmatrix}-1&-1&-1\\-1&9&-1\\-1&-1&-1\end{bmatrix}$　(x−1, y−1)　(x−1, y+1)　(x+1, y+1)　x　y
$\Rightarrow h(x,y)=9\delta(x,y)-\delta(x-1,y-1)-\cdots$　左上角 −1
$\cdots-\delta(x+1,y+1) \Rightarrow g(x,y)=-1\cdot f(x-1,y-1)-f(x,y-1)\ \cdots\cdots$

$\delta(x-x_0,y-y_0)\xrightarrow{F} e^{-j2\pi(\frac{ux_0}{M}+\frac{vy_0}{N})}$

$\therefore H(u,v)=9-e^{-j2\pi\frac{v}{N}}-e^{-j2\pi\frac{u}{M}}-\cdots-e^{-j2\pi(\frac{u}{M}+\frac{v}{N})}\cdots$
$=10-(1+2\cos\frac{2\pi v}{N})(1+2\cos\frac{2\pi u}{M})$

空间核 → 频域mask　600×600　3×3　在600+3−1=602×602上 对3×3进行DFT得到mask

对于对称的filter，它的 correlation与convolution得到结果相同

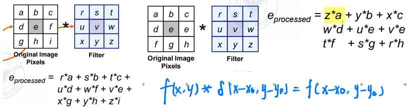

| a | b | c |
|---|---|---|
| d | e | f |
| g | h | i |

Original Image Pixels　*　Filter

| r | s | t |
|---|---|---|
| u | v | w |
| x | y | z |

$e_{processed}$ = r*a + s*b + t*c + u*d + w*f + v*e + x*g + y*h + z*i

| a | b | c |
|---|---|---|
| d | e | e |
| f | g | h |

Original Image Pixels　*　Filter

| r | s | t |
|---|---|---|
| u | v | w |
| x | y | z |

$e_{processed}$ = z*a + y*b + x*c + w*d + u*e + v*e + t*f + s*g + r*h

$f(x,y)*\delta(x-x_0,y-y_0)=f(x-x_0,y-y_0)$

## U6. Image Restoration

图像恢复是一个客观过程

复原利用退化的先验知识，面向退化model 设立最佳准则，产生最佳估计

退化model：$g(x,y)=h(x,y)*f(x,y)+\eta(x,y)\xrightarrow{F} G(u,v)=H(u,v)\cdot F(u,v)+N(u,v)$

LTI：线性时不变：$H[af_1+bf_2]=aH(f_1)+bH(f_2)$ 且 $H(f(x-a,y-b))=g(x-a,y-b)$

Noise的Model：① Gaussian：$p(z)=\frac{1}{\sqrt{2\pi}\cdot\sigma}e^{-(z-\bar z)^2/2\sigma^2}$

② Rayleigh：$p(z)=\begin{cases}\frac{2}{b}(z-a)e^{-(z-a)^2/b} & (z\ge a)\\0 & (z<a)\end{cases}$　③ 爱尔兰：$p(z)=\begin{cases}\frac{a^bz^{b-1}}{(b-1)!}e^{-az} & (z\ge0)\\0 & (z<0)\end{cases}$

④ 指数：$p(z)=\begin{cases}ae^{-az} & (z\ge0)\\0 & (z<0)\end{cases}$　⑤ 均匀 $p(z)=\begin{cases}\frac{1}{b-a} & (a\le z\le b)\\0\end{cases}$　⑥ 脉冲 $p(z)=\begin{cases}P_a & z=a\\P_b & z=b\\0 & \text{else}\end{cases}$

P为噪声密度 $P=P_s+P_p$ ← salt pepper

Noise估计：典型周期干扰参数可通过对频谱图分析估计；有时也可在noisy图上推断.

传感器噪声：有时noise的概率密度参数可根据sensor确定. 但与环境有关. 光照不同变化大

对于一般图像. 可以找一些flat区，统计其直方图. 从形状中确定

只存在噪声复原：Model $g(x,y)=f(x,y)+\eta(x,y)$ 可采用的空域滤波：

① Mean Filter：算术均值 $\hat f(x,y)=\frac{1}{mn}\sum_{(s,t)\in S_{xy}}g(s,t)$ 将会模糊原图 } 适用高斯与均匀

几何均值 $\hat f(x,y)=[\prod_{(s,t)\in S_{xy}}g(s,t)]^{\frac{1}{mn}}$ 损失更少细节

谐波均值：$\hat f(x,y)=\frac{mn}{\sum_{(s,t)\in S_{xy}}\frac{1}{g(s,t)}}$　善于处理盐(Salt)粒与高斯噪声　纯白(1)

逆谐波~：$\hat f(x,y)=\frac{\sum_{(s,t)}g(s,t)^{Q+1}}{\sum_{(s,t)}g(s,t)^{Q}}$　Q>0 胡椒(pepper)　纯黑(0)　(B) 蓝光打在黄 (R+G) 反射黑光

Q<0 盐噪.　Q=0 算术均值　Q=−1 谐波均值滤波

② 统计排序滤波(非线性)　中值filter：$\hat f(x,y)=\text{median}\{g(s,t)\}$ 应对 salt pepper

Max：$\hat f(x,y)=\max\{g(s,t)\}$ 利于去pepper　Min. $\hat f(x,y)=\min\{g(s,t)\}$ 利于Salt.

中点filter $\hat f(x,y)=\frac{1}{2}[\max\{g(s,t)\}+\min\{g(s,t)\}]$　利于Gaussian与Uniform均匀

修正α均值 $\hat f(x,y)=\frac{1}{mn-d}\sum g_r(s,t)$　去掉 d/2 个最高灰度和 d/2 个最低~

d=0 算术平均　d=mn−1 中值滤波　滤除脉冲同时平滑，对多噪混合有用.

③ 自适应滤波：$\hat f(x,y)=g(x,y)-\frac{\sigma_\eta^2}{\sigma_{S_{xy}}^2}[g(x,y)-\bar z_{S_{xy}}]$　其中 $\sigma_\eta^2$ 为Noise方差　$\sigma_\eta^2$ 为唯一参数

$\sigma_\eta^2=0$ 时 返回 $g(x,y)$ | $\sigma_\eta^2=\sigma_{S_{xy}}^2$ 时 等同于均值滤波 | 边缘 $\sigma_S^2\gg\sigma_\eta^2$ 返回 $g(x,y)$

自适应中值Filter：标准中值filter用中值代替. 会引起细节损失. 随着脉冲密度增大. 要更大窗口消除噪声. 该filter可以在保留图像细节同时平滑非Impulse Noise

① 中值介于Max, Min 则进 ② 否则增大窗口
① 当前值是否介于Max Min 是→输出 否→中值

④ 带阻Filter：去除Image中的特定frequency

最佳陷波Notch Filter：通过陷波带通获得Noise空域近似：$\eta(x,y)=F^{-1}[H_{NP}\cdot G(u,v)]$

⇒ 原图减去Noise加权 使得恢复图每pixel 邻域方差min：$\hat f(x)=g(x,y)-w(x,y)\cdot\eta(x,y)$

令 $\frac{\partial\sigma^2(x,y)}{\partial w(x,y)}=0$　方差min可认为恢复干净 得到 $w(x,y)=\frac{\overline{g(x,y)\cdot\eta(x,y)}-\bar g\cdot\bar\eta}{\overline{\eta^2}-[\bar\eta(x,y)]^2}$

## U7 Image Restoration and Reconstruction

前提：Noise与灰度值不相关

Image退化：$g(x,y)=h(x,y)*f(x,y)+\eta(x,y)\xrightarrow{F} G(u,v)=H(u,v)\cdot F(u,v)+N(u,v)$

观察：以高信噪比g为对图像处理. 用增强方法获得无噪f. 获得子图像的H

$H_s(u,v)=\frac{G_s(u,v)}{\hat F_s(u,v)}$　基于得到的系统函数更大比例重建有相同性质的H

试验：观察 Impulse Response，拍图作F变换再相除 $H(u,v)=G(u,v)/A$

建模：相机相对运动问题　$g(x,y)=\int_0^T f(x-x_0(t),y-y_0(t))\cdot dt$

两边傅里叶后：$G(u,v)=F(u,v)\cdot\int_0^T e^{-j2\pi(ux_0(t)+vy_0(t))}\cdot dt$

$\Rightarrow H(u,v)=\int_0^T e^{-j2\pi[ux_0(t)+vy_0(t)]}dt$

eg. 一个物体仅在x方向移动 $\Rightarrow\begin{cases}x_0(t)=\frac{at}{T}\\y_0(t)=0\end{cases}\Rightarrow H(u,v)=\int_0^T e^{-j2\pi ux_0(t)}dt=\frac{T}{\pi ua}\sin\pi ua\, e^{-j\pi ua}$

逆滤波及其病态性：$G=H\cdot F+H\Rightarrow\hat F(u,v)=\frac{G}{H}=F(u,v)+\frac{N(u,v)}{H(u,v)}$

在 $H(u,v)\to0$ 时后边的 $N/H\to\infty$ 图像淹没在Noise中. ⇒ 限制频率在低频

维纳Filter（最小均方误差）$e^2=E[(f-\hat f)^2]$

$\hat F(u,v)=[\frac{1}{H(u,v)}\frac{|H(u,v)|^2}{|H(u,v)|^2+S_\eta(u,v)/S_f(u,v)}]\cdot G(u,v)$　其中 $S_\eta=|N(u,v)|^2$　$S_f=|F(u,v)|^2$

由于 $S_f$ 一般未知. 这里将 $K=S_\eta/S_f$

约束最小平方恢复：$\min C=\sum_x\sum_y[\nabla^2f(x,y)]^2$ s.t. $\|g-H\hat f\|^2=\|\eta\|^2$　$\begin{bmatrix}0&-1&0\\-1&4&-1\\0&-1&0\end{bmatrix}$

$\hat F=[\frac{H^*(u,v)}{|H(u,v)|^2+\gamma|P(u,v)|^2}]\cdot G(u,v)$　其中 $P(u,v)$ 为 Laplacian 算子　↓ $P(u,v)$ 与 $H(u,v)$ 大小要相同

记残差 $r=g-H\hat f$　$\phi(\gamma)=\|r\|^2$　γ↑ 约束强 Image平滑导致残差↑ $\|r\|^2$↑

因此调整γ以至于 $\|r\|^2=\|\eta\|^2\pm a$　而 $\|\eta\|^2=MN\cdot(\sigma_\eta^2+m_\eta^2)$　只需要Noise的均值和方差即可.

几何均值滤波 $\hat F=[\frac{H^*}{|H|^2}]^\alpha[\frac{H^*}{|H|^2+\beta S_\eta/S_f}]^{1-\alpha}\cdot G(u,v)$

α=1 逆滤波　α=0 参数化维纳滤波 ⇒ β=0 逆滤波　β=1 标准维纳

$\alpha=\frac{1}{2}$ 逆滤波与参数维纳的几何平均，即几何均值 ⇒ β=1 功率谱均衡

图像的重建　180°就够用了

雷登变换Radon.　一条线 $x\cos\theta+y\sin\theta=\rho$

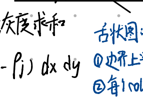

即沿着给定的某条直线，对在该直线上的图像像素灰度求和

$g(\rho_j;\theta_k)=\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}f(x,y)\cdot\delta(x\cos\theta_k+y\sin\theta_k-\rho_j)\,dx\,dy$

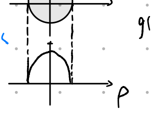

$f(x,y)=\begin{cases}A & x^2+y^2=r^2\\0\end{cases}$　θ=90° 代表 x=ρ

$g(\rho,\theta)=\iint f(x,y)\cdot\delta(x\cos\theta+y\sin\theta-\rho)\cdot dxdy$
$=\int f(\rho,y)dy=\begin{cases}2A\sqrt{r^2-\rho^2} & |\rho|\le r\\0\end{cases}$

舌状图：① 边界上完全饱和颜色 ② 每1 color 等能量为白色

傅里叶切片定理：给定θ下，就是傅~变换 $F(u,v)$ 在θ角的切片

1-D的F变换 $G(\omega,\theta)=\int g(\rho,\theta)\cdot e^{-j2\pi\omega\rho}\cdot d\rho=F(\omega\cos\theta,\omega\sin\theta)$

直接反投 会模糊　只需要在不同角度下测得的data作一维傅~变换 $F(u,v)$ 再代入θ即可.

滤波反投影 $f(x,y)=\int_0^\pi\int_{-\infty}^{+\infty}|\omega|\cdot G(\omega,\theta)e^{j2\pi\omega(x\cos\theta+y\sin\theta)}\cdot d\omega\cdot d\theta$

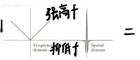

$=\int_0^\pi[\int_{-\infty}^{+\infty}|\omega|\cdot G(\omega,\theta)\cdot e^{j2\pi\omega\rho}\cdot d\omega]_{\rho=x\cos\theta+y\sin\theta}d\theta$　逆一维F变换

$F(-\omega,\theta)=F(\omega,\theta+\pi)=F(\omega,\theta-\pi)$　→ 高通滤波

整个过程：① 计算每个角度的1-D傅里叶变换 ② 用|ω|与窗函数乘每个傅里叶变换 (c=0.54 汉明　c=0.5 汉宁) ③ 求上述的反1-D F变换. ④ 对上述得到的所有1-D F反变换进行角度积分

CT：Fan-beam：实际中不采用平行线投影　扇束⇔平行束坐标.　① 射线量决定取样数 ② 角度量决定重建质量

Δα, Δβ 尽可能小

$\theta=\beta+\alpha$　$\rho=D\cdot\sin\alpha$　实现扇形投影 $p(\alpha,\beta)$ 与平行束 $g(\rho,\theta)$ 转换

## U8. Color Image Processing

整个颜色不能三种颜色表示 (RGB围成三角形不能cover了大部)

Color Fundamentals：人类看到的颜色是物体反射出来的光色. 如绿色物体主要反射500~570nm 而吸收其他波长的光

3种基本描述标准：辐射 Radiance (total amount of energy)　光强 Luminance (观察者看到的总能量). 亮度 Brightness 主观.

白—蓝 (三补色)

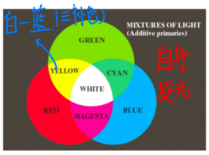

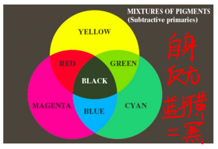

光源三基色：红R绿G蓝B. 颜料三基色：青C. 品红M. 黄：Y. RGB相加 ⇒ Y=R+G.　CMY相减：Y=R+G+B−B

CMY与RGB转换 $\begin{bmatrix}C\\M\\Y\end{bmatrix}=1-\begin{bmatrix}R\\G\\B\end{bmatrix}$

CMY与CMYK转换. K为引入的黑色 $K=\min(C,M,Y)$ base　$\therefore C'=\frac{C-K}{1-K}$　$M'=\frac{M-K}{1-K}$　$Y'=\frac{Y-K}{1-K}$

反之 CMYK→CMY　$C=C'(1-K)+K$　$M=M'(1-K)+K$　$Y=Y'(1-K)+K$

颜色的三种基本特性 HSI：① 亮度I：无色的强度概念
② 色调H(Hue)：光波混合中与主波长有关属性. 观察者感知颜色
③ 饱和度S(Saturation)：相对纯净度. 与一种颜色混合白光量有关.

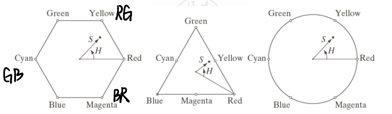

RGB与HSI转换：

$I=\frac{1}{3}(R+G+B)$　$S=1-\frac{3}{R+G+B}\cdot\min(R,G,B)$

$H=\begin{cases}\theta & \text{if } B\le G\\360-\theta & \text{if } B>G\end{cases}$　$\theta=\arccos\frac{\frac{1}{2}[(R-G)+(R-B)]}{[(R-G)^2+(R-G)(R-B)]^{\frac{1}{2}}}$

HSI与RGB转换.

① RG域：$B=I(1-S)$.　$G=3I-(R+B)$　$R=I[1+\frac{S\cos H}{\cos(60-H)}]$

② GB~ (H: 120°~240°)　$R=I(1-S)$　$B=3I-$~　$G=I[1+\frac{S\cos H}{\cos(60-H)}]$　令 H=H−120

③ BR~ (H: 240~360)　H=H−240　$G=I(1-S)$，$R=3I-$~　$B=I[1+$~$]$

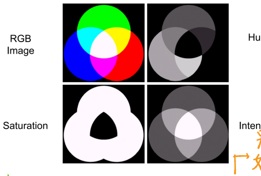

$R=0°$　$H=\frac{H}{360°}\times255$

$S=1-\frac{3}{R+G+B}\cdot0=1$

$I=\frac{1}{3}(R+G+B)$

另法：RGB采用正弦，变量相同 ↳ 如灰度，拼接三通道　相位偏差

伪彩色(Pseudocolor)　黑白图0~M个，分成N个区间，分配色彩

Color Transformation：$g(x,y)=T[f(x,y)]$　HSI：$s_3=kr_3$ ↓

← RGB：$s_i=k\cdot r_i$　CMY：$1-s_i=k(1-r_i)\Rightarrow s_i=kr_i+(1-k)$　仅强度

CMYK　$s_i=\begin{cases}r_i\ (CMY)\\kr_i+1-k\ (K)\end{cases}$

补色：彩色环上与色调相对的一端. 增强图像暗部细节

颜色分层：把感兴趣颜色保持，之外的变为无确定性质(灰色)　→ 球体 / 立方体

HSI直方图增强：单独对R.G.B直方图化不正确. 需对I做增强

彩图的平滑：可以单独在每个平面上执行. 与使用彩色向量平均相同.

← RGB平滑得到平均颜色. HSI平滑颜色不变. Filter↑ 两平滑差异↑

彩图的锐化 $\nabla^2c(x,y)=\begin{bmatrix}\nabla^2R\\\nabla^2G\\\nabla^2B\end{bmatrix}$ 向量的Laplacian分量=各个标量 → HSI 只对I锐化

RGB的分割. 欧式：$D(z,a)=\|z-a\|=[(z_R-a_R)^2+(z_G-a_G)^2+\cdots]^{\frac{1}{2}}$

椭球(马氏距离) $D(z,a)=[(z-a)^TC^{-1}(z-a)]^{\frac{1}{2}}$　绝对值：立方体.

R.G.B分别梯度再合并是错误的!

← 彩色边缘检测 $u=\frac{\partial R}{\partial x}r+\frac{\partial G}{\partial x}g+\frac{\partial B}{\partial x}b$　$v=\frac{\partial R}{\partial y}r+\frac{\partial G}{\partial y}g+\frac{\partial B}{\partial y}b$

$g_{xx}=u^T\cdot u=|\frac{\partial R}{\partial x}|^2+|\frac{\partial G}{\partial x}|^2+|\frac{\partial B}{\partial x}|^2$　$g_{yy}=v^T\cdot v=|\frac{\partial R}{\partial y}|^2+|\frac{\partial G}{\partial y}|^2+|\frac{\partial B}{\partial y}|^2$

$g_{xy}=u^T\cdot v=\frac{\partial R}{\partial x}\cdot\frac{\partial R}{\partial y}+\frac{\partial G}{\partial x}\cdot\frac{\partial G}{\partial y}+\frac{\partial B}{\partial x}\cdot\frac{\partial B}{\partial y}$

$\theta(x,y)=\frac{1}{2}\tan^{-1}\left[\frac{2g_{xy}}{g_{xx}-g_{yy}}\right]$ 矢量梯度方向（最大变化率）

在此方向上变化率的值. $F_\theta(x,y)=\left\{\frac{1}{2}\left[(g_{xx}+g_{yy})+(g_{xx}-g_{yy})\cos 2\theta+2g_{xy}\sin 2\theta\right]\right\}^{\frac{1}{2}}$

**彩图中Noise**：与单色图像相比 同级别的Noise在彩图中不太引人注意，

**带噪的HSI分量**：Noise对H、S影响最大，对I轻. 由于求余弦和最小值非线性造成. $I=\frac{1}{3}(R+G+B)$ 平均 因此Noise影响小. 单通道Noise 转HSI会扩散

**彩图的压缩**. 原始彩图比特数比灰图大3~4倍. 用减小或消除冗余/不相干data

$\sigma_1:\sigma_2=1.75:1$

LOG：$\sigma=\frac{\sigma_1^2\sigma_2^2}{\sigma_1^2-\sigma_2^2}\ln\frac{\sigma_1^2}{\sigma_2^2}$

## U9. Morphological Image Processing U10

理论：二值图像 $Z^2$. 反转：$\hat{B}=\{w|w=-b\}$ 全部180°(包括原点) 平移 $(B)_z=\{c|c=b+z\}$

**结构元(SE)**：原点用黑点表示，若SE对称则默认原点在中心对称处. 通常SE是矩形阵列，因此要添加背景，但背景不属于SE.

**三种关系**：Hit（有一个pixel盖住就对），Fit（所有pixel盖住Image），Miss

**腐蚀(erosion)** $A\ominus B=\{z|(B)_z\subseteq A\}=\{z|(B)_z\cap A^c=\phi\}$

作用：分开合在一起的2个objects 或使边界更光滑（毛刺少）

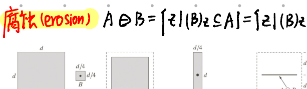
d
d/4
A
B
A ⊖ B
d/8
3d/4
d/2

**膨胀(dilation)** $A\oplus B=\{z|(\hat{B})_z\cap A=\phi\}$

作用：修复断裂和残缺裂口

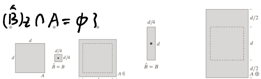
d
d/4
A
B̂ = B
A ⊕ B
d/8
d/2

**对偶性**：$(A\ominus B)^c=A^c\oplus\hat{B}$ $(A\oplus B)^c=A^c\ominus\hat{B}$ 对目标D⇔对背景E

腐蚀⇔明可夫斯基交集 $\cap A_{-b}$ 膨胀⇔明~并集 $\cup A_b$

**开Opening** $A\circ B=(A\ominus B)\oplus B=\cup\{(B)_z|(B)_z\subseteq A\}$ 相当于用SE填内部

**闭Closing** $A\cdot B=(A\oplus B)\ominus B$ 相当于用SE在A外滚一圈. 填补空隙.

开运算可以将比结构元小的点剔除掉，起分离；闭运算可以把比结构元小的缺口或洞填上. 搭接间隙起连通作用. **对偶性**：$(A\cdot B)^c=A^c\circ\hat{B}$ $(A\circ B)^c=A^c\cdot\hat{B}$

**开闭的特性**：$A\circ B$是A子集，A是$A\cdot B$子集；$C\subseteq D$则$C\circ B\subseteq D\circ B$. $(A\circ B)\circ B=A\circ B$

$(\cup A_i)\circ B\geq\cup(A_i\circ B)$ 同样闭也是 $(\cap A_i)\circ B\subseteq\cap(A_i\circ B)$ 闭也是

**击中击不中变换**. 除×外. 前景与背景都匹配则击中 $A\circledast B=(A\ominus B_1)\cap(A^c\ominus B_2)$

将(a)拆为$B_1$, $B_2$

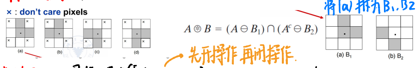
× : don't care pixels
(a)
(b)
(c)
(d)
A ⊛ B = (A ⊖ B₁) ∩ (Aᶜ ⊖ B₂)
(a) B₁
(b) B₂

先开操作再闭操作

**噪声滤除**：去图像噪声 $\{[(A\ominus B)\oplus B]\oplus B\}\ominus B\Rightarrow(A\circ B)\cdot B$ 个点.

**边界提取**：$\beta(A)=A-(A\ominus B)$ 孔洞填充：$X_k=(X_{k-1}\oplus B)\cap A^c$ 起始$X_0$边界内部

**连通分量提取** $X_k=(X_{k-1}\oplus B)\cap A$ 起始$X_0$为前景的一个点 不超过初始水平垂直限度

**凸壳Convex**. 若A内任意两个点的直线都在A内 则称A凸 $X_k^i=(X_{k-1}\circledast B^i)\cup A$ i-第i个$B^i$)

**细化**：逐渐去掉集合上边界元素. $A\otimes B=A-(A\circledast B)=A\cap(A\circledast B)^c$ 对边界各个方向进行. 因此用一组SE $\{B^1\cdots B^n\}$ $B^i$是$B^{i-1}$旋转后结果 粗化与细化是对偶的. 但以互换

$A\odot B=A\cup(A\circledast B)$ 实际操作，先对背景进行细化. 再对结果求补集

**骨架中轴**：区域边界内切圆圆心集合 火烧草地 边界同时点火火线相遇

得到骨架子集 $S_k(A)=(A\ominus kB)-(A\ominus kB)\circ B$ 最后合并 $S(A)=\cup S_k(A)$

**形态学重建**：2个图像：1个标记F，一个为模板G + 1个SE 记作 $R_G^D(F)=D_G^{(k)}(F)$

**测地膨胀**：$D_G^{(1)}(F)=(F\oplus B)\cap G$. $D_G^{(0)}(F)=F$ 且 $D_G^{(n)}(F)=D_G^{(1)}[D_G^{(n-1)}(F)]$

**测地腐蚀**：$E_G^{(1)}(F)=(F\ominus B)\cup G$ $E_G^{(0)}(F)=F$ 且 $E_G^{(n)}(F)=E_G^{(1)}[E_G^{(n-1)}(F)]$ 51 ▯ 51×1

**重建开操作** $O_R^{(n)}(F)=R_F^D(F\ominus nB)$ 恢复腐蚀后所保留物体的形状 pohgh→p g

**自动填充空洞**. $F(x,y)=\begin{cases}1-I(x,y) & 若(x,y)在边界\\ 0\end{cases}$ $\Rightarrow H=[R_{I^c}^D(F)]^c$ 二值化图上进行

**边界清除**：删除接触边界的物体. 处理只保留完整的物件

$F(x,y)=\begin{cases}I(x,y) & 若(x,y)在边界\\ 0\end{cases}$

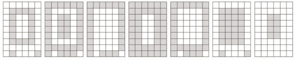
I
Iᶜ
F
F⊕B
F⊕B∩Iᶜ
H
H∩Iᶜ

**灰度图像形态学操作**. flat SE ⊓ ⇒ disk ⇒ $f\ominus b_N=\min\{f(x+s,y+t)\}$ $f\oplus b_N=\max\sim$

Nonflat SE ⊓ ⇒ $f\ominus b_N=\min\{f(x+s,y+t)-b_N\}$ $f\oplus b_N=\max\{f(x-s,y-t)+b_N\}$

**灰度膨胀**：SE值均为正则结果趋向更亮. 根据SE值形状，发暗细节消失或减少

D.R仍有对称 $(f\ominus b)^c=f^c\oplus\hat{b}$ 其 $f^c=-f(x,y)$，$\hat{b}=b(-x,-y)$ $(f\oplus b)^c=f^c\ominus\hat{b}$

**开闭操作**：开：$f\circ b=[f\ominus b]\oplus b$. 开⇒去除小的发亮细节 闭⇒去除小的暗细节

削峰（前提：宽度<SE） 补谷

**形态学梯度** $g=(f\oplus b)-(f\ominus b)$ 原图-削峰后 ⇒ 校正阴影

**灰帽变换**：Top-hat $T_{hat}(f)=f-(f\circ b)$ Bottom-hat $B_{hat}(f)=f\cdot b-f$

**粒度检测**：对比背景亮且有规则的颗粒，由逐渐增大的SE对图像开操作. 某个尺寸的SE会对有类似尺寸的Image产生最大效果. 每次开后像素和随SE↑而↓

**纹理分割**：

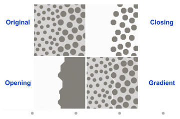
Original
Closing
Opening
Gradient

计算机处理的是灰度为1的. 所以这里closing是对白色背景进行闭操作 大小斑点大. 可以从闭含义上理解：先用小SE处理去掉小圆 再用较大(大于缝隙)的SE填满白色背景(Open)

## U13 U14. Image Segmention

主要2类：基于Edge，基于Region

1st 产生粗边缘 2st对精细细节有强响应. 2st在灰度斜坡和台阶过渡处会产生双边缘响应；2st的符号"+"从暗到亮 "-"从亮到暗. 2st零交叉点可定位粗edge中心

**点检测**：用1st(Laplacian) 孤立点灰度不同于周围. 优点 各相同性(旋转不变)；缺点是 边缘元方向信息丢失，2st双倍加强噪声 因此导数前需进行平滑处理

Edge Model

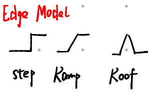
step
Ramp
Roof

**线检测**：

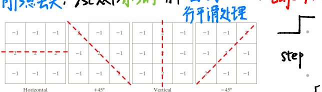
-1 -1 -1
2 2 2
-1 -1 -1
2 -1 -1
-1 2 -1
-1 -1 2
-1 2 -1
-1 2 -1
-1 2 -1
-1 -1 2
-1 2 -1
2 -1 -1
Horizontal
+45°
Vertical
-45°

**边缘检测**. $M(x,y)=mag(\nabla f)=\sqrt{g_x^2+g_y^2}\approx|g_x|+|g_y|$ $\nabla f=\begin{bmatrix}g_x\\g_y\end{bmatrix}=\begin{bmatrix}\frac{\partial f}{\partial x}\\ \frac{\partial f}{\partial y}\end{bmatrix}$

Prewitt实现较简单 Sobel对噪声抑制能力强 效果更好一点

$\downarrow\begin{bmatrix}-1&-1&-1\\0&0&0\\1&1&1\end{bmatrix}$ $\begin{bmatrix}-1&-2&-1\\0&0&0\\1&2&1\end{bmatrix}\downarrow$ $\begin{bmatrix}0&1&2\\-1&0&1\\-2&-1&0\end{bmatrix}\nearrow$

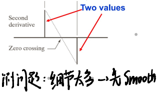
Second derivative
Zero crossing
Two values

边缘检测问题：细节太多→先Smooth

**Marr-Hildreth (LoG)**：先用高斯滤波再用Laplacian 或直接用LOG算子

$g(x,y)=[\nabla^2G(x,y)]\star f(x,y)=\nabla^2[G(x,y)\star f(x,y)]$ $\nabla^2G(x,y)$ 称为LOG算子

边缘所在

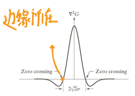

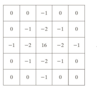

| | | | | |
|---|---|---|---|---|
| 0 | 0 | -1 | 0 | 0 |
| 0 | -1 | -2 | -1 | 0 |
| -1 | -2 | 16 | -2 | -1 |
| 0 | -1 | -2 | -1 | 0 |
| 0 | 0 | -1 | 0 | 0 |

找0交叉. 将LOG分为行列操作提高速度

特点：强Noise抑制力. 边缘为1像素且连成闭合曲线. 还可得到目标区域二值图. 计算量太大

近似LOG（**DoG** Difference of gaussian） $DoG=\frac{1}{2\pi\sigma_1^2}e^{-\frac{x^2+y^2}{2\sigma_1^2}}-\frac{1}{2\pi\sigma_2^2}e^{-\frac{x^2+y^2}{2\sigma_2^2}}$

**坎尼Canny边缘检测**. 边缘点条件：该点边缘强度大于两个相邻像素点的边缘强度 与该点梯度方向(近似)相邻两点方向差小于45°；以该点为中心的3×3边缘强度max>阈值

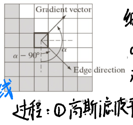
Gradient vector
Edge direction
α − 90°
α

(a,b) 点→线 幅：$\sqrt{a^2+b^2}$ 相位 arcsin $a/\sqrt{a^2+b^2}$

细化Edge：非极大值抑制. 找$d_k$(近似α实际梯度)，在$d_k$上比相邻两值小则抑制掉

$d_k$作用：离散化 由于□只有水平垂直，±45°(8个方向)找近似以决定$d_k$ 用8连通

双阈值处理：$>T_H\Rightarrow$强边缘 $>T_L\Rightarrow$弱边缘 $<T_L\Rightarrow$非边缘 用于连接边缘

过程：①高斯滤波平滑 ②算Image梯度的幅度与角度 ③用非极大值抑制.细化edge ④双阈连接

**边缘的局部连接**：相邻且有一定相似性. 无论在幅度还是角度上 ②迭代选择，逐步加入

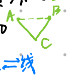

③**霍夫变换Hough** 将直线用(ρ,θ)表示. $x\cos\theta+y\sin\theta=\rho$ 一般直线 $Ax+By+C=0$

$x\cos\theta+y\sin\theta-\rho=0$ 对比得 $\frac{A}{\sqrt{A^2+B^2}}x+\frac{B}{\sqrt{A^2+B^2}}y+\frac{C}{\sqrt{A^2+B^2}}=0$ 对应代入即可 极点⇌线

过一个点可以有无数条直线(ρ,θ). 若几个点共线 则它们的(ρ,θ)必交于一点，这个点(ρ,θ)反变换

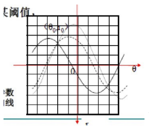

θ取值[-90°,90°] ①N×N的Image 则ρ取值$[-\sqrt{2}N,\sqrt{2}N]$ ②将θ取值量化为0°, ±15°, ±30°, ±45°, ±60°, ±75°, ±90° 共12值 ③将ρ取值量化为50 则得到12×50 统计每个单元格曲线出现频度. 若超过某个阈值T. 则认为有(ρ,θ)的直线. 检验选中单元pixel关系(连续)

Hough缺点：曲线参数空间量化精度不易确定. ρ,θ过粗则不可定位；ρ,θ过细. 计算量且落入单元格中的点数过于分散. 不能有效检测 干扰因素：噪声、光照、对比度、比例

**阈值：全局T** $g(x,y)=\begin{cases}1&f>T\\0&f<T\end{cases}$ 此方法对T判断有较严要求. Basic Global：①初始化一个T ②用T将Image分为两部分$G_1$, $G_2$ ③算出$G_1$均值$\mu_1$，$G_2$均值$\mu_2$ ④ $T=\frac{1}{2}(\mu_1+\mu_2)$ ⑤迭代至收敛.

**Ostu方法(大津算法)** 类内方差最小，类间方差最大 $\max\eta(k)=\frac{\sigma_B^2(k)}{\sigma_G^2}$. $\sigma_B^2(k)=\frac{[m_GP_1-m(k)]^2}{P_1(k)\cdot(1-P_1(k))}$

可以使用Smooth（相当于去噪）后改进全局T处理. $\sigma_B^2(k)=\sum P_k(m_k-m_G)^2$

**使用Edge改进全T算法**：对仅位于或接近边缘的像素(如一整个黑背景中只有一个小白点)得到的直方图只有一个峰(白点峰太小了). 可用edge生成一个Mask后，对用Mask只考虑边缘附近的像素分布. 再用Ostu方法效果更好 或者也可用Laplacian 加深峰间波谷的趋向. 像素在Edge区在物体和背景上的p近似相等(改善)对称性. 重建不仅变特征增强(以自由度)

**Multiple T**：相比上述全局T. 多引入了更多的T Ostu保持使σ类内min σ类间max.

**可变T处理**：**阴影校正**：先采集没有目标的背景图. 与有目标图相减. 消除光照不均的

根据图片特性决定 $T=a\sigma_{xy}+bm_{xy}$ 分块后处理⇒局部性质决定T⇒移动平均

**局部T法**：(无法消背影) 若某个Image中有目标、背景则直方图双峰. 若图像块中只有目标或背景时. 则不呈双峰，难以用T划分. 但可根据邻近双峰块的局部T. 内插一个T作分割

**基于区域分割 Region growing**：①找到S的所有连通分量，找一个种子作为像素生长的起点 ②判定条件Q(相似性). 将种子8连通区域判定Q，若Q成立则加入 ③作为新种子生长.

**区域分裂与聚合 Spliting and Merging**：将I分为不相交区域. 再聚合像素满足分割条件. ①按4象限为4个区域. 4叉树表示. 检查相似性Q ②不一致则进一步分裂 ③一致则合并

**形态学分水岭**：用于Image的梯度图，而非I本身. 汇水区域最小值为感兴趣较小梯度.

⇒局限：Noise或梯度局部不规则性造成过度分割. 存在大量潜在min. Smooth Marker

**标记**：与感兴趣物相联系的Marker为内部标记. 与背景相连M为外部标记.

⇒选择标记的典型过程：预处理(Smooth)，定义Marker以须满足的准则合集.

**累积差值图像ADI**. 将参考图像R与后续序列比较. 某个像素上出现差异则+1

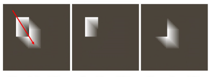
Absolute ADI
Positive ADI
Negative ADI

绝对ADI：有差异则+1 正ADI：R-f>T +1 负ADI R-f<T +1

正ADI 对应物体位置. 完全离开参考物体时不再发生变化

方向和速度 由绝对ADI和负ADI的值决定

K是预先分类K类

**K-Means算法**：①初始化 $m_i(1)$ i=1,…,k ②将sample分至最近的$m_i$中 ③更新$m_i$为质心

**Superpixels**：将像素划分为比单个pixel更有感知意义的Superpixels 优化分割减少计算

**Graph Cuts** 将图视为拓扑结构. 计算关联性(关联越强) 沿最弱的将子切分开来 ⇒NP-Hard

考虑(x,y) 不会将远距离放一块

## U15. U16 Feature Extraction

**边界追踪(Moore追踪)**. ①起始点$b_0$为左上角"1"的点. $c_0$为$b_0$左侧(背景点)

②以$b_0$的8邻域. $c_0$顺时针考察. $b_1$为第一个遇到"1"的点，$c_1$为$b_1$前一个值 ③直到$b_0$.$b_1$ 回$b_0$ 且下步$b_1$

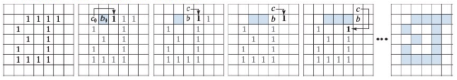

注意：Moore可能会出错. 由于原图有分支存在. $c_0$旋转后先找回到$b_0$而提前结束 debug:

**边界链码：Chain Code** 4方向

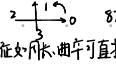

8方向

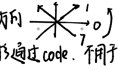

可由边界跟踪得到. 关于形状的特征如周长、曲率可直接通过code. 不用于目标识别

特点：code长对Noise干扰大. 目标平移code不变. 每个方向+4/+8 相当于目标旋转.

8 direct：+奇数 相当于45°倍数旋转 +偶数. 旋转90°倍数 (D-1)+4 这是循环的

起点不同 同一目标有不同code. 差分1st链码 |f(x)-f(x-1)| 2/0/03322 → 33133030 差分后才有旋转不变性

**MPP**. 内墙的凸与外墙的凹作为MPP顶点. 凹点沿±45°方向平移与凸点共线

**标记图(Signature)** 二维边界⇒一维函数

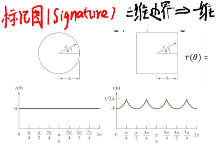

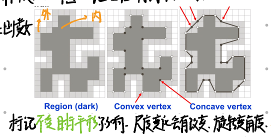
外
内
Region (dark)
Convex vertex
Concave vertex

标记依赖于平移影响. 尺度变化会改变. 旋转改角度.

边界线段：将边界分为数段，凸包 非凸边界借凸包

**细化**：把区域截面宽度缩min，即单pixel，直到出现最小的像素连通性(文字识别)

**骨架化(MAT) 中轴变化** 在边界上找到多于一个同样距离最近点，则P为中轴/骨架

**距离变换导致得到骨架**：找每个像素与标记为1的像素的最小距离. 将是局部最大值的集合. 相比细化 距离变化往往容易产生连续的骨架

**边界特征描述**：**边界长度** 两种区分：①直接乘1.1107 ②表示斜边与√2 (奇数)

**边界直径**(主轴或长轴) $Diam(B)=\max D(p_i,p_j)$ 相隔最远两点间距离

**曲率**：$K=\frac{d\alpha}{ds}=y''/(1+y'^2)^{\frac{3}{2}}$ 曲率与半径互为倒数 >0外凸向左弯

**形状数**：组成最小整数的差分链码 eg. 33133030 → 03033133 循环移位

**形状数的阶n**：形状数序列的长度. 4direct 闭合曲线n总为偶数 n=8

**傅里叶描述子**：边界N个点. 按逆时针 $(x_k,y_k)$ $s_k=x_k+jy_k\xrightarrow{F}S(u)$ 傅~描述

⇒只利用傅~描述的前P个值. 舍去边界上的高频成分 $\sum_{u=0}^{P-1}P(u)\cdot e^{j2\pi uk/N}$

**统计量描述**：r-阶矩 $m=\sum r_if(r_i)$ n阶矩 $\mu_n=\sum(r_i-m)^nf(r_i)$ 方差$\mu_2$

⇒进行了边界的旋转 有旋转不变性，用r和f(r)缩放达尺度归一化

**区域描述**：表示可以用数组或四叉树 区域面积 $A=\sum 1$ 重心 $\bar{x}=\frac{1}{A}\sum x$

形状因子(旋转+尺度不变)(圆形度) $F=\frac{P^2}{4\pi A}$ (P=周长 A=面积)

圆形区域 F最小F=1 边界能量. A相同时，圆有最小的平均边界 $E=\frac{1}{R^2}$

拟合椭圆. 球状性 圆形性. 紧致度compact$=\frac{P^2}{A}$ 偏心率$=\sqrt{1-(\frac{b}{a})^2}$

**拓扑描述**. 连通数C. 孔数H. 欧拉数 $E=C-H$ A(C=1 H=1)

⇒欧拉公式 顶点V 边数Q. 面数F 则 $E=C-H=V-Q+F$

**纹理特征**：灰度统计量. **灰度共生矩阵**：对于两个像素间位置关系的统计

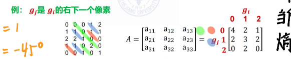

共生矩阵A的每个元素$a_{ij}$是具有灰度$g_i$和$g_j$的像素对在图像上出现的数目.

例：$g_j$是$g_i$的右下一个像素

0 0 0 1 2
1 1 0 1 1
2 2 1 0 0
1 1 0 2 0
0 0 1 0 1
A = [a11 a12 a13; a21 a22 a23; a31 a32 a33] = gj 0 1 2 [4 2 1; 2 3 2; 0 2 0]
gi 0 1 2

d=1 θ=-45°

⇒ 最大概率 $W_p=\max$ 一致性 $W_u=\sum\sum p^2$ 当所有$P(g_1,g_2)$相等时 $W_u$min 纹理丰富

熵：惯性(2阶矩) $W_I=\sum\sum(g_1-g_2)^2\cdot p$

**频谱方法**：图像上周期性，方向性的纹理在频谱上有相应表现

不变矩(p+q阶矩) $m_{pq}=\sum_x\sum_y x^py^qf(x,y)$ p+q阶中心矩 $\mu_{pq}=\sum_x\sum_y(x-\bar{x})^p(y-\bar{y})^qf$

$\bar{x}=\frac{m_{10}}{m_{00}}=\frac{\sum x\cdot f(x,y)}{\sum f(x,y)}$ 同理$\bar{y}$，$(\bar{x},\bar{y})$重心 归一化中心矩 $\eta_{pq}=\frac{\mu_{pq}}{\mu_{00}^{\gamma}}$ $\gamma=\frac{p+q}{2}+1$

**PCA. 霍特林Hoteling变换**. 用 $C_x=E\{(x-m_x)(x-m_x)^T\}$ 的特征矩阵A 各特征之间正交

即 $C_xe_i=\lambda_ie_i$ $A=\begin{bmatrix}e_1^T\\ \vdots\\ e_n^T\end{bmatrix}$ 且 $A^T=A^{-1}=[e_1\cdots e_n]$ ⇒ $y=A(x-m_x)$

其中 $m_y=0$ $C_y=A\cdot C_x\cdot A^T=\begin{bmatrix}\lambda_1&&\\&\ddots&\\&&\lambda_n\end{bmatrix}$ 逆变换 $x=A^Ty+m_x$ 满足 $\lambda_1>\lambda_2>\cdots\lambda_n$

自相关 $R_x=E\{x\cdot x^T\}$ $C_x=R_x-m_xm_x^T$ 用M个样本估计 $m_x=\frac{1}{M}\sum x_k$ $C_x=\frac{1}{M}\sum x_kx_k^T-m_xm_x^T$

只取$C_x$前K个(最大K个)对应的e构建$A_K$ ∴ $\hat{x}=A_K^Ty+m_x$ 均方误差 $\sum_{k+1}^{n}\lambda_i$

**Harris-Stephens Corner 检测**：3种 flat, edge, corner 2个patch区别 $C_{xy}$⇒

$[x,y]\cdot M\cdot\begin{bmatrix}x\\y\end{bmatrix}$ 其中Hamx $M=\sum_s\sum_t w(s,t)\cdot\begin{bmatrix}f_x^2&f_xf_y\\f_xf_y&f_y^2\end{bmatrix}$ ⇒ 2个特征值$\lambda_1$, $\lambda_2$ 权重 抗噪

⇒ $\lambda_{1,2}$小 flat 有1个大 edge 2个大 corner ⇒ $R=\lambda_x\lambda_y-k(\lambda_x+\lambda_y)^2=\det-\lambda\,trace^2$

⇒ R>T corner R<-T edge |R|<|T| flat 对缩放变化有较高敏感性 ⇒ 旋转不变 尺度不变

**MSERs 最大稳定极值区域** σ, kσ, k²σ σ不断变化 (窗口大小一定时)

**SIFT 尺度不变特征变换**：$L(x,y,\sigma)=G(x,y,\sigma)\star f(x,y)$

过程：①构建尺度空间：不同模糊度的金字塔 ②初始关键点. 通过DoG找粗略特征点 ③改进位置：Taylor位置改到亚像素级别 ④删点：去掉受Noise点与边缘上点 ⑤计算关键点方向与描述子

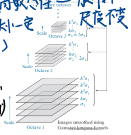
More octaves
Scale
Octave 3
Octave 2
Octave 1
Images smoothed using Gaussian lowpass kernels

## U11 U12 Image Patter Classification

**模式**：对客体的定量或结构描述. 用特征进行描述如颜色 尺寸. 形状结构

**特征矢量**：一组特征可以用一组测量数据表征 把待识别模式划分给模式类中

**模式类**：有共同特征的模式的集合. **模式识别**：根据特征.属性.

结构模式(树) 表示多层次排列的表达 可以是语义层的大小分层.

**基于匹配的识别**：if $d_i(x)>d_j(x)$ 则 $x\in\omega_j$ 决策边界 $d_{ij}(x)=d_i(x)-d_j(x)=0$

⇒**最小距离分类**：每类原型 $m_j=\frac{1}{n_j}\sum_{x\in\omega_j}x_j$ $D_j(x)=\|x-m_j\|$ $d_j(x)=x^Tm_j-\frac{1}{2}m_j^Tm_j$

⇒**通过相关性分类**：$c(x,y)=\sum_s\sum_t w(s,t)f(x+s,y+t)$ ⇒结构分类 eg.形状数

相关匹配目标检测问题：计算大；很难有旋转与尺度不变. 对变化敏感

**最近邻分类**：优点：简单，可以N个可分类别 缺点：样本大，近邻受Noise干扰

改进方法：集群方法：分几个集，用其平均样本作分类 K-近邻：K样本参数点.

**非线性可分**：多项式(二次判别是超二次曲面)；特殊函数展开；广义线性；高维

**最佳Bayes统计分类**：把x分为ω类. 每个样本计算分为不同类损失. 最低的损失赋值给相应的类. 则决策的总体的平均损失min $p(\omega_j|x)=\frac{p(x|\omega_j)\cdot p(\omega_j)}{p(x)}$

平均损失 $r_j(x)=\sum_{k=1}^{W}L_{kj}p(\omega_k|x)\overset{贝叶斯}{=}\frac{1}{p(x)}\cdot\sum L_{kj}p(x|\omega_k)\cdot p(\omega_k)$

引入0-1损失 正确为0. 错为1 $=p(x)-p(x|\omega_j)p(\omega_j)$ $d_j(x)=p(x|\omega_j)\cdot p(\omega_j)$

若有2个类且0-1损失 ①等先验 边界为 $p(x_0|\omega_1)=p(x_0|\omega_2)$时 $x_0$ ②不~~：边界 $\omega_1$概率大则$x_0$偏向$\omega_1$，同理另一边.

坐标×1/2 求m

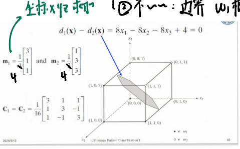
d₁(x) − d₂(x) = 8x₁ − 8x₂ − 8x₃ + 4 = 0
m₁ = 1/4 [3 1 1]ᵀ and m₂ = 1/4 [1 3 3]ᵀ
C₁ = C₂ = 1/16 [3 1 1; 1 3 −1; 1 −1 3]
(0,0,1)
(0,1,1)
(1,0,1)
(1,1,1)
(0,0,0)
(0,1,0)
(1,0,0)
(1,1,0)
x₁
x₂
x₃
∈ ω₁
∈ ω₂
L11 Image Pattern Classification 1

$C_1=C_2$时 必线性：$d_1(x)-d_2(x)=w^Tx+w_0=0$

$w=C^{-1}(m_1-m_2)$ w为一个矢量.

$w_0=-\frac{1}{2}(m_1+m_2)^T\cdot w$

Bayes→最小距离分类：①所有模式为高斯分布 ②所有协方差矩阵为单位阵 ③所有类出现的概率相同 $d_j(x)=\ln P(\omega_j)+x^TC^{-1}m_j-\frac{1}{2}m_j^TC^{-1}m_j$

**神经网络(NN)** 线性决策 $d(x)=\sum w_ix_i+w_{n+1}$

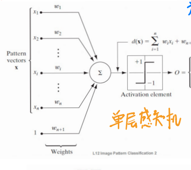
Pattern vectors x
x₁
x₂
xᵢ
xₙ
1
w₁
w₂
wᵢ
wₙ
wₙ₊₁
Weights
Σ
d(x) = Σ wᵢxᵢ + wₙ₊₁
+1
−1
Activation element
O = +1 if d(x) > 0; −1 if d(x) < 0
L12 Image Pattern Classification 2

单层感知机

为处理XOR 引入非线性

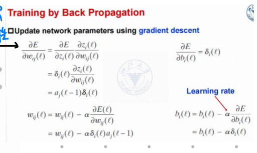

**Training by Back Propagation**

☐Update network parameters using gradient descent

$$\frac{\partial E}{\partial w_{ij}(\ell)}=\frac{\partial E}{\partial z_i(\ell)}\frac{\partial z_i(\ell)}{\partial w_{ij}(\ell)}=\delta_i(\ell)\frac{\partial z_i(\ell)}{\partial w_{ij}(\ell)}=a_j(\ell-1)\delta_i(\ell)$$

$$\frac{\partial E}{\partial b_i(\ell)}=\delta_i(\ell)$$

$$w_{ij}(\ell)=w_{ij}(\ell)-\alpha\frac{\partial E(\ell)}{\partial w_{ij}(\ell)}=w_{ij}(\ell)-\alpha\delta_i(\ell)a_j(\ell-1)$$

Learning rate

$$b_i(\ell)=b_i(\ell)-\alpha\frac{\partial E}{\partial b_i(\ell)}=b_i(\ell)-\alpha\delta_i(\ell)$$

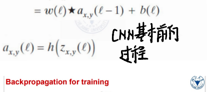

$$z_{x,y}(\ell)=\sum_l\sum_k w_{l,k}(\ell)a_{x-l,y-k}(\ell-1)+b(\ell)=w(\ell)\star a_{x,y}(\ell-1)+b(\ell)$$

$$a_{x,y}(\ell)=h(z_{x,y}(\ell))$$

CNN基本前向过程

pool：降计算 平移不变性，防过拟合 扩大感受野

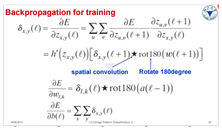

**Backpropagation for training**

$$\delta_{x,y}(\ell)=\frac{\partial E}{\partial z_{x,y}(\ell)}=\sum_u\sum_v\frac{\partial E}{\partial z_{u,v}(\ell+1)}\frac{\partial z_{u,v}(\ell+1)}{\partial z_{x,y}(\ell)}=h'(z_{x,y}(\ell))[\delta_{x,y}(\ell+1)\star\text{rot}180(w(\ell+1))]$$

spatial convolution

Rotate 180degree

$$\frac{\partial E}{\partial w_{l,k}}=\delta_{l,k}(\ell)\star\text{rot}180(a(\ell-1))$$

$$\frac{\partial E}{\partial b(\ell)}=\sum_x\sum_y\delta_{x,y}(\ell)$$

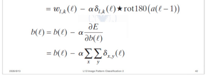

**Backpropagation for training**

$$w_{l,k}(\ell)=w_{l,k}(\ell)-\alpha\frac{\partial E}{\partial w_{l,k}}=w_{l,k}(\ell)-\alpha\delta_{l,k}(\ell)\star\text{rot}180(a(\ell-1))$$

$$b(\ell)=b(\ell)-\alpha\frac{\partial E}{\partial b(\ell)}=b(\ell)-\alpha\sum_x\sum_y\delta_{x,y}(\ell)$$

**BP**：输入模式向量：正向传播并确定分类误差. BP误差. 更新参数所需变化；更新权重与偏置