人工智能基础（B）

期末复习参考纲要

邵 玉

浙江大学脑与脑机融合前沿科学中心

浙江大学计算机科学与技术学院

2025年1月1日星期日

第一章复习要点

❖ 人工智能发展历史

– 1956年，被誉为人工智能诞生元年的达特茅斯会议在美国新罕布什尔州召开，首次正式提出了“人工智能”这一术语。

❖ 符号主义的基本思想

符号表示和逻辑推理

– 在人工智能研究的早期，符号主义（Symbolism）占据了主导地位。符号主义者认为，智能可以通过对符号的操作来实现，即使用逻辑和规则来模拟人类的思维过程。

– 符号主义的基本思想和方法包括：逻辑推理、知识表示、专家系统。

❖ 人工智能时代的社会及伦理问题

鲁棒性差、非结构化数据

– AI的自主性和决策能力引发了对意识、自我和人性的探讨。

– 在伦理学方面，AI的决策可能会涉及生死攸关的问题，如自动驾驶汽车在紧急情况下的选择。

【简答题点】对于符号主义优缺点的描述、对于人工智能时代伦理问题的思考。

第二章复习要点

- **机器学习概念**
  - 通过数据“自动学习”规律并作出预测或决策的能力
- **从“知识驱动”的AI，到“数据驱动”的AI**
- **机器学习的核心要素**
  - 模型，建模，关键阶段，数据，参数与超参数，损失函数
- **梯度下降法**
  - 核心思想：通过迭代优化，让模型不断调整参数，逐步降低损失函数的值，从而找到最佳解
  - 迭代优化过程
  - 主要超参数和影响（学习率）

第二章复习要点

- ❖ 回归与分类的概念
- ❖ 线性回归、逻辑回归
- ❖ 决策树、朴素贝叶斯、支持向量机
- ❖ K-Means聚类
- ❖ 过拟合

朴素贝叶斯要求掌握公式！

【简答题点】每种方法的类型（分类/回归/聚类、监督/无监督）、方法的参数与超参数、损失函数、求解方法

【简答题点】过拟合的原因、现象、解决方案，以及如何从学习曲线判断是否过拟合

【实践题点】以课本2.3.1回归任务为例，能够根据给定数据和目标，给出数据集划分、模型、模型训练方法、模型测试方法。

机器学习的核心要素

❖模型

数学函数

输出 $y = f(x)$ 输入

- **输入** x 被称为**特征**，即用来描述问题的数据；
- **输出** y 被称为**目标**，即模型要实现的结果或目标变量。

	x	y
情感分析	这真是太棒了！	正面
语言翻译	我很好	I am fine.
语音识别		春眠不觉晓
人脸识别		小明

- **情感分析**：输入 x 是一个句子，输出 y 是该句子的情感（如正面或负面）。
- **语言翻译**：输入 x 是一个英语句子，输出 y 是翻译成的中文句子。
- **语音识别**：输入 x 是录制的声音片段，输出 y 是对应的文字转录。
- **人脸识别**：输入 x 是一张人脸照片，输出 y 是此人的身份。

机器学习的核心要素

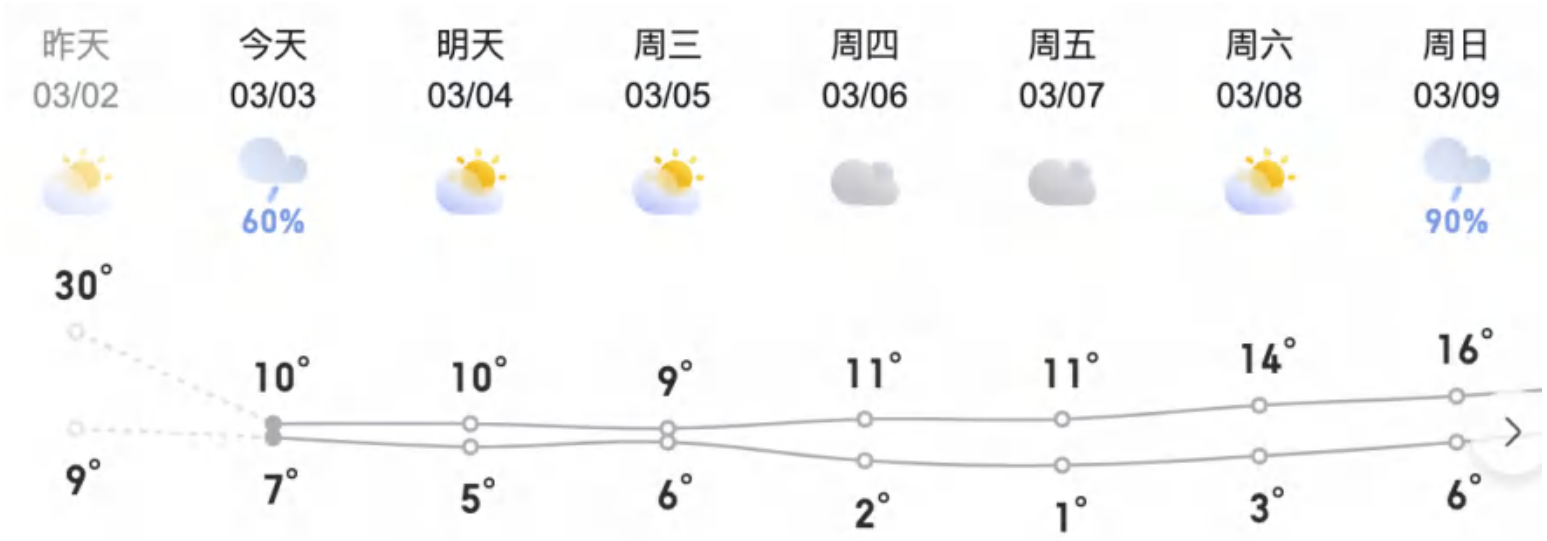
❖建模：找到输入和输出之间的函数关系，即 "$f()$"

比如预测一个城市的气温，一个直观的方法是：

温度(明天) = (温度(昨天) + 温度(今天)) ÷ 2

从数据出发：

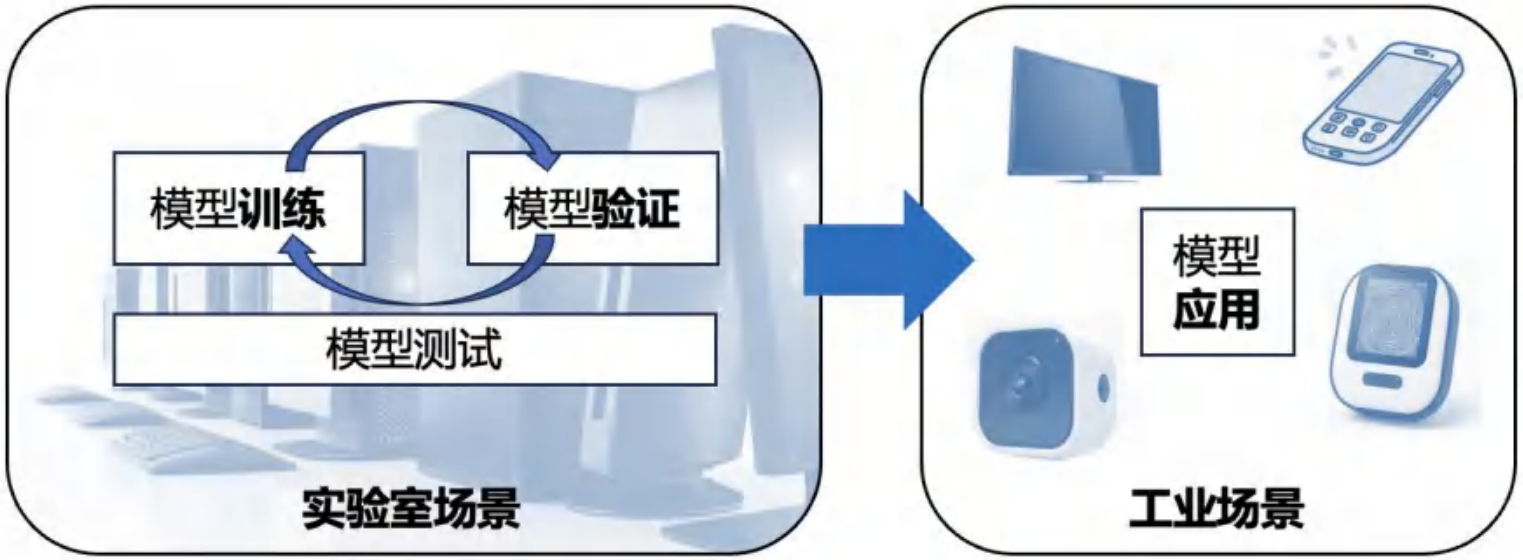
温度(明天) = A*温度(昨天) + B*温度(今天)



要素：模型的形式、模型的参数

机器学习的核心要素

❖关键阶段：训练、验证、测试和应用



机器学习的核心要素

❖数据集划分

一个典型数据集 D 的形式为：

$$D = \{(x_1, y_1), (x_2, y_2), \ldots (x_n, y_n)\}$$

- ✓ **训练数据(D_{train})**：占总数据的 60%~80%，用于训练模型，优化参数。
- ✓ **验证数据($D_{validate}$)**：占 10%~20%，用于调参和验证模型性能。
- ✓ **测试数据(D_{test})**：占 10%~20%，用于最终性能评估。
- ✓ **应用数据**：通常在实际部署时生成，没有固定比例。通常只有输入 x，模型需要基于已学到的规律预测未知的 y。

损失函数

❖ 损失函数是衡量模型预测结果与实际结果之间差距的工具。优化模型的核心目标是最小化损失函数的值，从而使模型的预测尽可能接近真实值。

均方误差：一般用于回归问题

$$L(\hat{y}, y) = \frac{1}{N}\sum_{i=1}^{N}(\hat{y_i} - y_i)^2$$

均方误差 yhead 预测值-标签值 误差的平方和 再平均

交叉熵：一般用于分类问题

$$L(\theta) = -\frac{1}{m}\sum_{i=1}^{m}(y_i \log f(x_i) + (1 - y_i)\log(1 - f(x_i)))$$

机器学习的通用方法：梯度下降法

❖ 梯度下降法

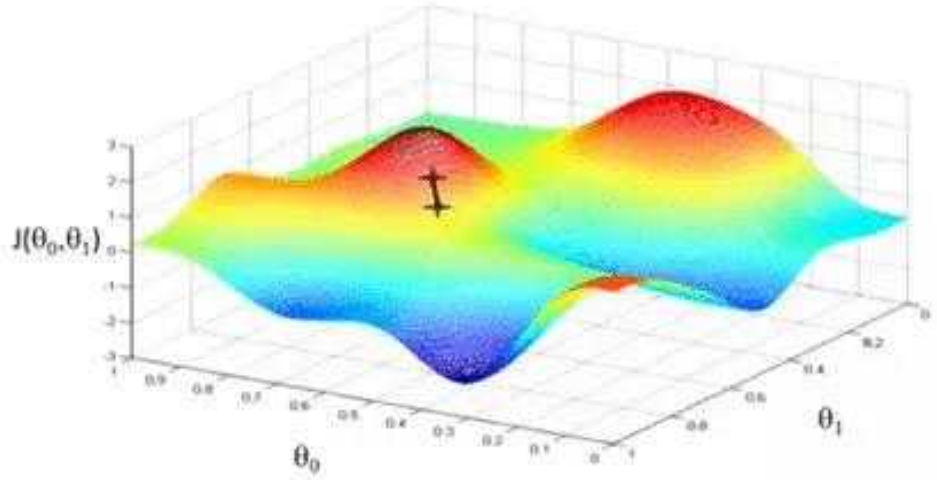
– 梯度下降的核心思想是通过迭代优化，让模型不断调整参数，逐步降低损失函数的值，从而找到最佳解。

基本步骤：

1 从起点出发，找到梯度最大方向

2 沿着梯度最大方向前进一小步

3 不断重复上述步骤，每次微调方向，向更低处移动，直到周围没有更低的位置



10

机器学习的通用方法：梯度下降法

❖ 梯度下降法

– 梯度下降的核心思想是通过迭代优化，让模型不断调整参数，逐步降低损失函数的值，从而找到最佳解。

局限性：

局部最优解：如果模型从一个不理想的初始参数出发，可能会陷入局部低点，而非全局最低点。

学习率的选择：学习率 α 对算法的效果至关重要。如果学习率太大，可能会“跳过”最低点；如果学习率太小，优化过程会变得非常缓慢。

【简答题点】梯度下降法的思想、过程、局限性

11

参数与超参数

- **参数与超参数：**在机器学习中，参数和超参数是两个核心概念。参数是模型在训练中学到的变量，而超参数是需要在训练开始前手动设定的选项，两者共同决定了模型的性能和效果。
- **参数**是模型在训练过程中学到的“内部数值”，这些数值决定了模型如何根据输入数据 x 生成输出 y。通过优化参数，模型能够从训练数据中提取规律并进行预测。
- **超参数**是在训练开始之前设定的外部变量，影响模型的结构和学习方式。与参数不同，超参数不是通过训练数据直接优化的，而是通过实验和经验手动调整。

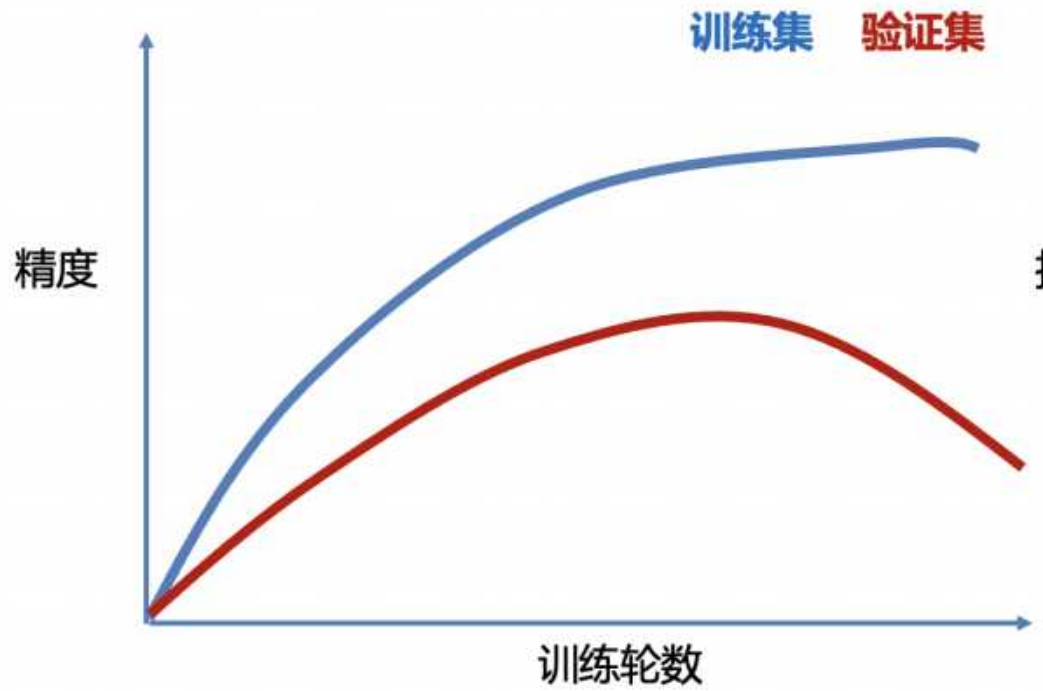
参数是模型在训练过程中通过数据学习得到的，而超参数是训练前设定的，用于控制模型的结构和学习策略。

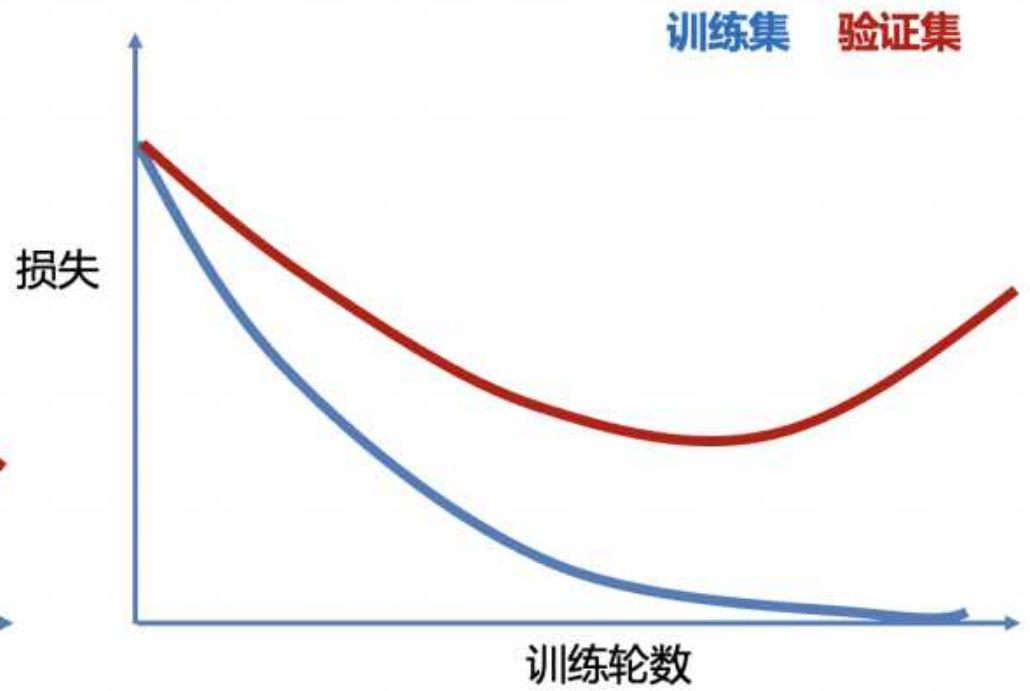
kmeans k是超参数

【简答题点】指定机器学习模型，说明有哪些参数和超参数

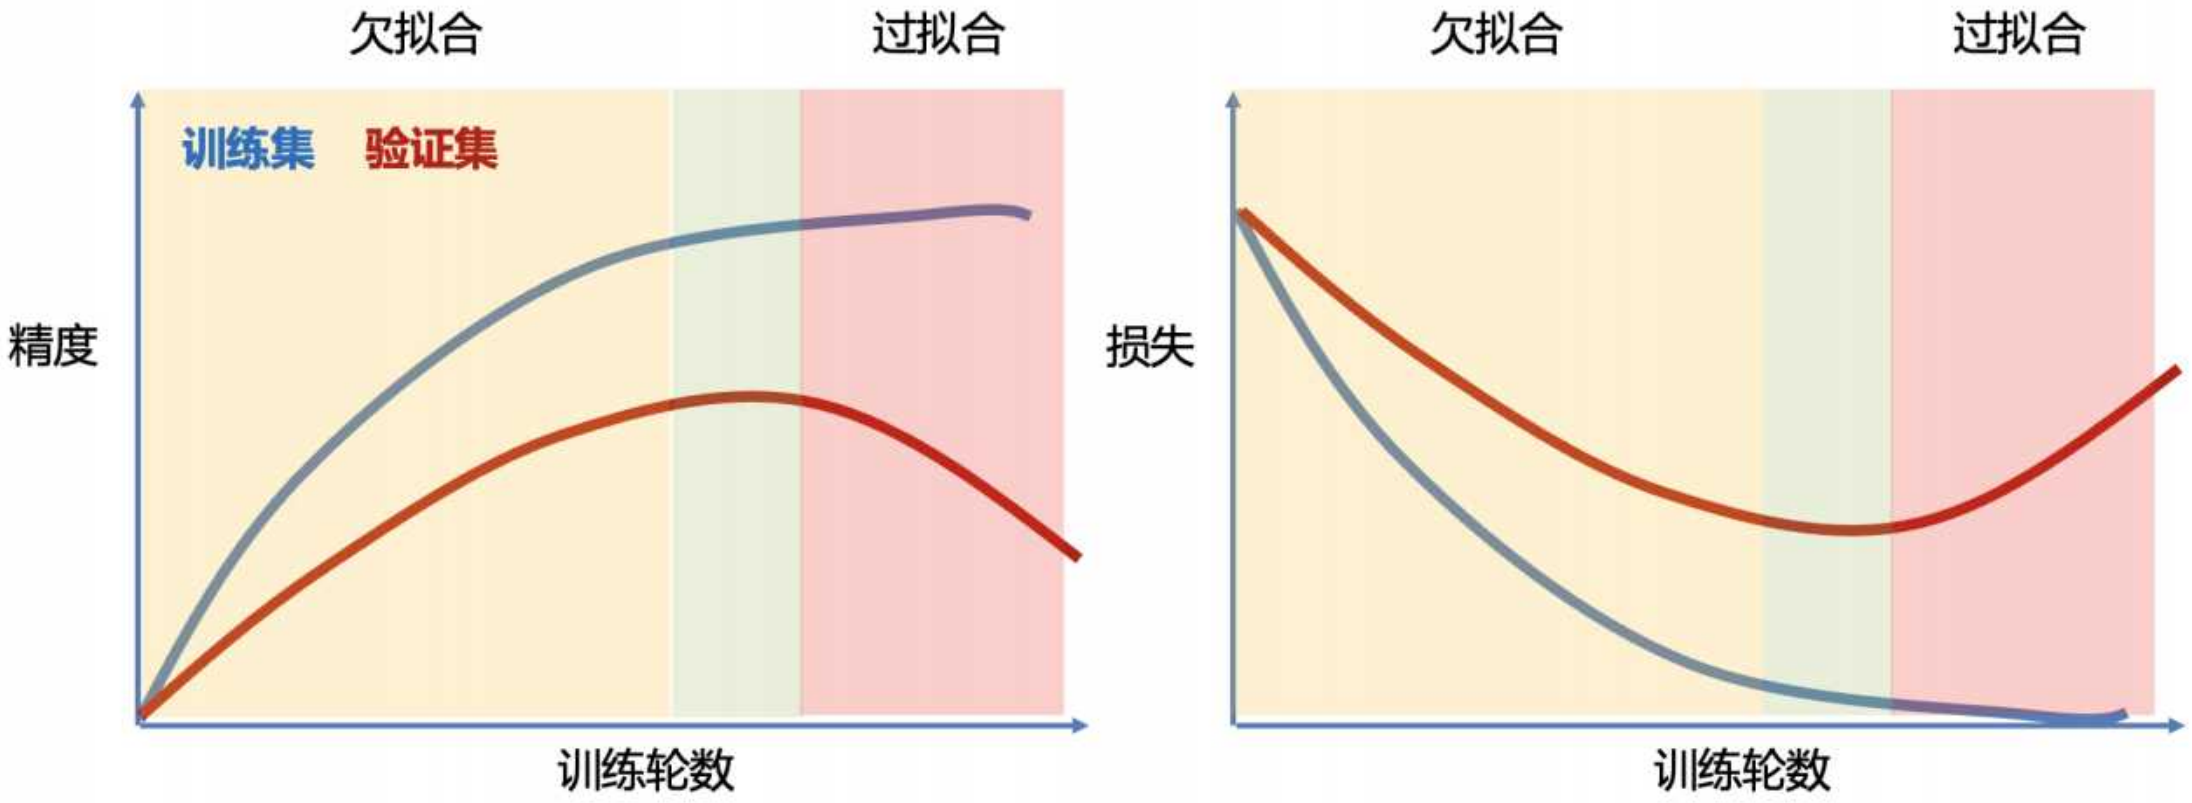
梯度下降的重要超参数：训练轮数

❖ 训练轮数：应该走多少步停止呢?



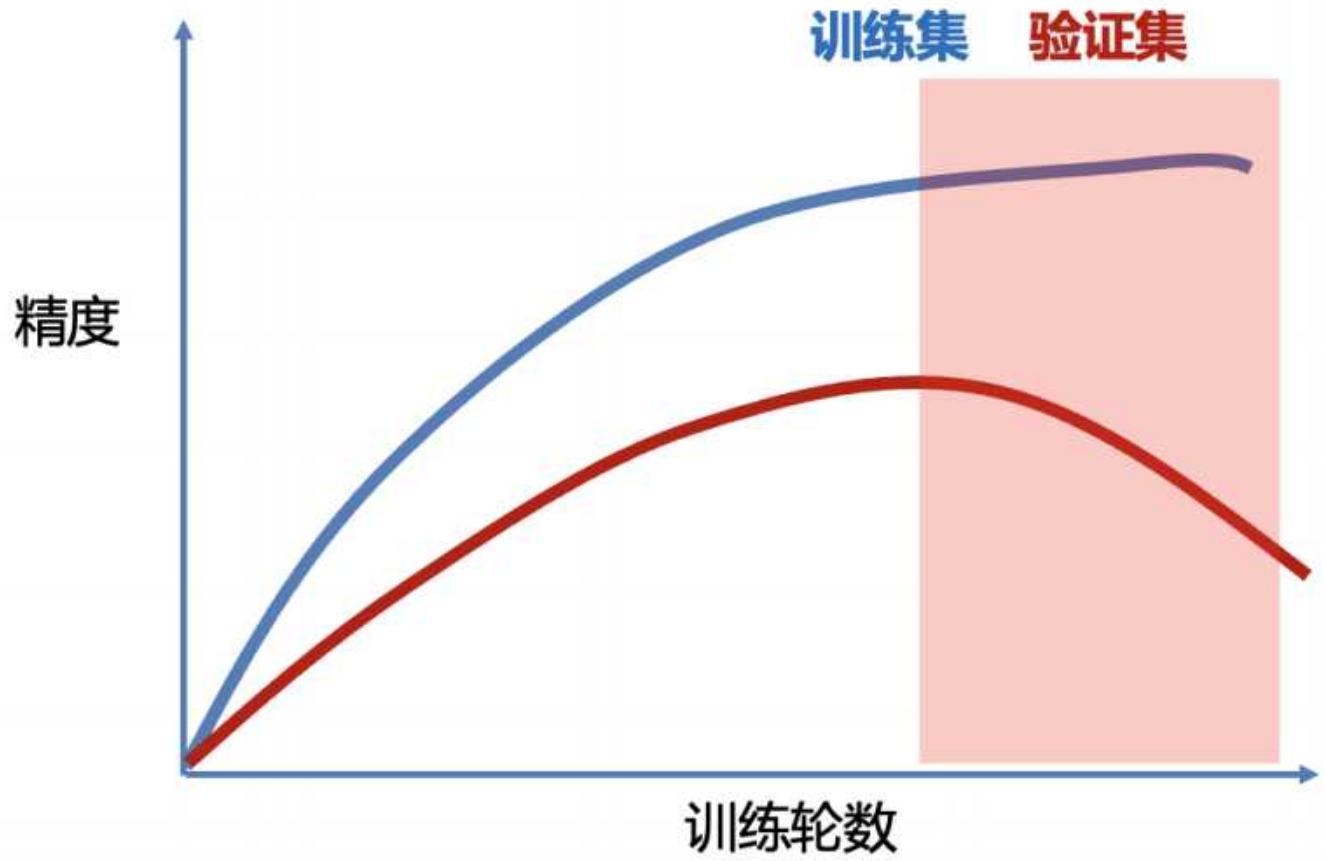


学习曲线



应对过拟合

- 增加数据量
- 数据增强
- 降低模型复杂度
- 正则化
- 早停
- 数据清洗
- 交叉验证

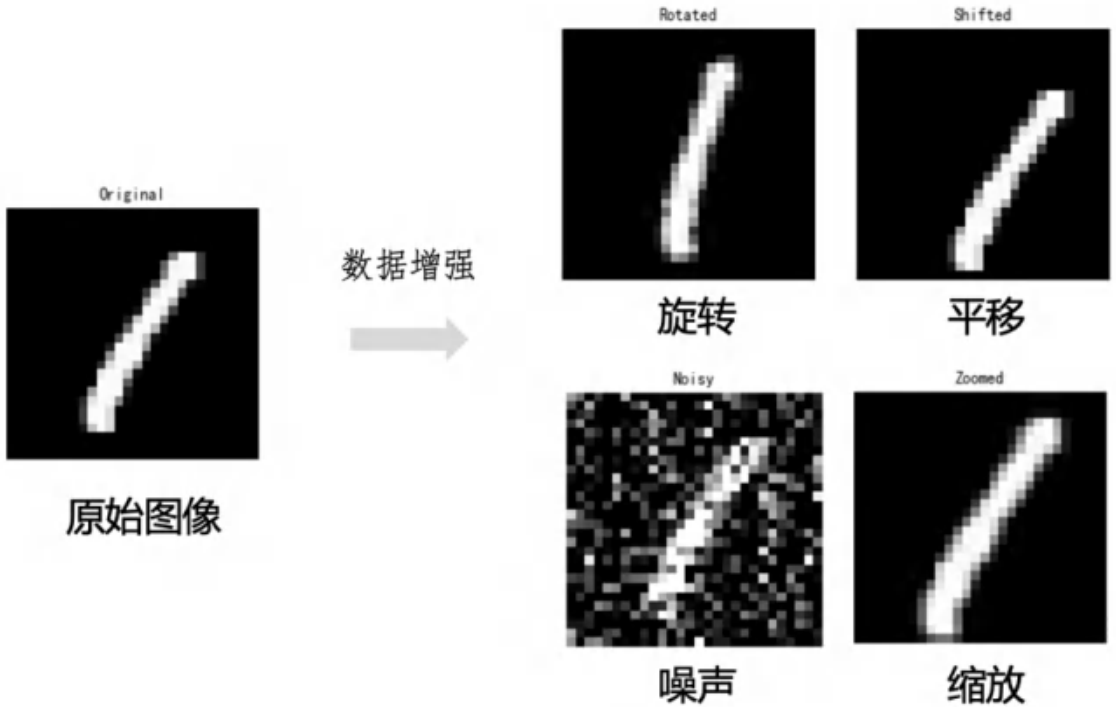


数据增强技术

噪声、偏置等等 文本数据增强

❖ 数据增强（**Data Augmentation**）是一种提升深度学习模型训练效果的常用方法，它通过对训练数据进行各种变换来增加数据集的多样性，从而提升模型泛化能力。尤其是当数据量有限时，数据增强可以显著提高模型的性能。

❖ **图像数据增强**



回归与分类：机器学习的两大任务

不是连续的类 是一种离散值

回归问题 用于预测连续值

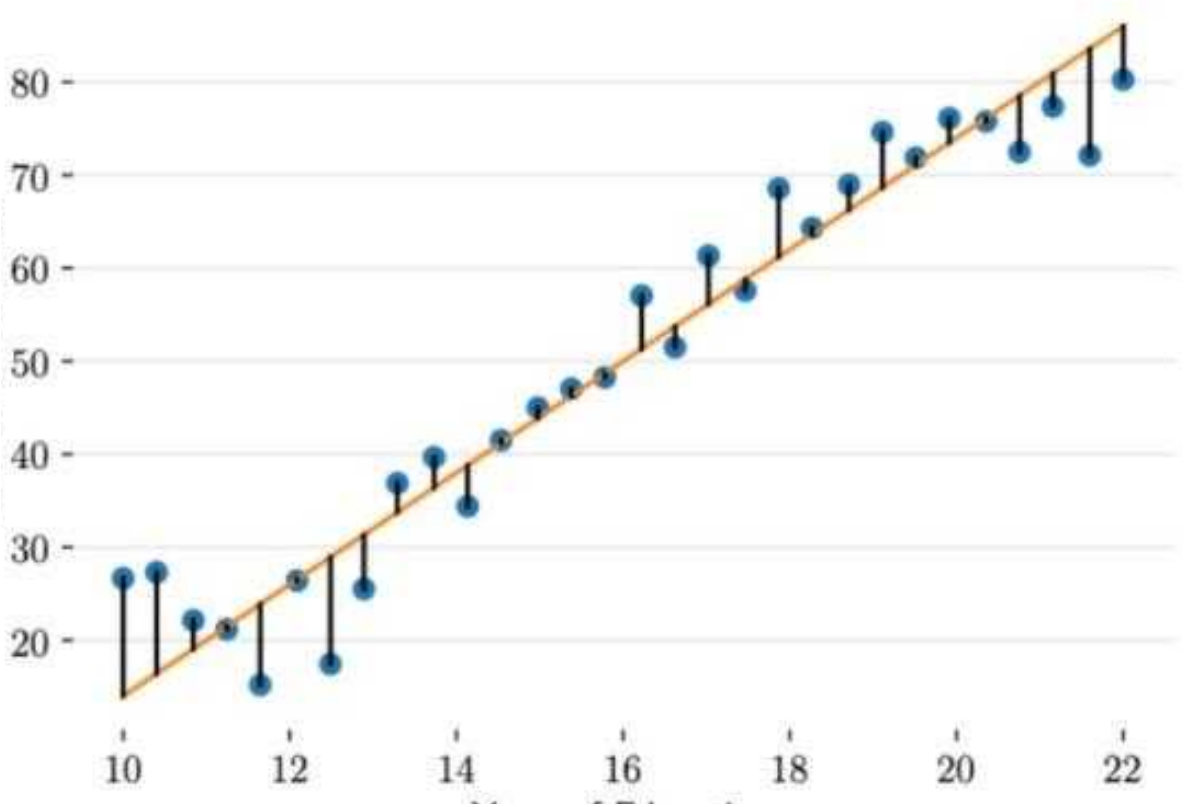
- 身高与体重的关系：根据一个人的身高，预测他的体重。
- 气温预测：根据过去几天的气温，预测明天的气温。
- 学历与收入：根据一个人的学历水平，预测他的年收入。

分类问题 判断一个样本属于哪一类

- 性别预测：根据一个人的身高和体重，预测性别（男/女）。
- 图片识别：输入一张图片，判断其中的物体是猫、狗，还是汽车。
- 疾病诊断：根据医学影像，判断某人是否患有某种疾病（是/否）。

线性回归

❖ 哪条线更好？损失函数来衡量



考虑一元线性回归：

$$y = mx + b$$

损失函数：

$$L(\hat{y}, y) = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}_i - y_i)^2$$

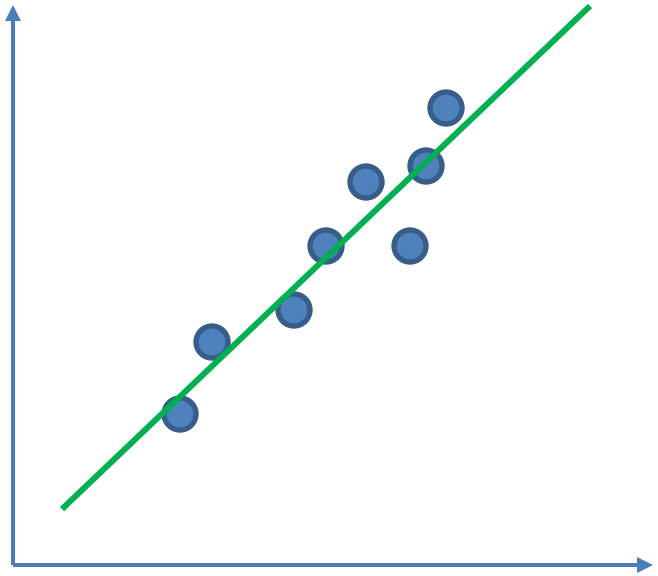
$$L(\hat{y}, y) = \frac{1}{N}\sum_{i=1}^{N}[(mx_i + b) - y_i]^2$$

模型参数：m和b

优化目标：找到使得L最小的m和b

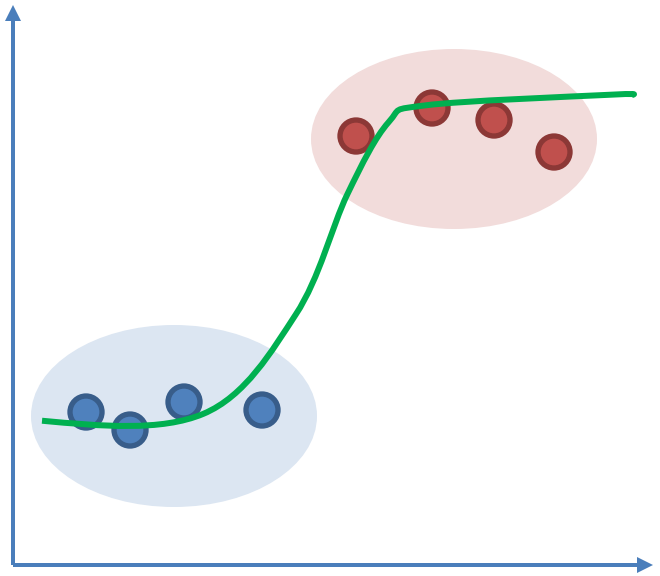
逻辑回归（Logistic regression）

❖**逻辑回归：通过回归方法解决二分类问题。**



线性回归

$y = mx + b$



逻辑回归

sigmoid函数 逻辑函数

$y = g(mx + b)$

决策树

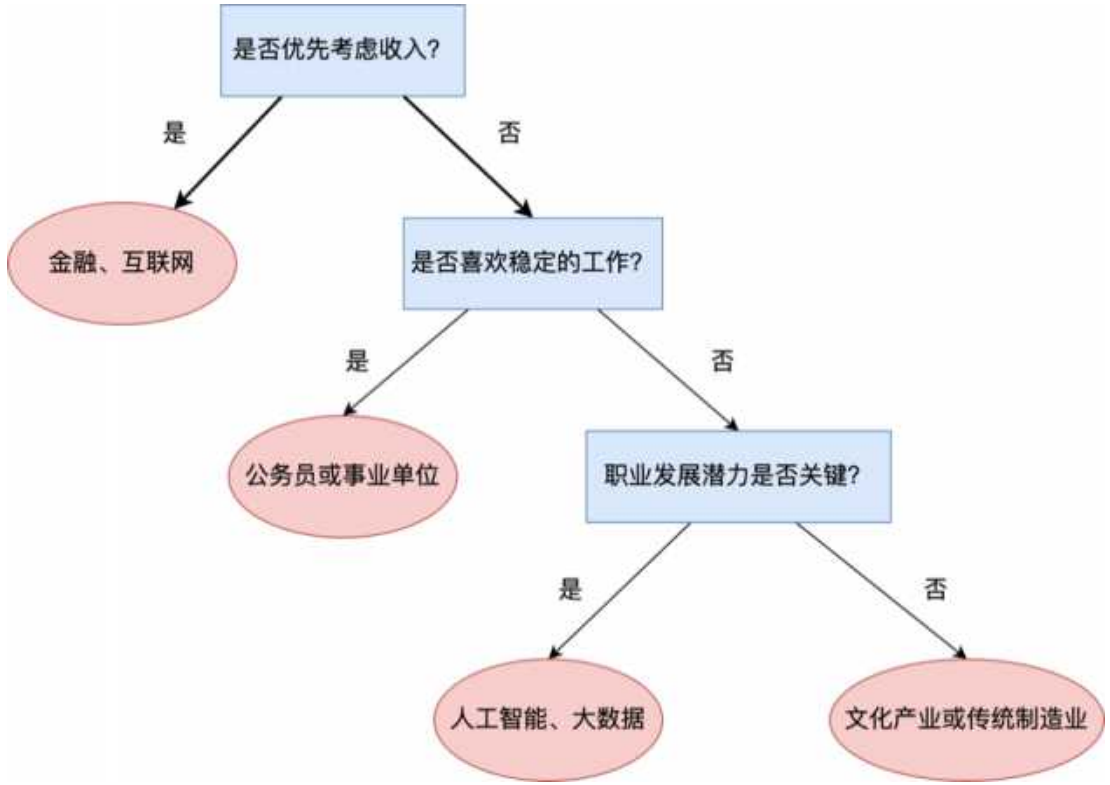
❖ **决策树（Decision Tree）**：一种形象化的分类模型，就像我们在生活中做决策时的推理过程。

1 天气好吗?

- 如果晴天：继续考虑
- 如果下雨：留在家

2 预算是否充足?

- 如果充足：可以长途旅行
- 如果有限：选择附近短途游



如何从数据构建决策树?

衡量数据的“有序”程度：计算信息熵

我们使用**“信息熵”**来计算信息的不确定性。

假设有 K 个信息，其组成了集合样本 D，记第 k 个信息发生的概率为 $p_k(1 \le k \le K)$。
这 K 个信息的信息熵：

$$E(D) = -\sum_{k=1}^{K} p_k log_2 p_k$$

$E(D)$ 的值越小，表示 D 包含的信息越确定，也称 D 的纯度越高。

朴素贝叶斯 – 先验、似然和后验

基本公式：　后验 = 先验 * 似然

$$P(C|X) = \frac{P(X|C)P(C)}{P(X)}$$

$P(C|X)$：在给定特征 X 的情况下属于类别 C 的概率（后验概率），即要预测的概率。

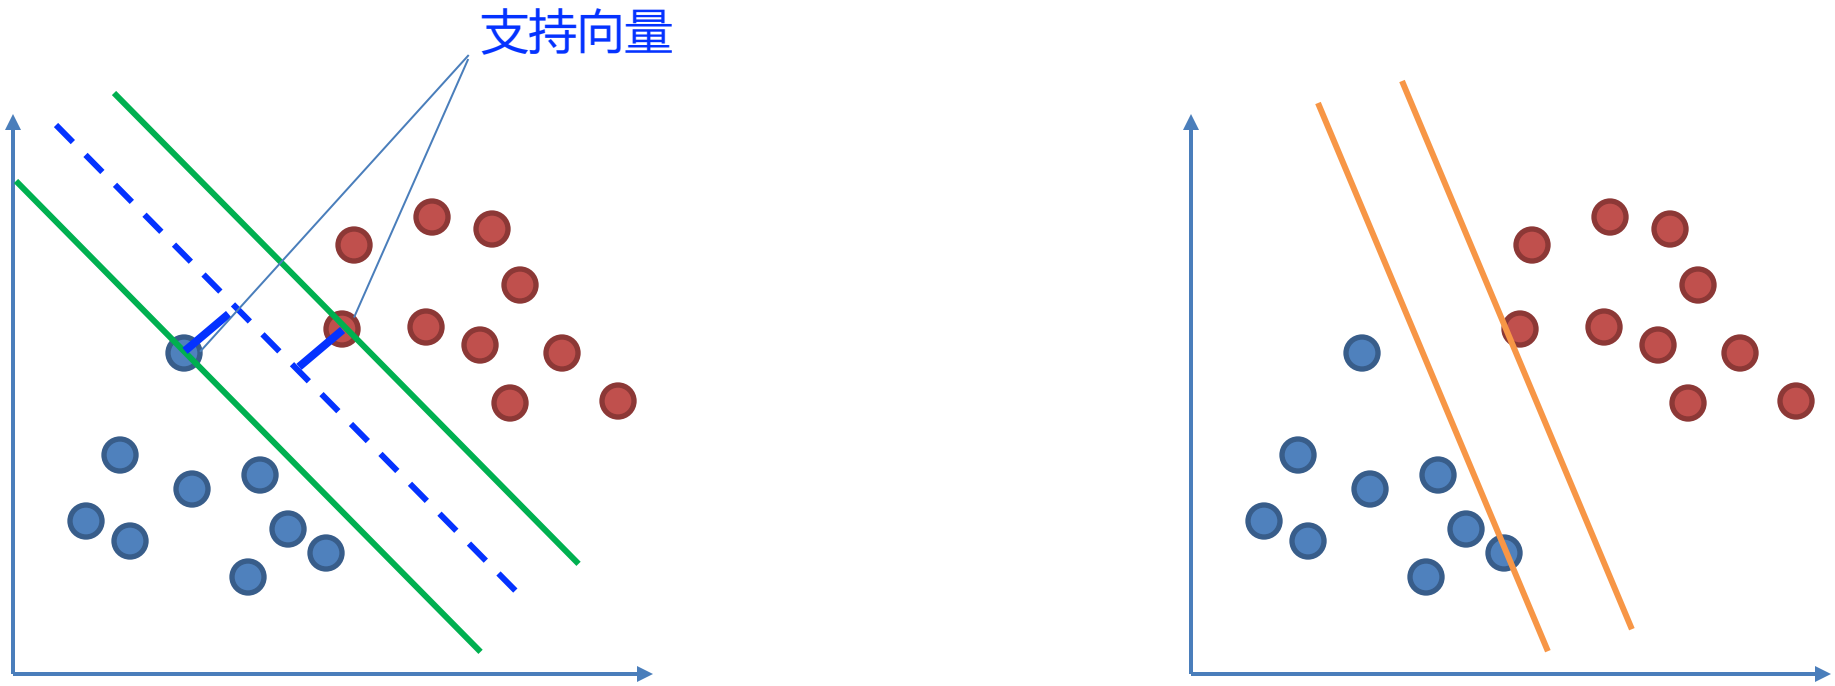
$P(X|C)$：在类别 C 下特征 X 出现的概率（似然概率）。

$P(C)$：类别 C 出现的概率（先验概率）。

$P(X)$：特征 X 出现的概率（标准化因子）。

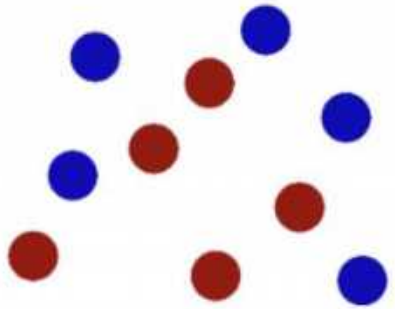
支持向量机

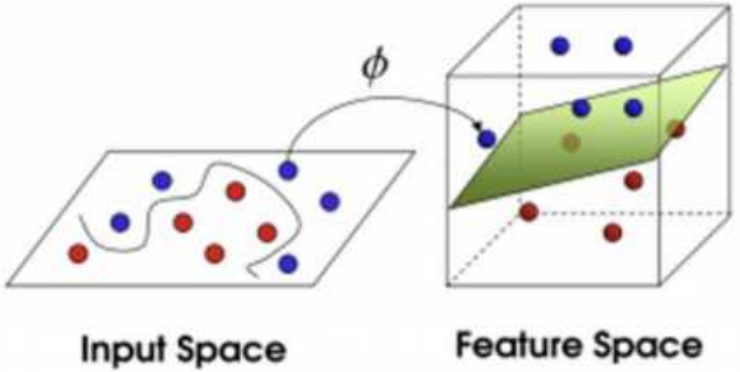
- 支持向量机（Support Vector Machine, SVM）是一种强大的分类模型，它的核心目标是找到一个“超平面”，将数据分成两类，同时最大化分割线与两类数据点的距离。
- 寻找“最大间隔超平面”



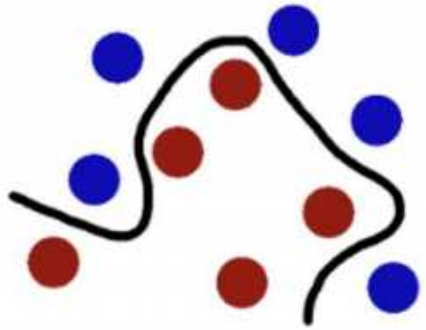
支持向量机

❖如果线性不可分呢？核函数！





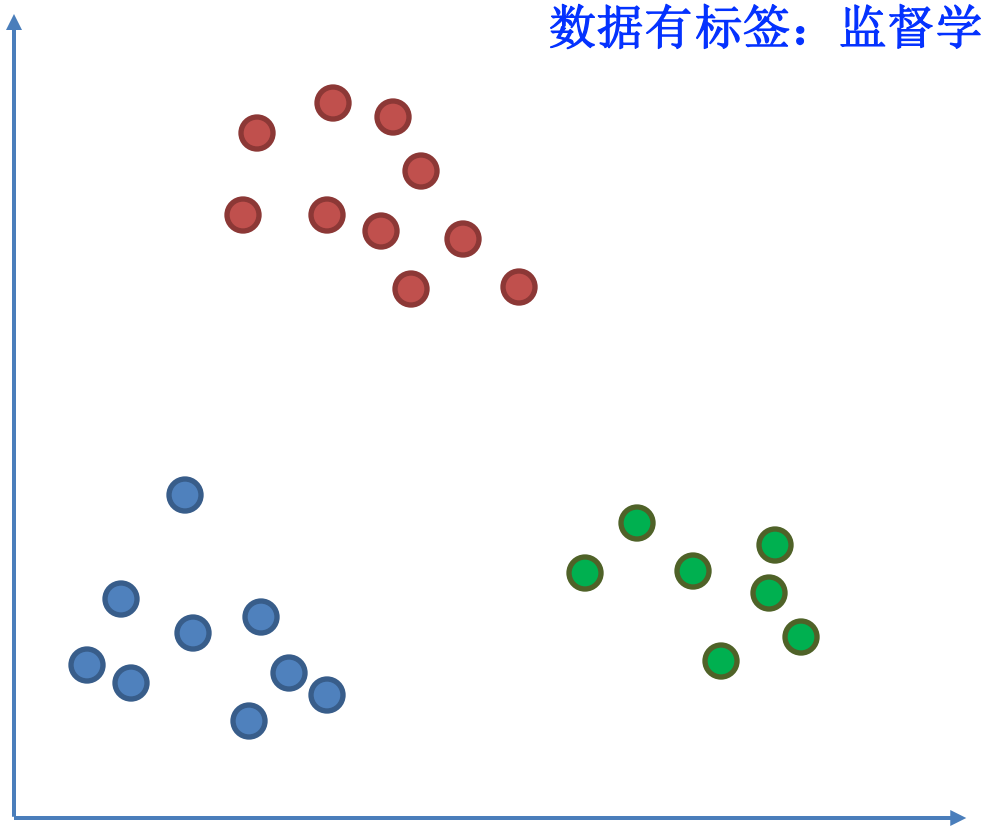
核函数



监督学习与无监督学习

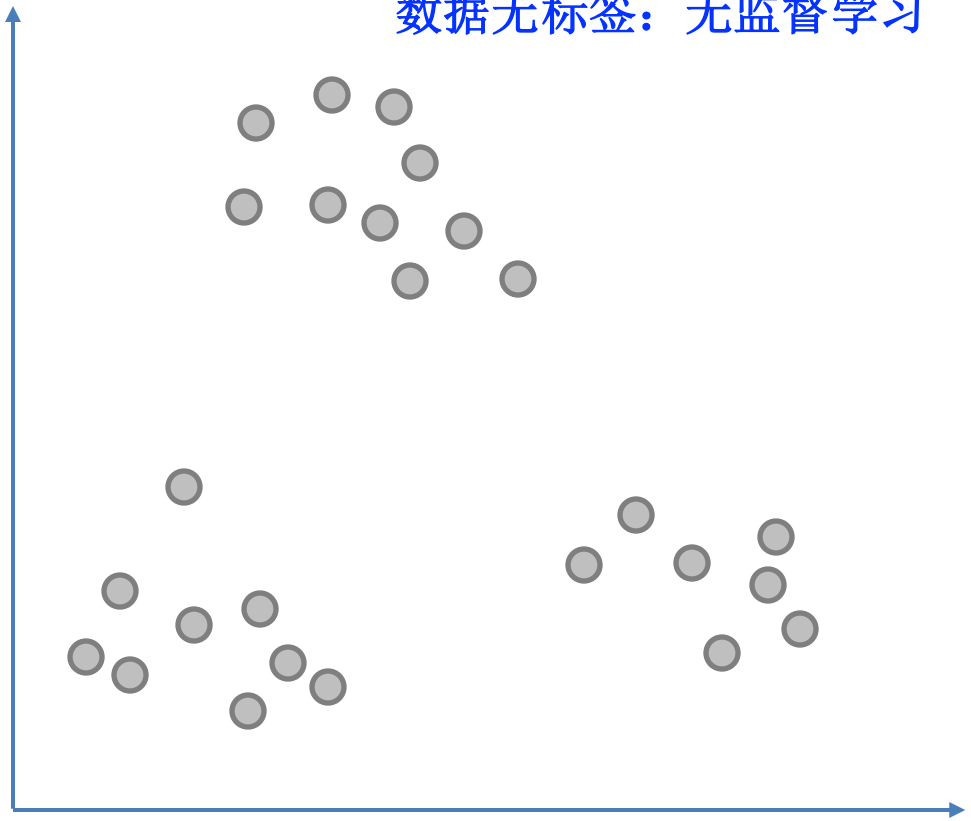
监督学习依赖于标注的数据集。无监督学习不需要标签数据，仅基于输入特征的分布来发现数据中的潜在结构和模式。

数据有标签：监督学习



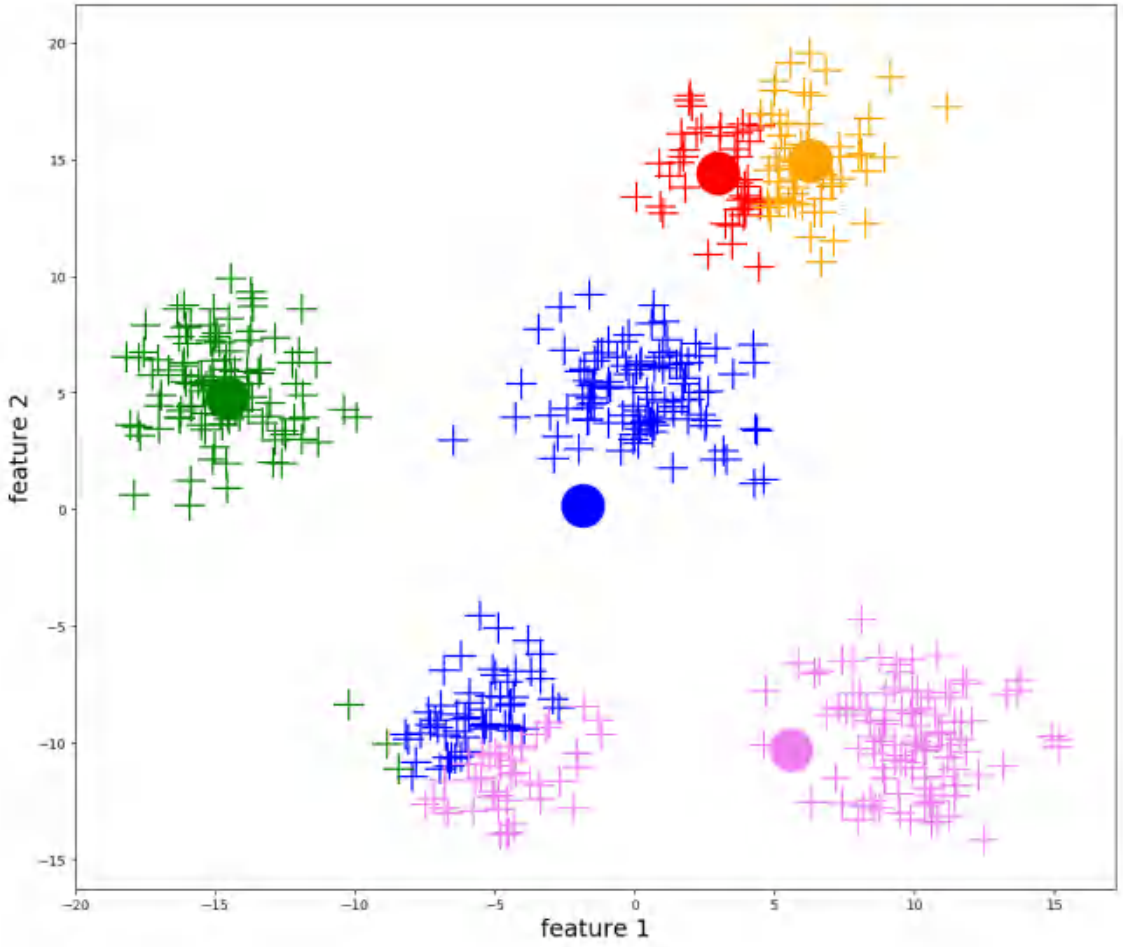
监督学习

数据无标签：无监督学习



无监督学习

聚类与K-Means算法



基于sklearn的机器学习实践

❖ **以后面几页PPT中的代码为例，对于核心代码，应了解每行代码的基本含义、关键参数等。**

【实践题点】给出一段基于sklearn的机器学习代码，指定关键语句，描述语句的功能。

示例代码：鸢尾花分类任务

❖ 获取鸢尾花数据集

```
from sklearn.datasets import load_iris
# 获取鸢尾花数据集
iris = load_iris()
print("鸢尾花数据集的返回值: \n", iris.keys())
```

❖ 获得数据信息

```
# 获得 ndarray 格式的变量 X 和标签 y
X = iris.data
y = iris.target

# 获得数据维度
n_samples, n_features = iris.data.shape

print(n_samples, n_features)
```

用逻辑回归进行鸢尾花数据集分类

```
# 只选择 Setosa (0) 和 Versicolor (1) 两类
X = X[y != 2]
y = y[y != 2]

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3)

# 创建逻辑回归模型
model = LogisticRegression()

# 训练模型
model.fit(X_train, y_train)

# 在测试集上进行预测
y_pred = model.predict(X_test)
```

第三章复习要点

❖ 人工神经元

- 激活函数（阶跃函数、sigmoid、tanh、ReLU、Softmax）
- 参数：w、b

❖ 人工神经网络

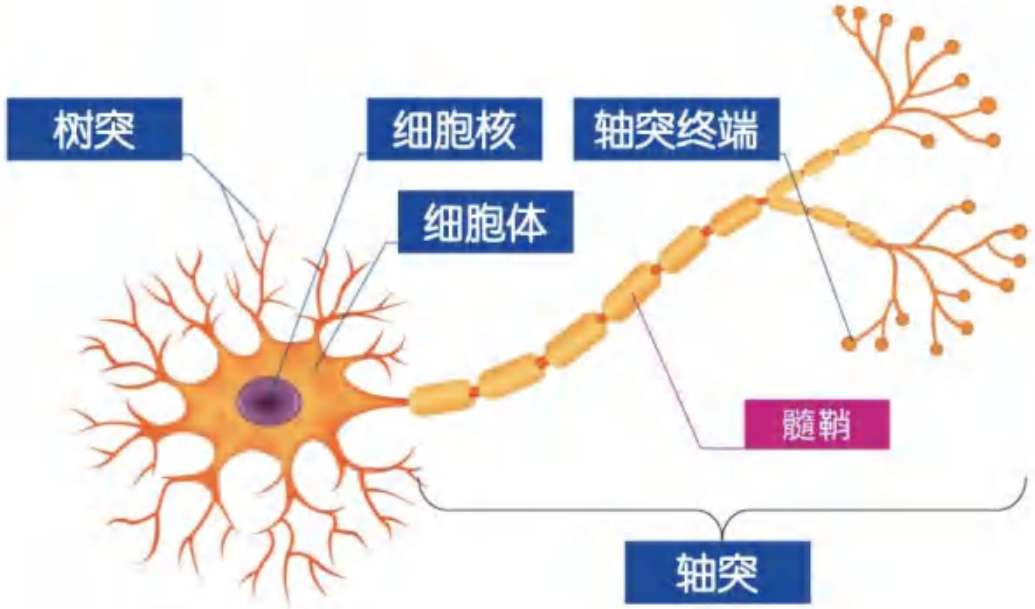
- 输入层、输出层、隐藏层、全连接网络
- 前序传播、反向传播
- 训练中的超参数、意义

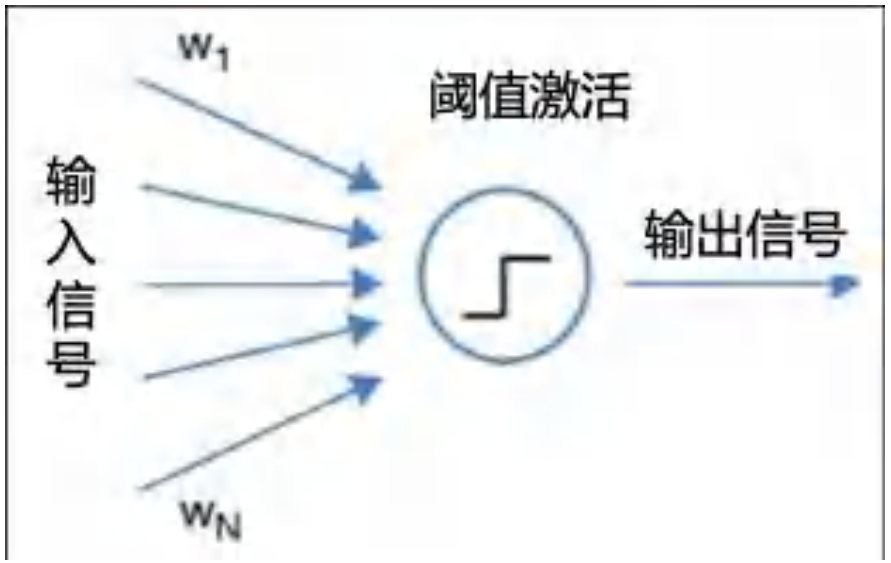
❖ 深度神经网络训练困难的原因

从生物神经元到人工神经元

❖ 人工神经元的基本结构

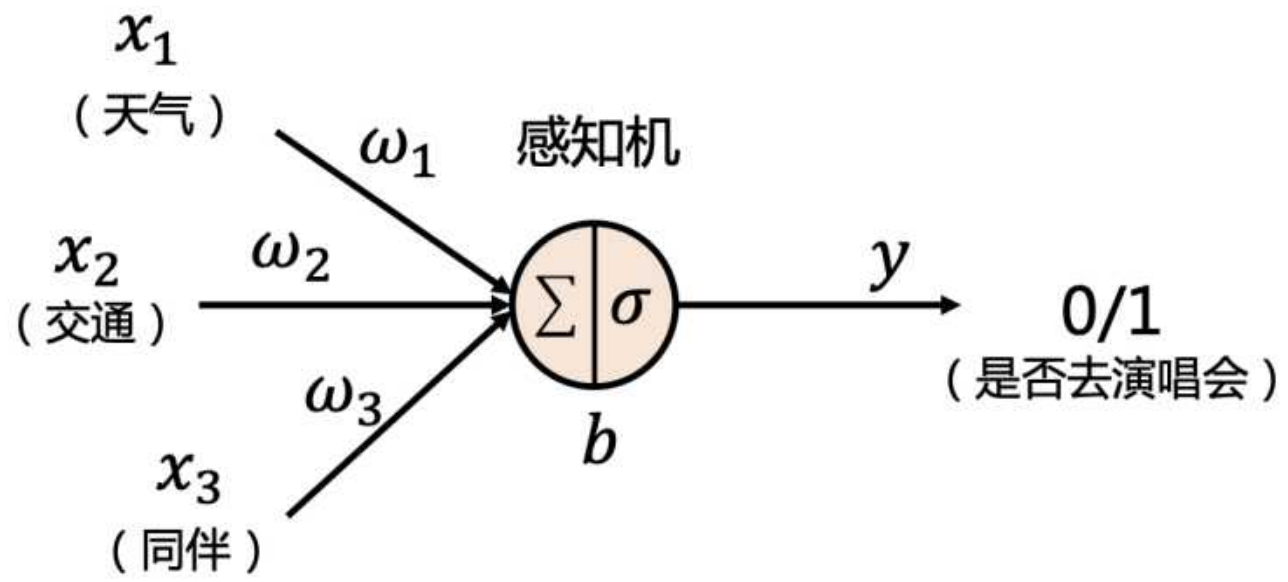
- 输入：信号输入（树突）
- 激活函数：计算单元（细胞体）
- 输出：信号输出（轴突）



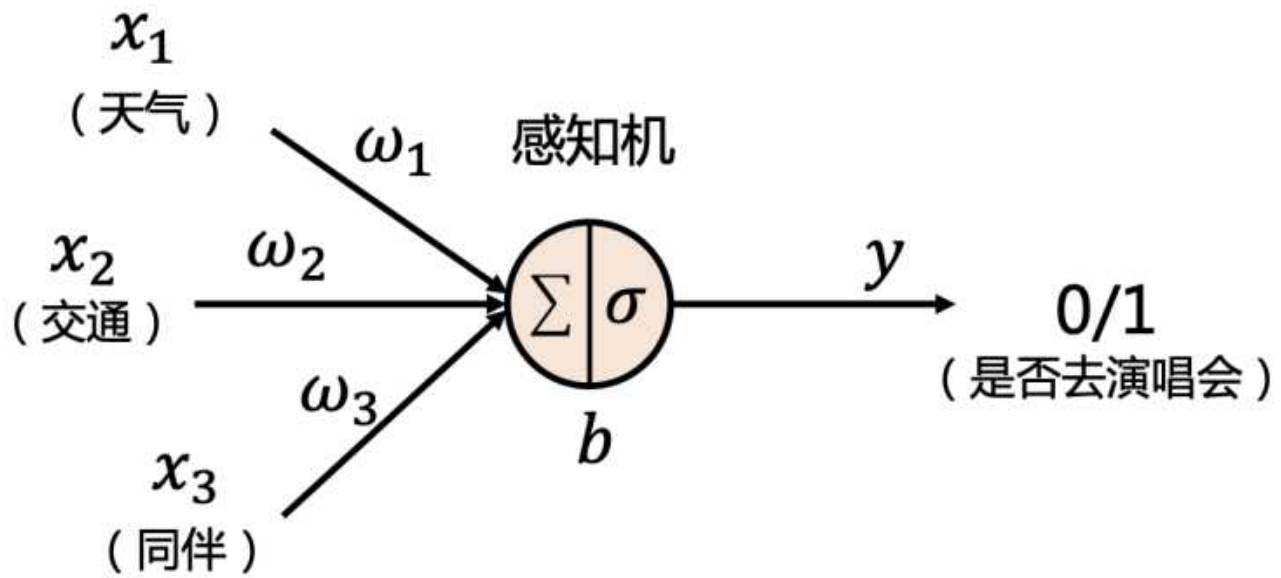


一个感知机的例子

❖ 通过一个例子来理解感知机的神经元，假设今天我们要做一个决策：晚上要不要去参加一场演唱会。这个决策取决于三个因素：x_1代表今天天气好坏， x_2表示去演唱会的交通是否方便， x_3代表是否有人陪着一起去。而 w_1，w_2，w_3分别表示这三个因素的重要性，因此我们将这三个因素加权求和： $x_1w_1 + x_2w_2 + x_3w_3$，此加权求和值如果大于某个阈值 b，则去参加演唱会（输出为1），否则不去（输出为0）：



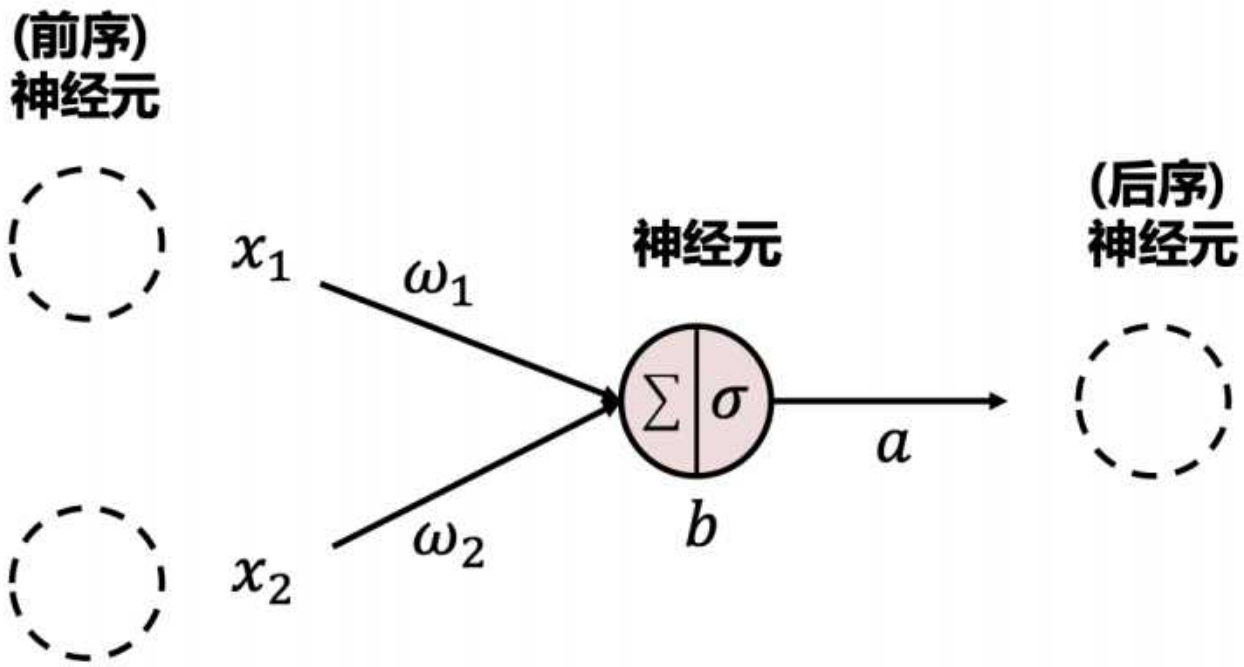
一个感知机的例子



$$\sigma(z) = \begin{cases} 1 & if\ x_1w_1 + x_2w_2 + x_3w_3 - b\ > 0 \\ 0 & otherwise \end{cases}$$

w 和 b 就是这个神经元的参数， w 决定了不同 x 的重要性，而 b 决定了一个人是否会去演唱会的偏好：如果 b 很高，则 wx 加权求和要很高才会去演唱会。

一个典型的人工神经元



神经元的计算操作:

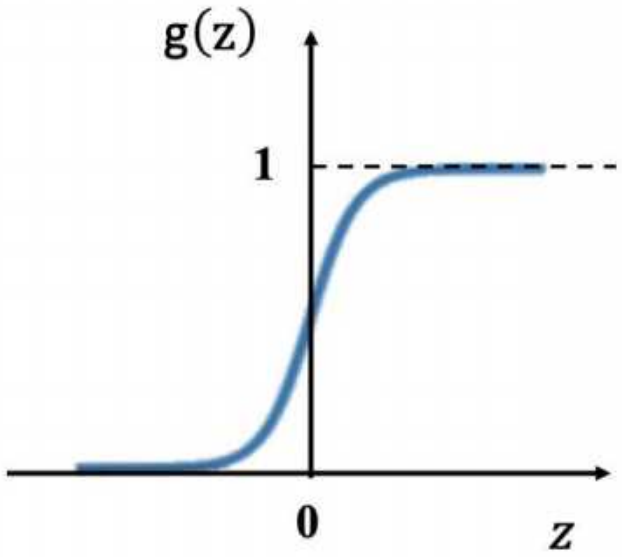
加权求和：$\sum wx$

减去偏置：$\sum wx - b$

经过激活函数：$\sigma(\sum wx - b)$

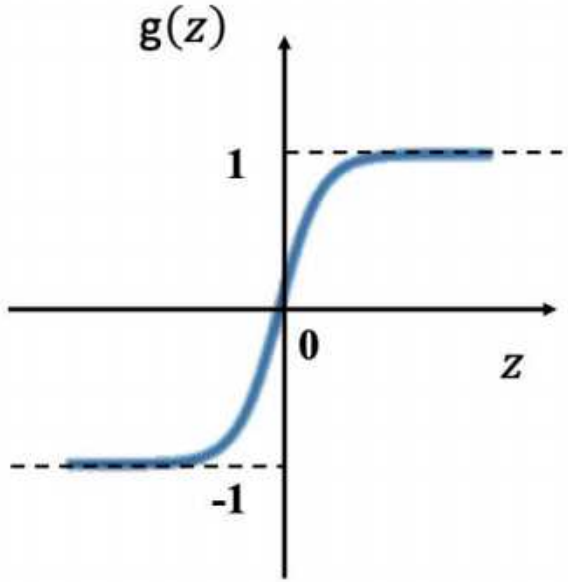
$$f(x) = \sigma\left(\sum wx - b\right)$$

人工神经元的激活函数



Sigmoid

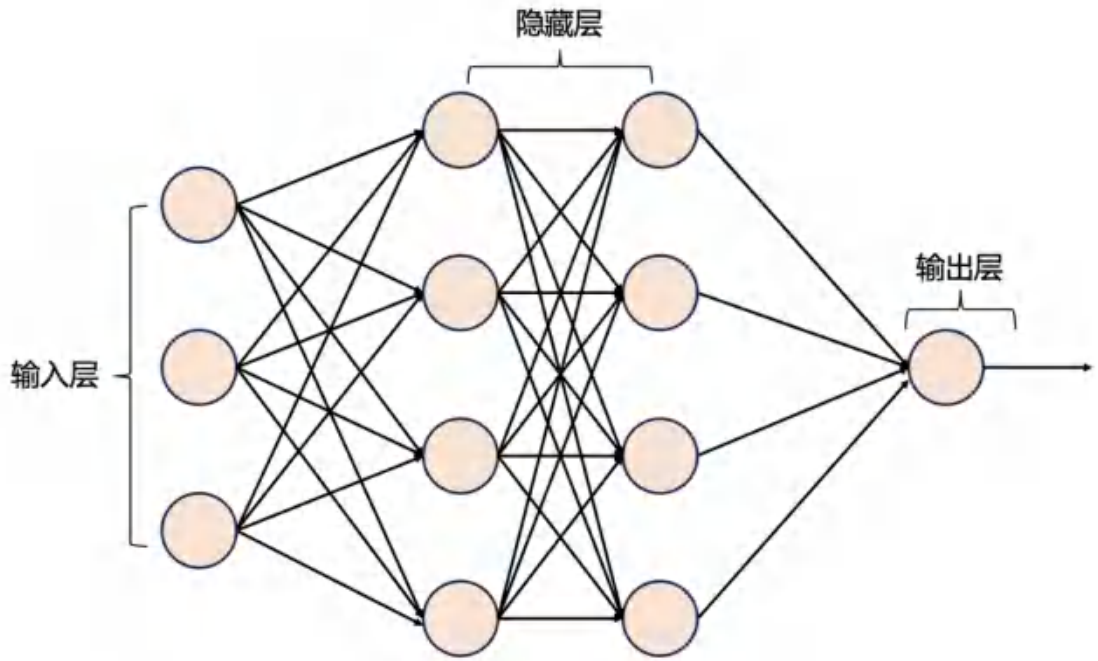
$$g(z) = \frac{1}{1+e^{-z}}$$



$$tanh(z) = \frac{e^{z} - e^{-z}}{e^{z} + e^{-z}}$$

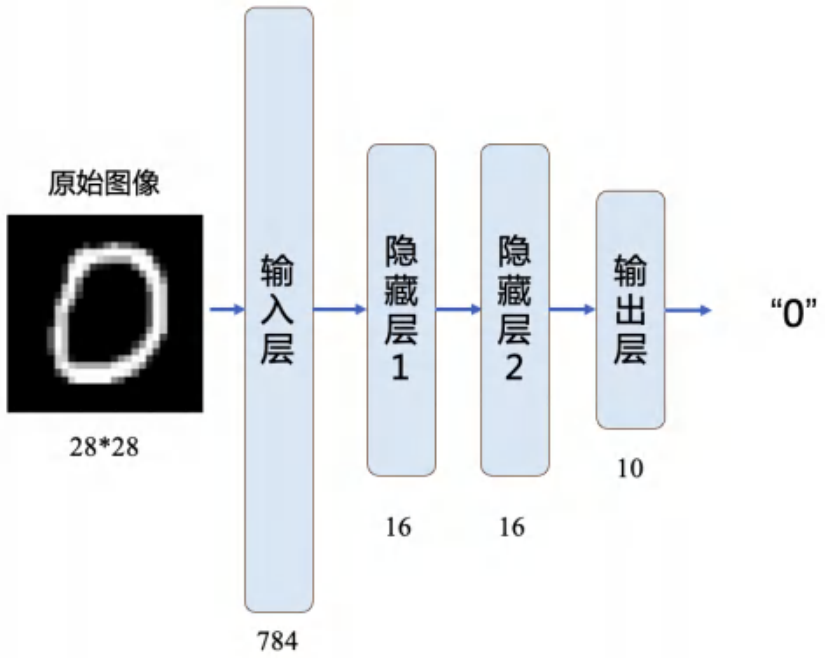
从人工神经元到人工神经网络

❖ **当许多神经元组合在一起，形成一种层次结构，就构成了神经网络。**



从第一层开始，每个神经元做完计算之后，获得其激活函数输出后，传递到下一层，下一层的神经元也经历三个动作，再传递到再下一层，直至到最后一层神经元，输出最终结果。

神经网络的参数是哪些?



它有多少个参数呢?

w 和 b 就是我们要优化的参数，第一层784个神经元，第二层和第三层都是16个神经元，最后一层是10个神经元，于是其参数数量：

w：$784 * 16 + 16 * 16 + 16 * 10 = 12,960$

b：$16 + 16 + 10 = 42$

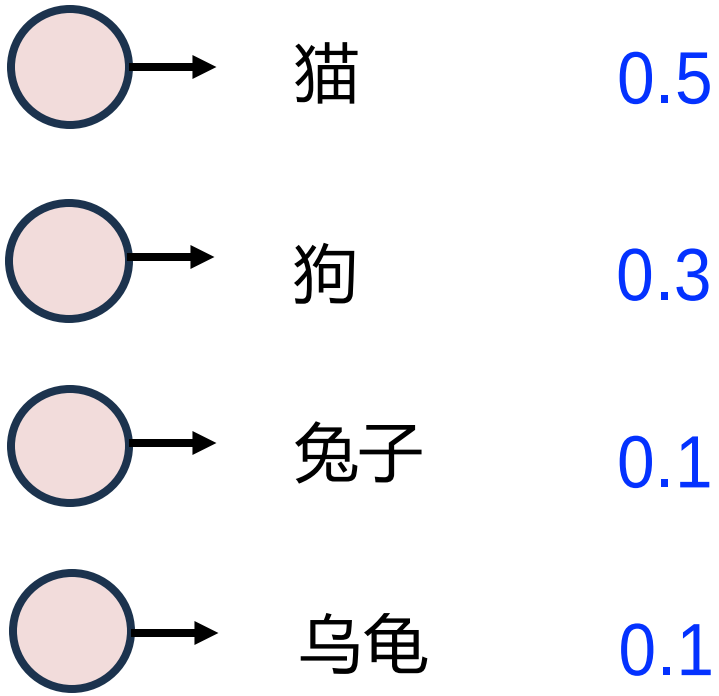
One-hot编码

❖ One-Hot 编码是一种将分类变量**转换为**二进制向量的方法，使得机器学习算法能够更好地处理非数值型数据。

- **核心思想**：每个类别对应一个唯一的二进制向量，其中只有一位是 1（表示激活），其余位都是 0（表示不激活）。
- **示例**：
  - 原始类别：["猫", "狗", "鸟"]
  - One-Hot 编码：
    - 猫 → [1, 0, 0]
    - 狗 → [0, 1, 0]
    - 鸟 → [0, 0, 1]

Softmax函数

❖ Softmax 是一种常用的**归一化指数函数**，主要用于多分类问题的输出层，将神经网络的原始输出（Logits）转换为**概率分布**，使得所有类别的概率之和为 1。



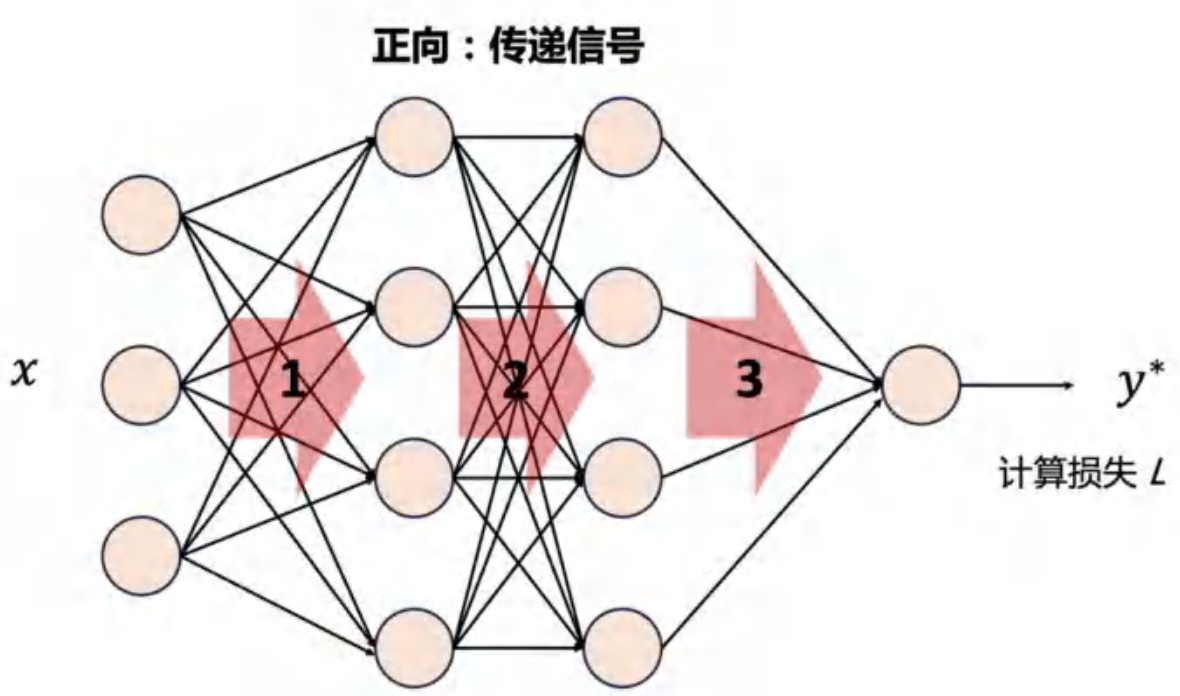
Softmax函数

$$a_j = \frac{e^{x_j}}{\sum_{i=1}^{k} e^{x_i}}$$

对 k 个不同的 x 值，Softmax函数将其转化成 k 个不同的 a，而这些 a 表示了不同类别的概率。

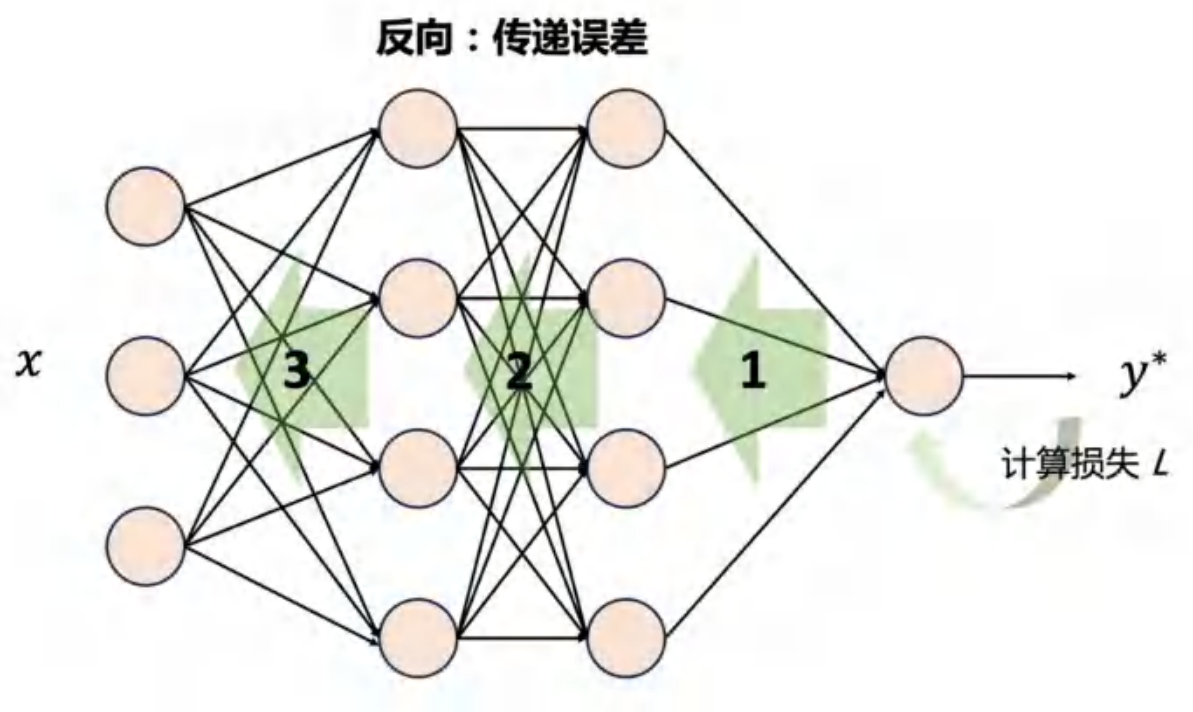
神经网络的计算：前序传播

❖ 前序传播是从输入 x 计算输出的过程。具体而言，一个神经网络从输入 x 开始，经历一层层隐藏层的操作，最后获得 y 的输出，这个输出即对 y 的预测 y^*，这个预测与实际 y 之间的差别，就是损失值，或者更准确地说，是关于 w 和 b 的损失函数。



人工神经网络：反向传播

❖ 反向传播在Rumelhart, Hinton & Williams (1986)的论文中被提出。我们可以认为，反向传播就是从最后一层开始，逐层将损失 L 传递回来，从而逐层修正模型参数（w 和 b），使得 L 更小的过程。

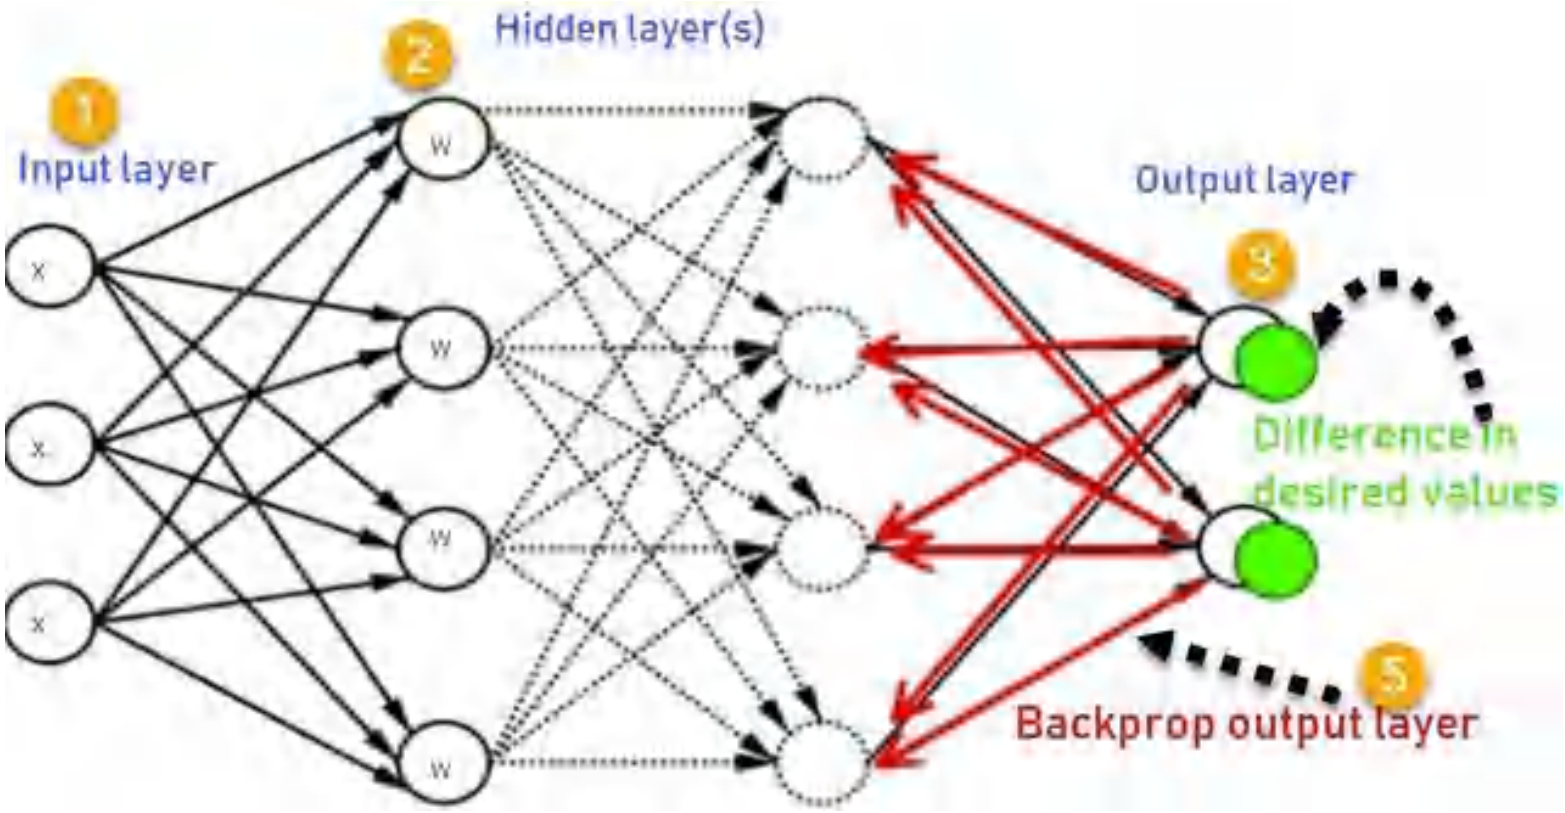


深度神经网络

- 一个拥有很多隐藏层的神经网络就是深度神经网络。实际上，根据通用近似原理（Universal Approximation Theorem），只有一个隐藏层的神经网络，就能近似任意的函数，那为什么我们还需要一个很深的神经网络呢？
- 第一，更深的网络所需的参数更少，这或许跟直观感觉相悖，深度神经网络不是网络更大，参数更多么？但实际上，如果要达到同样的模型能力，一个很浅的神经网络则会变得非常宽，从而需要更多的模型参数，因此网络更难训练；
- 第二，更深的网络可以构成更深的语义层次结构，这符合人类认知世界的方式（我们认识世界可以看做是不断将低层次的概念组合成更高层次新的概念的过程）。

深度神经网络的训练难题

❖ 梯度消失/梯度爆炸



基于keras的实践

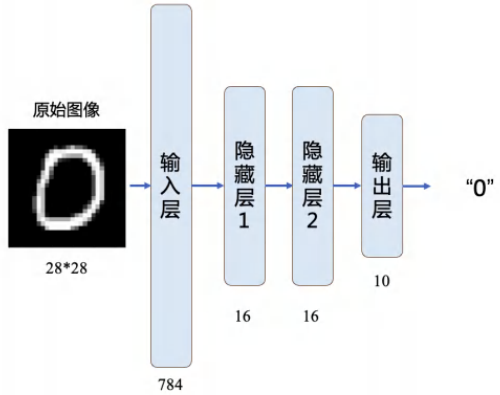
❖ **以后面几页PPT中的代码为例，对于核心代码，应了解每行代码的基本含义、关键参数等。**

【实践题点】给出一段基于keras的机器学习代码，说明其中关键语句的基本含义。

例子：手写数字识别

❖ 1、导入必要的库

```
import numpy as np
import matplotlib.pyplot as plt
from keras.datasets import mnist
from keras.models import Sequential
from keras.layers import Dense, Flatten
from keras.utils import to_categorical
from keras.optimizers import Adam
```



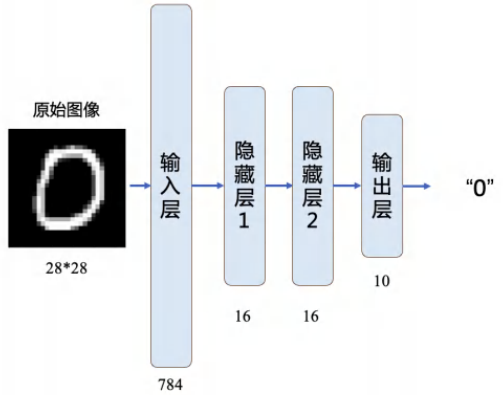
例子：手写数字识别

❖2、加载数据集

```
# 加载MNIST数据集
(x_train, y_train), (x_test, y_test) = mnist.load_data()

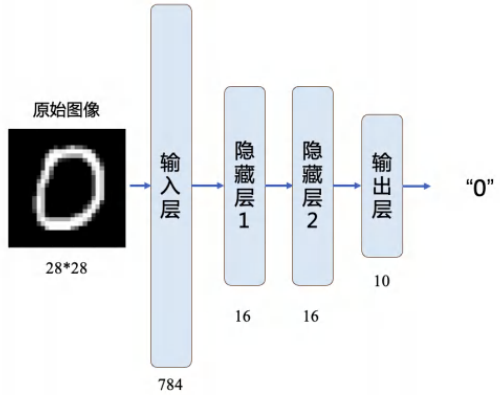
# 数据归一化 (0-255 -> 0-1)
x_train = x_train.astype('float32') / 255.0
x_test = x_test.astype('float32') / 255.0

# 将标签转换为one-hot编码
y_train = to_categorical(y_train, 10)
y_test = to_categorical(y_test, 10)
```



例子：手写数字识别

❖ 3、构建模型

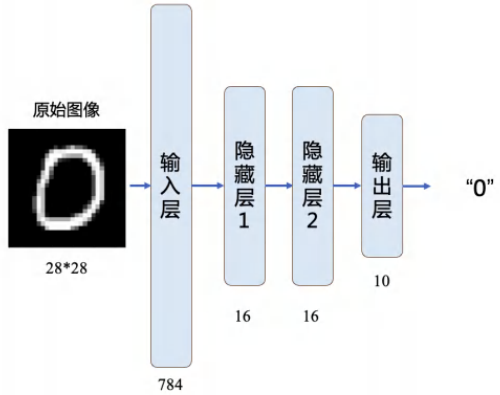



```
model = Sequential()  # 创建空模型

model.add(Flatten(input_shape=(28, 28)))  # 展平层，将28x28图像转为784维向量
model.add(Dense(16, activation='relu'))     # 第一个隐藏层，16个神经元
model.add(Dense(16, activation='relu'))     # 第二个隐藏层，16个神经元
model.add(Dense(10, activation='softmax')) # 输出层，10个神经元对应10个数字类别
```

例子：手写数字识别

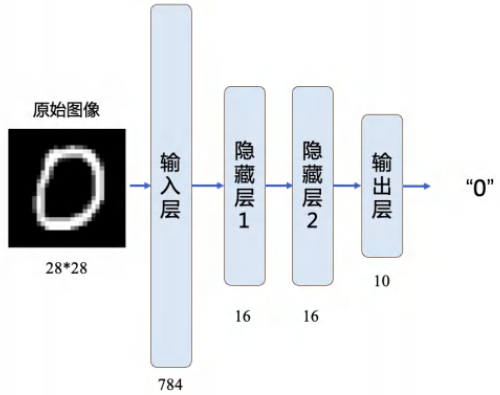
❖ 4、编译模型




```
# 编译模型
model.compile(optimizer=Adam(learning_rate=0.001),
              loss='categorical_crossentropy',
              metrics=['accuracy'])
```

例子：手写数字识别

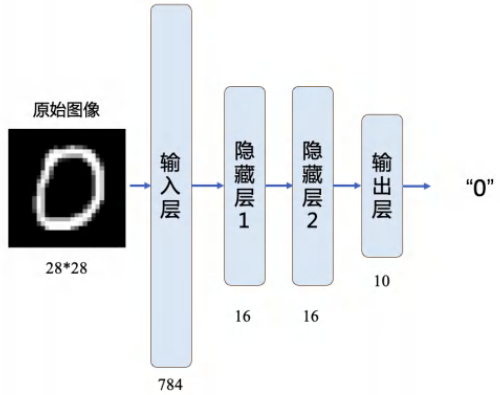
❖ 5、训练模型




```
history = model.fit(x_train, y_train,
                    batch_size=32,
                    epochs=10,
                    validation_split=0.2,   # 使用20%训练数据作为验证集
                    verbose=1)
```

例子：手写数字识别

❖6、评估模型




```
# 在测试集上评估
test_loss, test_acc = model.evaluate(x_test, y_test, verbose=0)
print(f"\n测试集准确率: {test_acc:.4f}")
```

```
测试集准确率: 0.9523
```

第四章复习要点

- **深度学习**
  - 概念和快速发展的原因
- **卷积神经网络**
  - 适用场景和原因，网络基本结构、卷积和池化、图像处理中的优势
- **循环神经网络**
  - 适用场景和原因，网络基本结构、LSTM、序列处理中的优势
- **深度学习中常用的超参数及其意义**

深度学习的概念

❖深度学习(Deep Learning)

- 特指基于深层神经网络模型和方法的机器学习方法。

❖深度学习快速发展的条件

- GPU的发展，带来建模算力的提升；
- 大数据带来海量的训练数据；
- ReLU激活函数被提出，可以有效缓解梯度消失问题。

常用深度学习方法

✓ 自编码神经网络

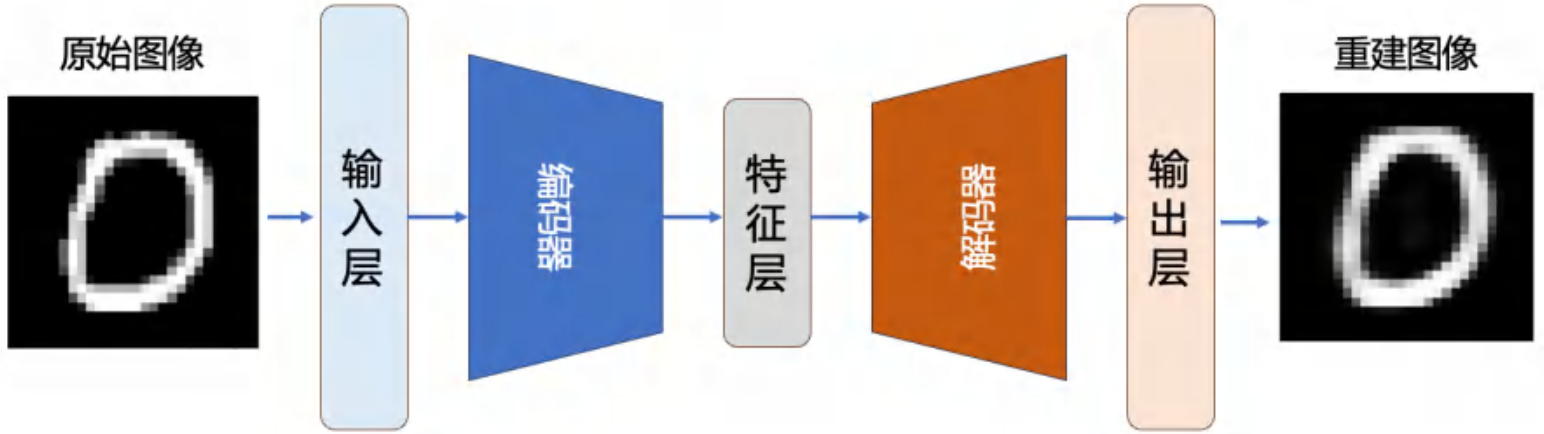
✓ 卷积神经网络

✓ 循环神经网络

✓ …

自编码器网络

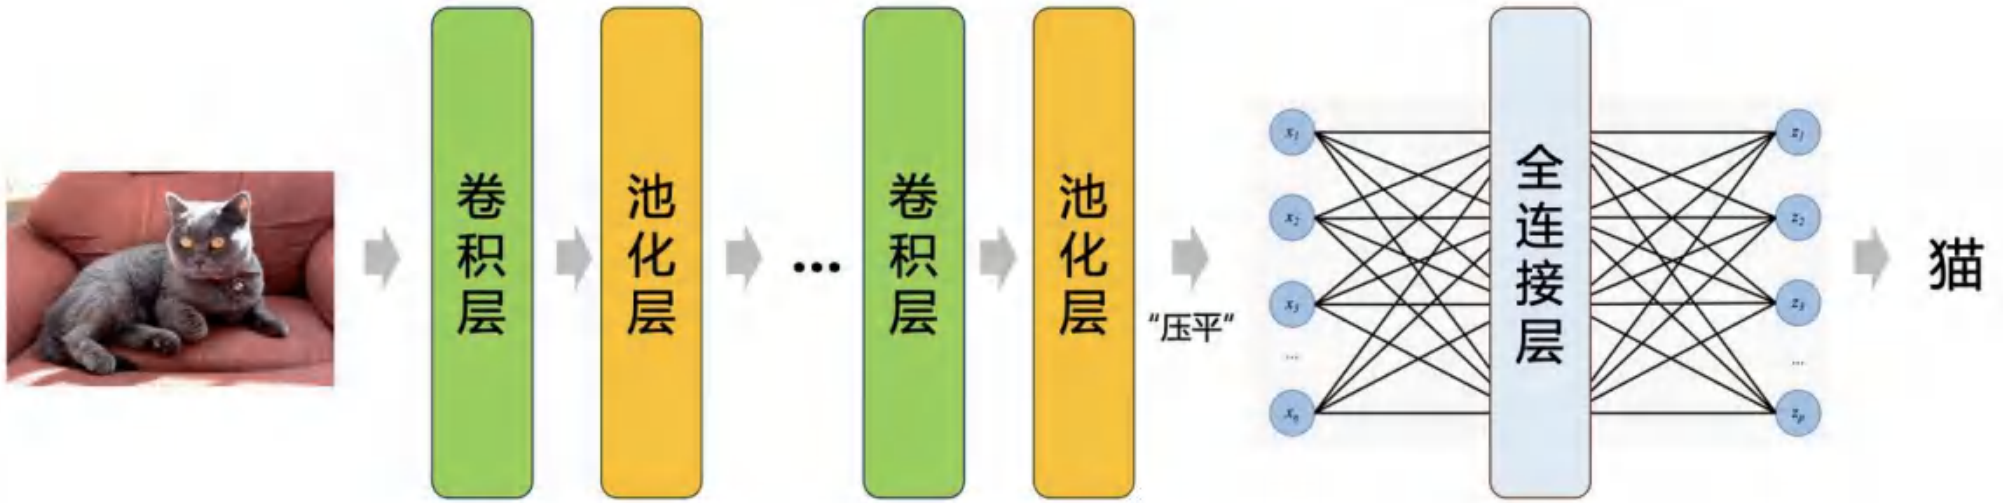
无监督深度学习模型——**自编码器（Autoencoder）**。对一个Autoencoder来说，它的建模目标是 $x = f(x)$，即希望输出与输入一致，当然这个网络是有一定限制的，即如下图所示，网络中间层的宽度是大大小于 x 向量的宽度的，所以如果 x 经过网络中间层的压缩，最终还能还原到 x 本身，那么就说明这个网络**有效地对数据进行了压缩编码**。



$$x = f(x)$$

卷积神经网络

❖ 卷积神经网络(Convolutional Neural Network，CNN)是一种最常用的深度学习网络，它主要用于对空间上有相关性的数据进行建模。



卷积

卷积操作可以认为是一个特征提取的过程，而卷积核就代表了待提取的特征。

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

conv （

1	0	0
0	1	0
0	0	1

1	-1	-1
-1	1	-1
-1	-1	1

）

卷积核 1

= 1*1+0*(-1)+0*(-1)+0*(-1)+1*1+

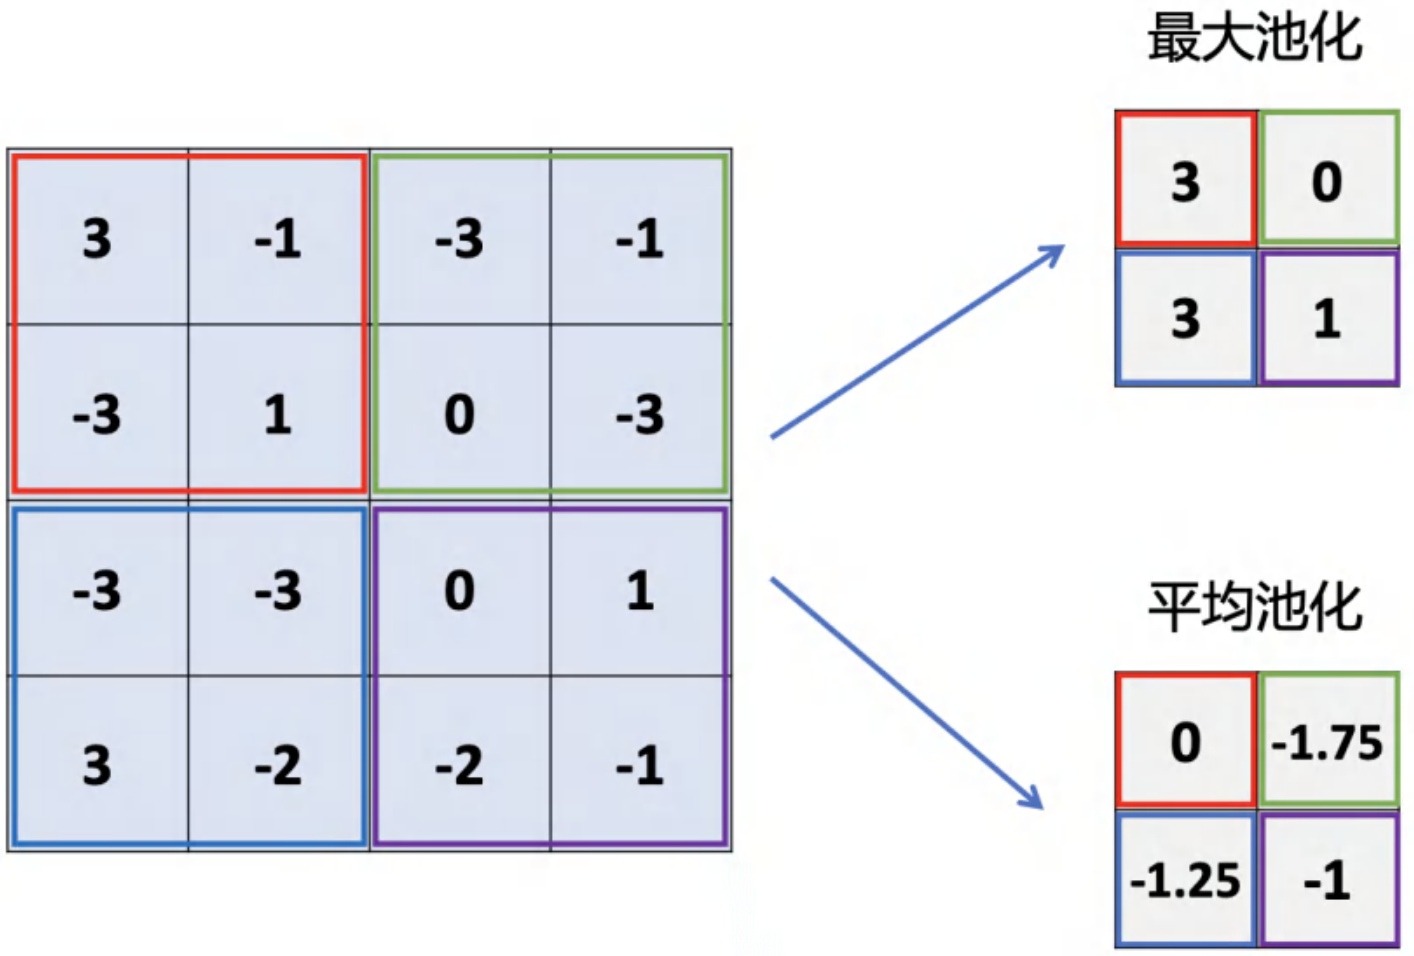
0*(-1)+0*(-1)+0*(-1)+1*1

= 3

3			

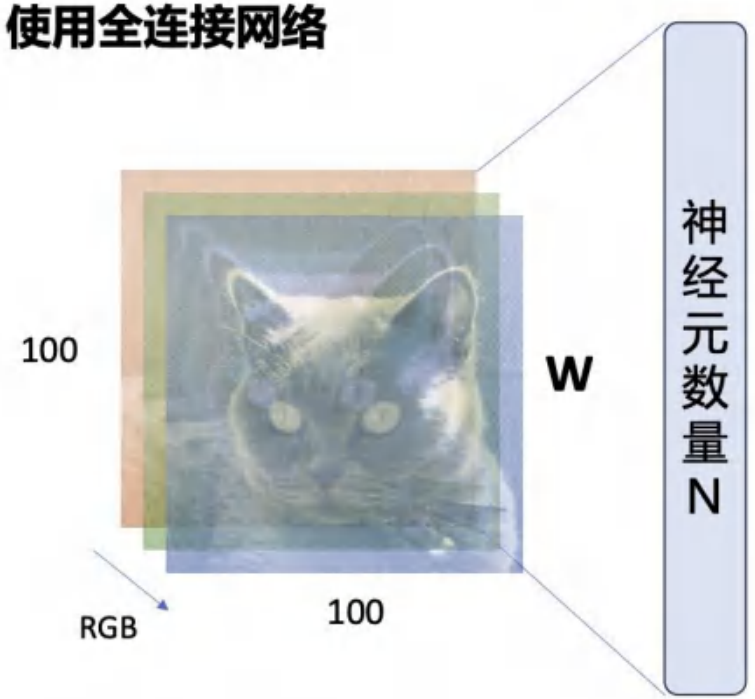
特征图 1

池化



卷积神经网络在图像处理中的优势

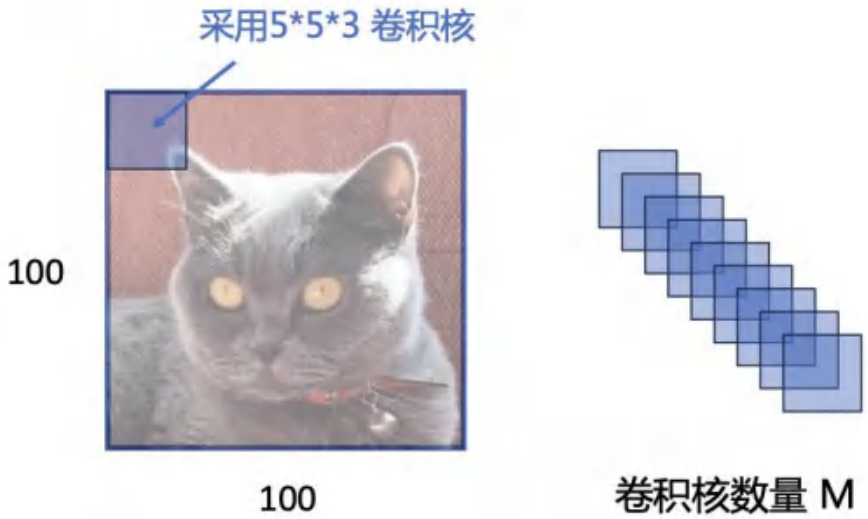
使用全连接网络



若 N = 1000

参数量 ≈ 100 * 100 * 3 * 1000 = $3*10^7$

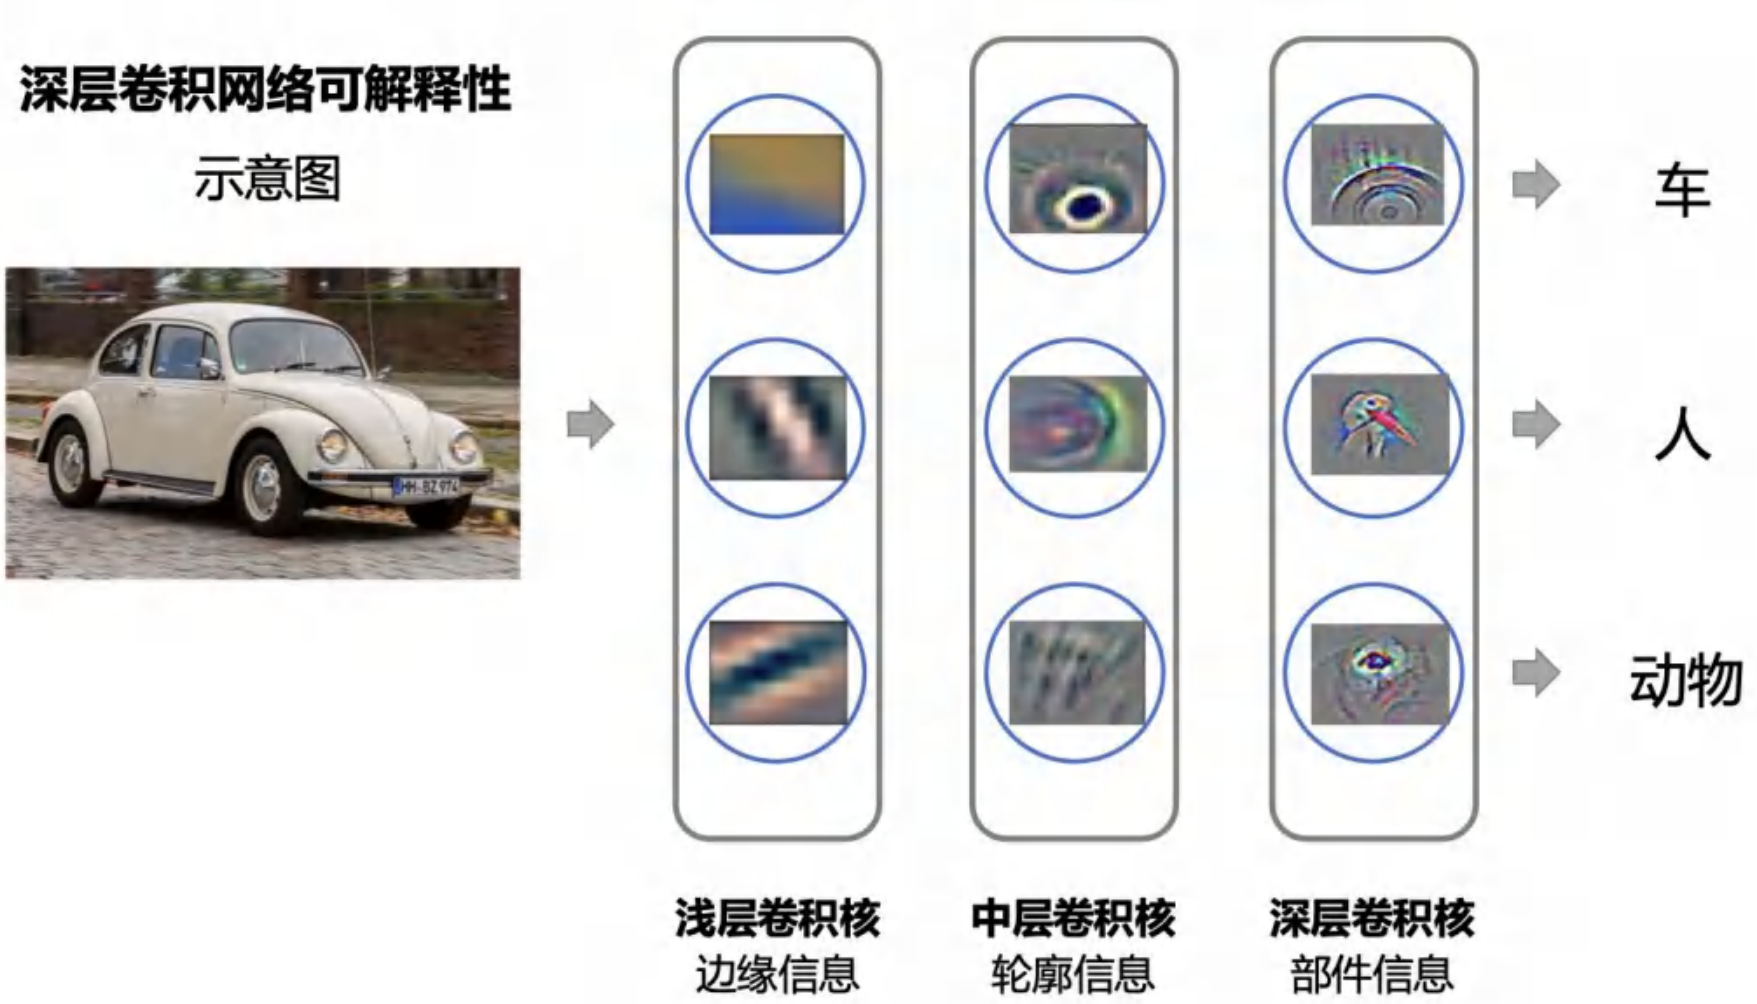
使用卷积网络



若 M = 100

参数量 ≈ 5 * 5 * 3 * 100 ≈ 7500

卷积神经网络的可解释性



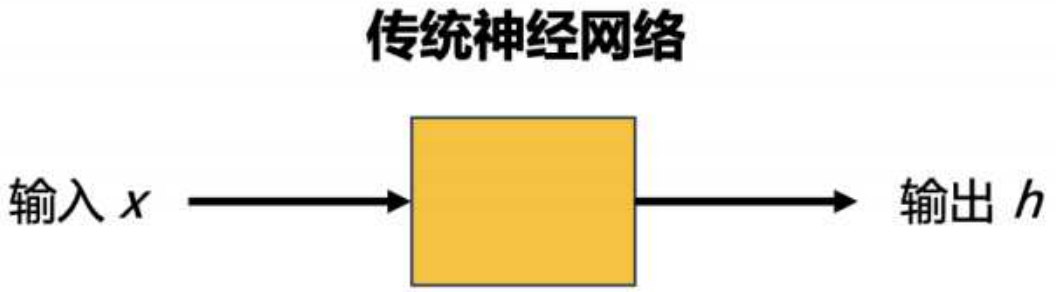
循环神经网络

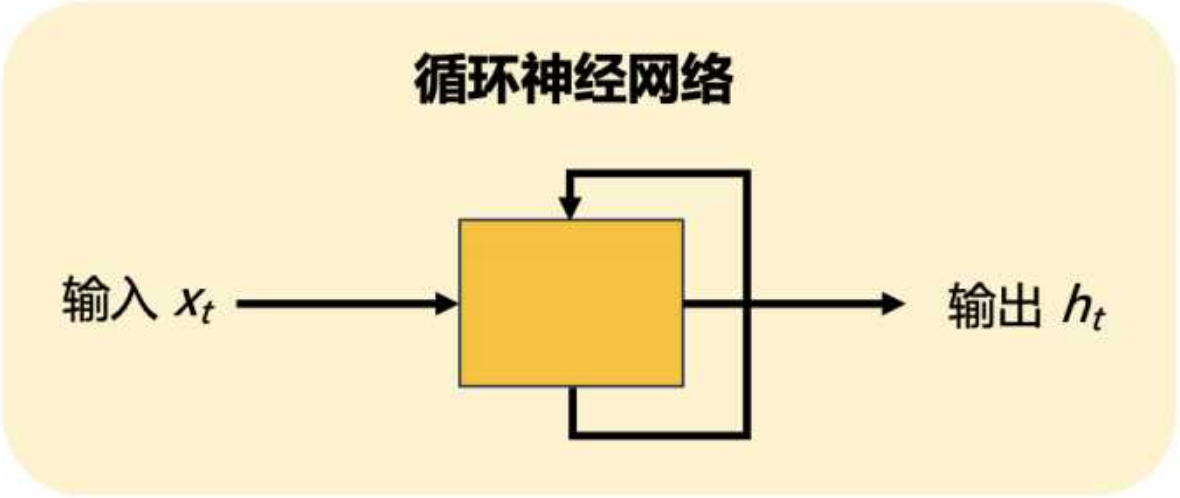
❖循环神经网络（Recurrent Neural Network，RNN）

– **主要用于对时间上有相关性的数据进行建模**

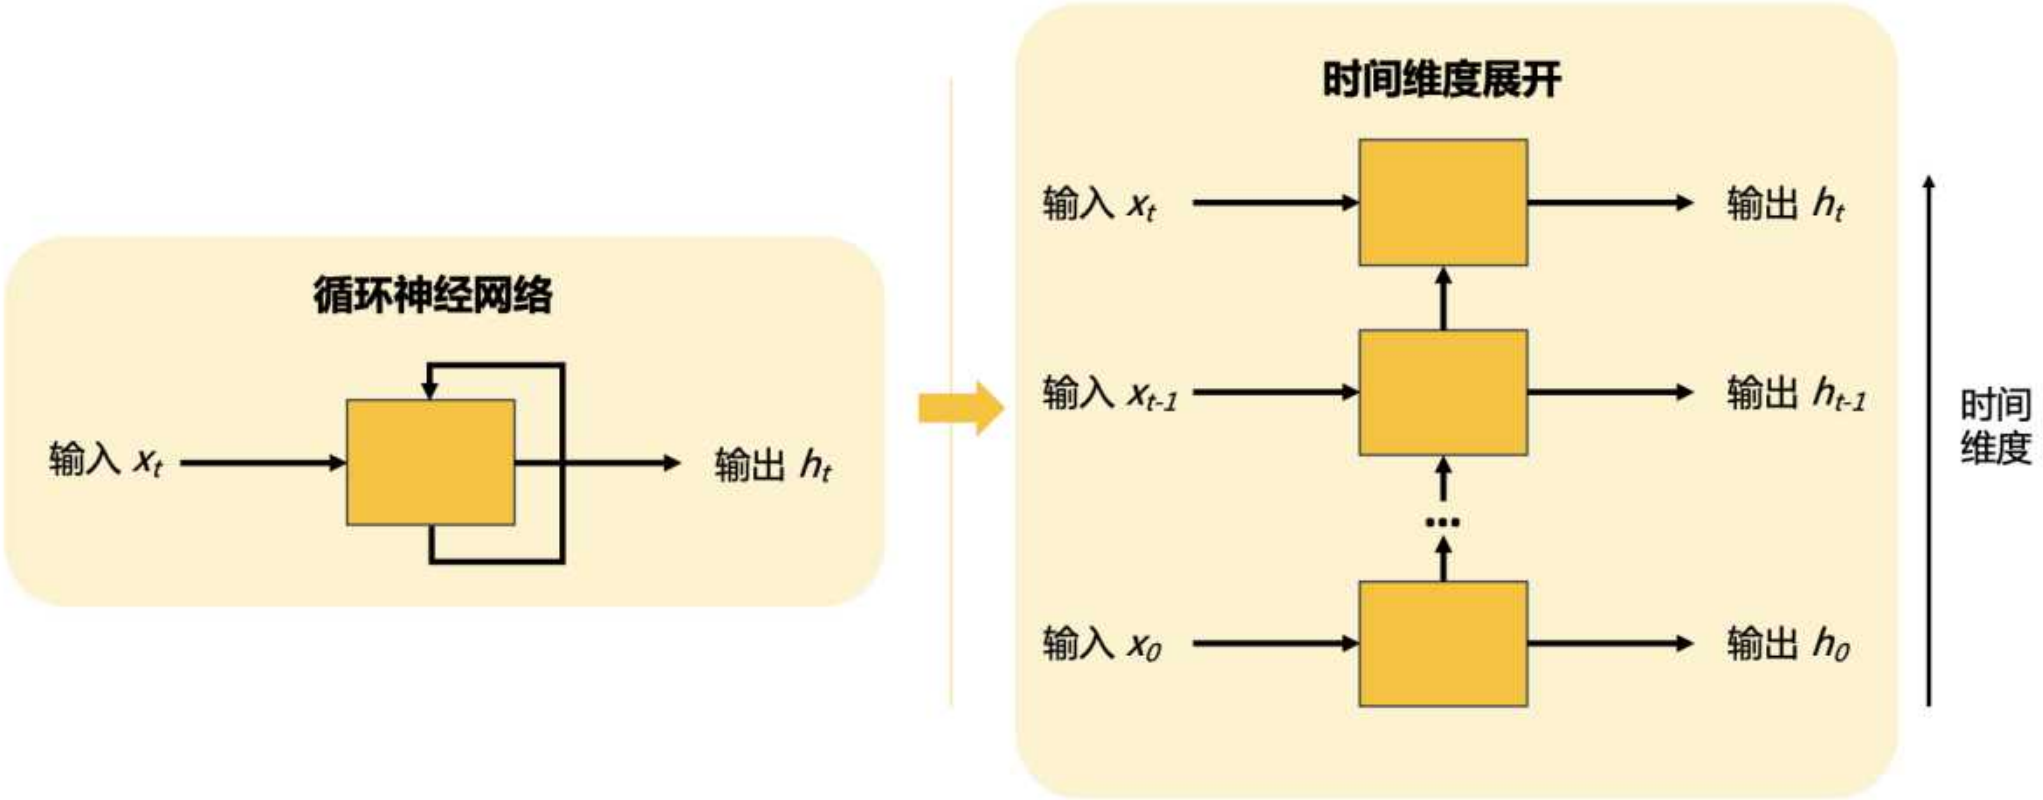
- ✓ 用过去一周的气温，预测明天的气温；
- ✓ 用过去几年的GDP，预测今年的GDP；
- ✓ 语音识别和翻译；
- ✓ 对话和问答系统。

循环神经网络





循环神经网络


循环神经网络
输入 x_t
输出 h_t
时间维度展开
输入 x_t
输出 h_t
输入 x_{t-1}
输出 h_{t-1}
...
输入 x_0
输出 h_0
时间维度

长短记忆网络（Long Short-Term Memory， LSTM）

- **核心思想**

通过一些“门”来决定记忆的长度，即通过“门”的开关决定每一段记忆依赖之前多久的信息。



Jürgen Schmidhuber

LONG SHORT-TERM MEMORY

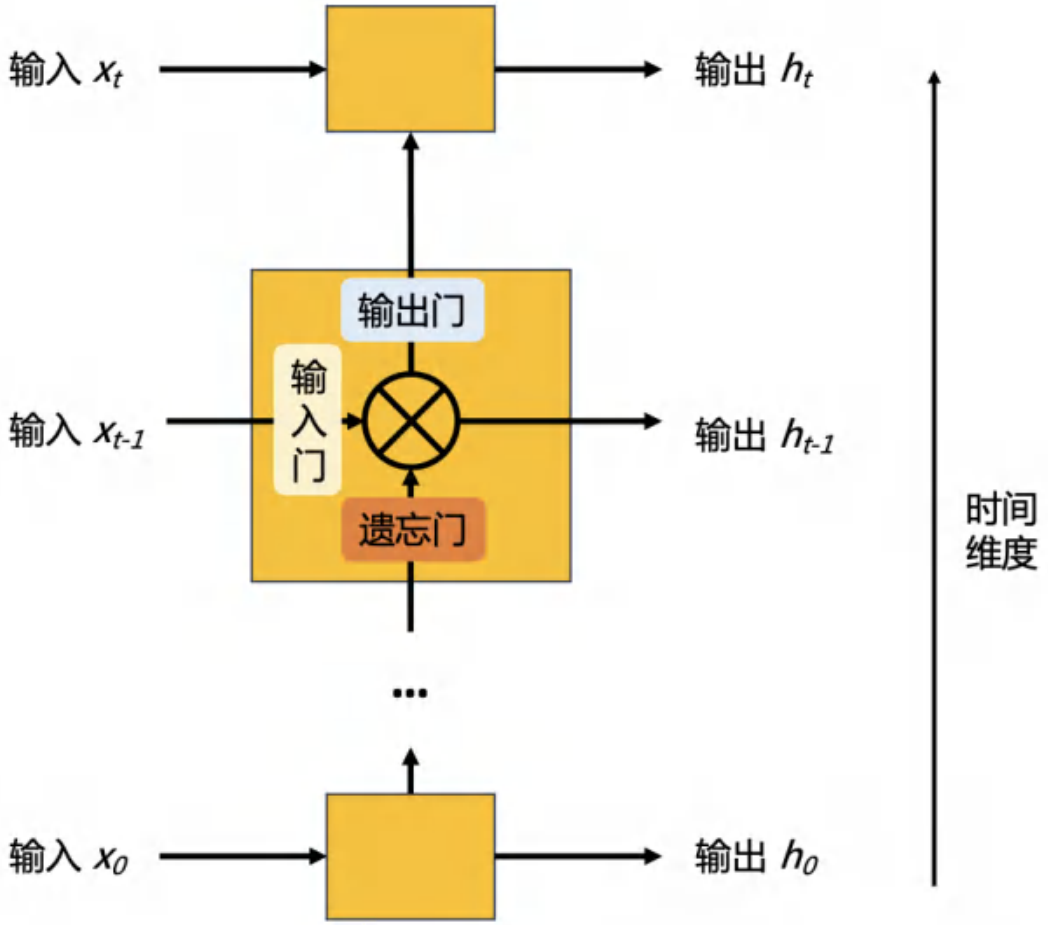
Neural Computation 9(8):1735–1780, 1997

Sepp Hochreiter
Fakultät für Informatik
Technische Universität München
80290 München, Germany
hochreit@informatik.tu-muenchen.de
http://www7.informatik.tu-muenchen.de/~hochreit

Jürgen Schmidhuber
IDSIA
Corso Elvezia 36
6900 Lugano, Switzerland
juergen@idsia.ch
http://www.idsia.ch/~juergen

Long short-term memory
S Hochreiter, J Schmidhuber - Neural computation, 1997 - ieeexplore.ieee.org
… (short-term memory, as opposed to long-term memory … learning what to put in shortterm memory, however, take too … and corresponding teacher signals are long. Although theoretically …
☆ 保存 99 引用 被引用次数：75190 相关文章 所有 49 个版本 »

长短记忆网络（Long Short-Term Memory， LSTM）



输入门（Input Gate）：

决定要获取多少新的长期记忆

遗忘门（Forget Gate）：

决定要遗忘多少之前的长期记忆

输出门（Output Gate）：

决定当前隐藏层的输出值

深度学习中的常用超参数

- **学习率（Learning Rate）**是影响深度学习模型训练速度和收敛稳定性的重要超参数。
- 学习率的值如果设置过大，模型可能在训练过程中不稳定，导致损失函数无法收敛；
- 如果设置过小，训练则可能非常缓慢，甚至陷入局部最优解。
- 一般来说，可以采用学习率衰减（Learning Rate Decay）的方法，从较大的初始学习率逐渐减小，或者使用自适应优化方法（如Adam、RMSprop），使学习率能够动态调整，从而加快收敛速度并提高稳定性。

深度学习中的常用超参数

- **优化器（Optimizer）**：优化器决定了如何更新模型的权重，从而最小化损失函数。
- 常见的优化器包括SGD（随机梯度下降）、Adam、RMSprop等。
- SGD是最基础的优化方法，但在大多数情况下速度较慢且不易收敛。
- Adam结合了动量和自适应学习率调整，适用于大部分深度学习任务，因其收敛速度快且对超参数设置较为不敏感。

深度学习中的常用超参数

- **批次大小（Batch Size）**指的是每次参数更新时使用的训练样本数量。
- 较大的批次大小通常可以加速训练，但也需要更多的显存资源；
- 而较小的批次大小则可能导致训练不稳定。
- 通常的设置方法是从一个合理的初始值开始（例如32或64），然后根据训练资源和效果进行调整。在一些应用中，还可以采用动态批次大小的策略，使模型在训练后期使用更大的批次，从而提高收敛速度。

深度学习中的常用超参数

- **正则化（Regularization）**指训练过程中对参数的特定约束，通常能够有效提升模型的泛化能力。
- 在深度学习中，常用的正则化技术有L1和L2正则化，它们通过在损失函数中增加惩罚项来防止模型过拟合。
- 此外，Dropout是一种非常常用的正则化方法，它通过在训练过程中随机丢弃部分神经元，来减少模型对特定神经元的依赖，从而提升模型的泛化能力。

深度学习中的常用超参数

- **权重初始化（Weight Initialization）**指网络参数初始设置的数值。
- 常用的权重初始化方法有Xavier初始化和He初始化，它们根据网络的激活函数来合理分配初始权重，避免梯度消失或梯度爆炸的问题，从而使模型能够更好地开始训练。

深度学习中的常用超参数

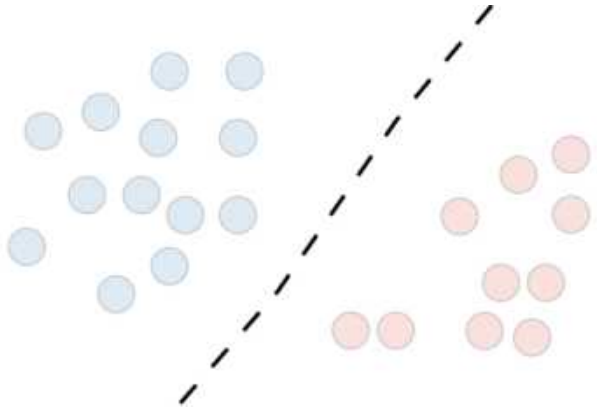
- **训练轮数（epochs）**：一个epoch是指将整个训练数据集完整地通过神经网络一次的过程，也可以理解为模型对所有训练样本学习一次。
- 通常设定的轮数过少会导致模型欠拟合，效果不佳。
- 而过多的轮数会消耗大量时间，还会导致模型过拟合。
- 通常可以通过设置验证集，选择合适的epochs参数，如模型loss不再降低的轮数。

第五章复习要点

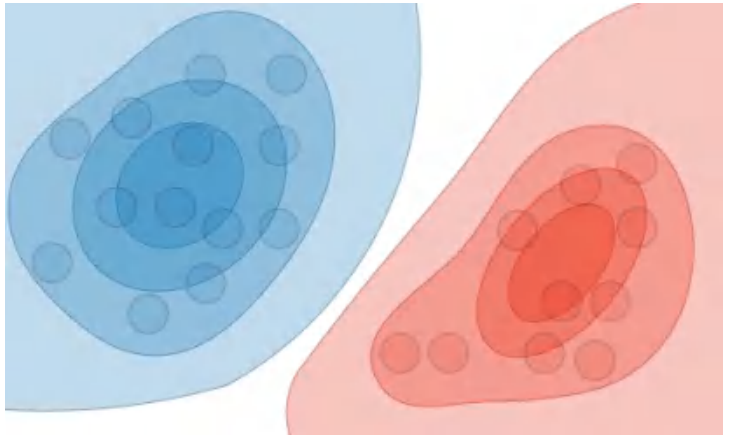
- ❖ 生成式模型与判别式模型
- ❖ GPT大模型的发展
- ❖ 常见的大模型
- ❖ 大模型的训练方式
  - 预训练 + 微调
- ❖ 大模型背后的大支撑
  - 数据、算力、模型

生成式模型与判别式模型

- **判别式模型**是在寻找一个决策边界，通过该边界来将样本划分到对应类别。
- **生成式模型**学习了每个类别的边界，它包含了更多信息，可以用来生成样本。



维度	判别式模型	生成式模型
核心任务	判断数据类别 （是什么）	生成符合规律的新数据 （像什么）
学习重点	捕捉类别差异特征	掌握数据生成规律
应用场景	分类、检测、评分	创作、补全、模拟



大语言模型的发展

❖ GPT（Generative Pre-trained Transformer）系列



技术演进脉络

模型	核心突破	类比解释
GPT-1	预训练范式验证	学会造句的小学生
GPT-2	零样本学习能力显现	不刷题就能考试的天才少年
GPT-3	少样本学习与通用推理	通晓各科的研究员
ChatGPT	安全对话与价值观对齐	懂得沟通技巧的谈判专家
GPT-4	多模态与深度推理	能解奥数题的艺术生

大语言模型的工作原理

❖ 关键思想：预训练+微调



预训练：学习语言



微调：应试

预训练

❖ 在这一初始学习阶段，主要涵盖两项关键任务

- 学习如何有效地处理与理解语言。GPT 架构是包含多层解码器的 Transformer，每层均配备自注意力机制（Self - Attention），该结构擅长在海量信息中迅速定位关键信息，如同人类在阅读文本时能够快速聚焦于重要内容一般。

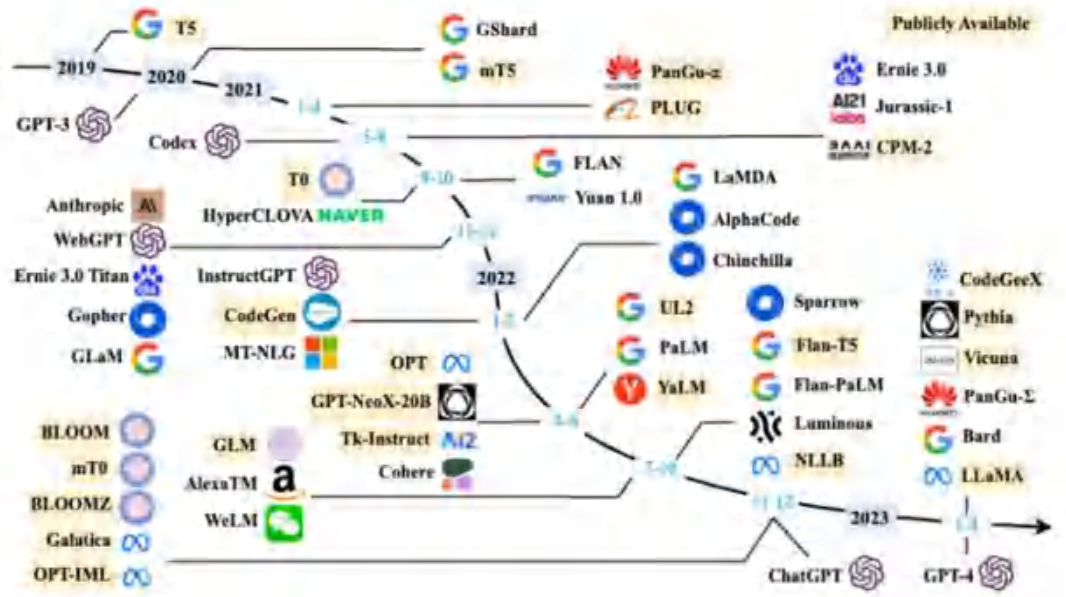
❖ 通过自监督学习方法进行预训练，模型借助掩码语言建模（Masked Language Modeling，MLM）任务预测输入文本中的缺失部分。具体而言，会随机遮蔽部分标记，并要求模型预测被遮蔽的标记。通过此类预测任务，促使模型深入理解上下文语义，习得更全面、深入的语言表示，这类似于人类通过上下文线索理解词语含义的过程。

微调

❖ 完成基础知识学习后，进入针对性训练阶段。例如，若需学习回答问题，便为其提供大量问答示例，使其依据示例调整自身答案，从而更好地适应特定任务需求，就像学生通过大量练习题来提高特定学科的解题能力一样。

大模型背后的“大支撑”

❖ 大模型



	Model	Release	Type	Parameters
1	DeepSeek-R1	2025/1/20	Chat	671B
2	o1-2024-12-17	2024/12/17	Chat	N/A
3	o3-mini-2025-01-31	2025/1/31	Chat	N/A
4	Gemini-2.0-Pro-Exp-02...	2025/2/5	Chat	N/A
5	o1-mini-2024-09-12	2024/9/12	Chat	N/A
6	Gemini-2.0-Flash-001	2025/2/5	Chat	N/A
7	DeepSeek-V3	2024/12/26	Chat	671B
8	Doubao-1.5-pro-32k-25...	2025/1/22	Chat	N/A
9	Qwen2.5-Max	2025/1/28	Chat	N/A

大模型 2022年的GPT-3有1750亿个参数，相当于人脑神经元连接的复杂程度。2025年初的DeepSeek-R1更是有6710亿个参数。这种规模赋予模型强大的模式识别和泛化能力。现在我们一般认为越大的模型，在各种任务上的表现能力也就越好。同时，模型架构也是影响模型性能的关键。

大模型背后的“大支撑”

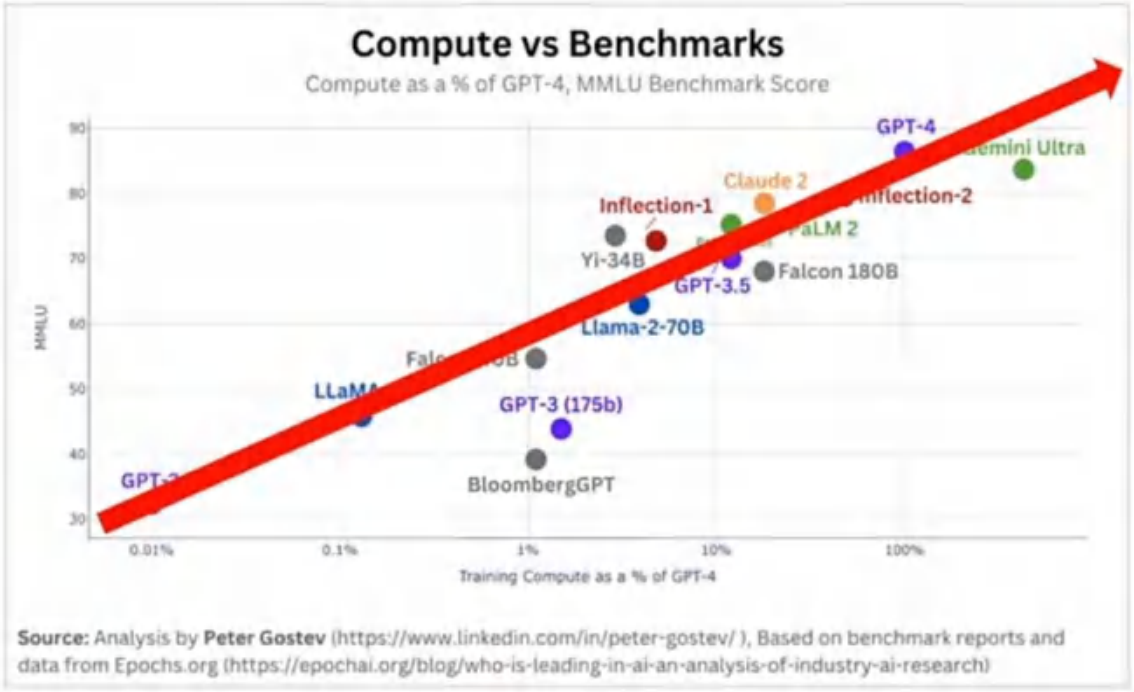
❖ 大数据

大数据 数据是模型的知识来源，模型的训练需要海量各类数据，包括多个语言的图书、文章、对话记录、网站内容。高质量的数据在模型训练中尤为重要，DeepSeek-V3的训练就使用了14.8T的高质量文本。当下训练数据也面临高质量资料枯竭的挑战，合成数据逐渐成为新的数据来源。



大模型背后的“大支撑”

❖大算力



大算力

大模型的训练需要大量算力支撑，DeepSeek-R1的基座模型DeepSeek-V3，其总训练时长约 278.8万GPU小时，预训练阶段：使用了约 266.4万GPU小时，耗时约 55天，上下文扩展阶段：使用了约 11.9万GPU小时。后期训练阶段：使用了约 5000 GPU小时。硬件配置：训练使用了 2048张H800 GPU，集群规模庞大。训练成本：总成本约为 557.6万美元。

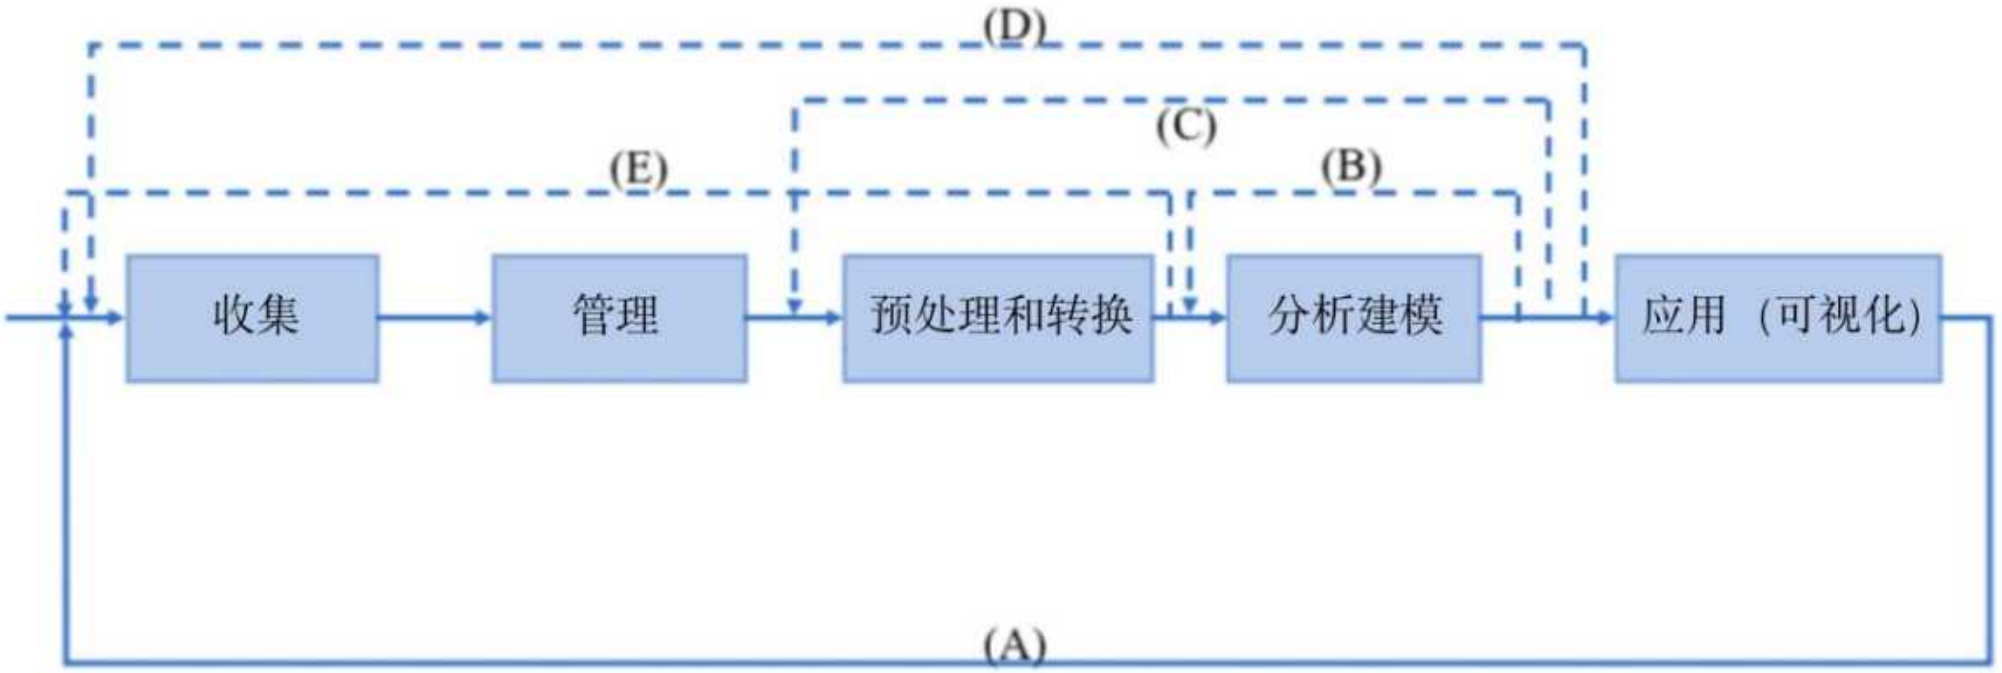
如果用1990年代的电脑训练，需要超过1万年的时间。

第六章复习要点

- 数据链条的概念与意义
- 五个核心步骤：数据收集、数据管理、数据预处理和转换、分析与建模和应用。
- 数据收集的方法
- 数据管理的方法
- 数据预处理方法
- 数据分析方法
  - 单变量、多变量

数据链条：让数据产生价值

- 当数据流经“数据链条”，数据由原始资源转换为最终产品。在此过程中，数据产生了价值，这些价值是原始数据里所不能直接获得的，因此数据链条也是数据挖掘价值的过程。
- 五个核心步骤：数据收集、数据管理、数据预处理和转换、分析与建模和应用。



数据管理

❖ 当数据收集完成之后，接下来要做的就是存储和管理它们，通常我们使用文件（例如Word、Excel等）和数据库（例如SQL、NoSQL等类型的数据库）等形式来存储数据。

- **文件**：文件非常灵活，适合存储多媒体数据（图像，音频，视频等）和非结构化数据（日志，电子邮件等）。
- **数据库**：如果数据是结构化的，则最好使用数据库进行存储，因为将数据存储在数据库中通常比存储在Excel中更灵活，更容易用简单的代码实现查询、添加、删除、统计等操作。

数据预处理和转换

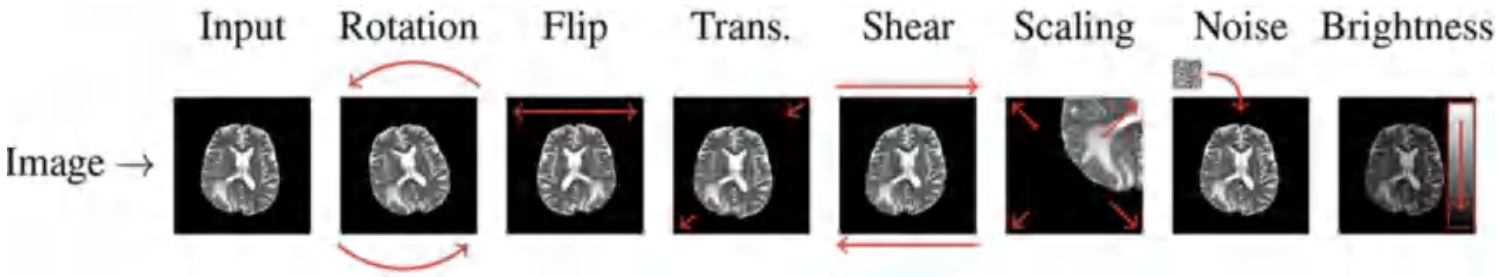
❖ 数据预处理的目的是解决数据中存在的问题，这些问题包括：

- 数据缺失
- 数据噪声
- 数据不一致
- 数据不足

数据预处理和转换

❖ 数据不足

- 原因
  - 构建一个性能良好的机器学习模型需要足够的数据，甚至是大量的数据（对于深度神经网络来说），而实际上可能没有足够的数据
- 方案
  - 增加随机噪声
  - 数据增强



数据分析

- 数据预处理完成后，下一步就是进行数据分析，数据分析是数据链条中重要的一步，其目的是从数据中获取价值。
- 典型的数据分析方法：描述性分析，诊断性分析，预测性分析和规范性分析

	目标	方法
数据分析	从数据中获得有价值结论	统计分析
数据建模	建立数据与其结果之间的函数关系	机器学习

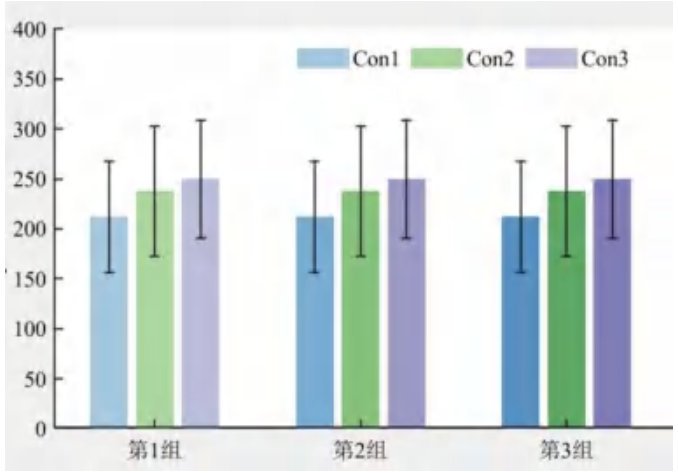
单变量数据分析

❖ 统计归纳

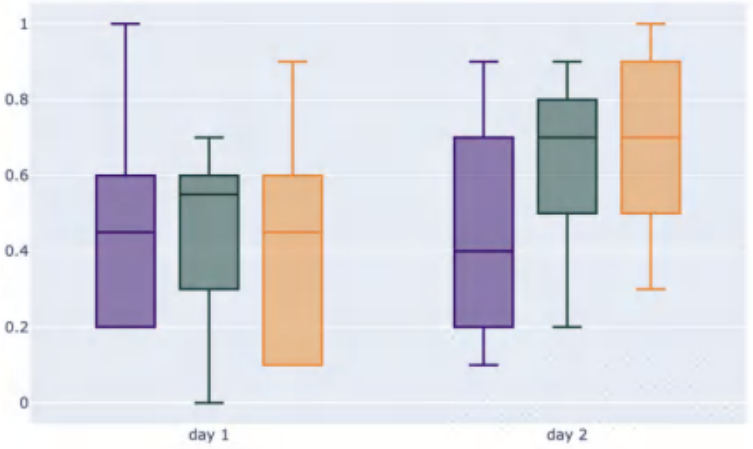
❖ 统计归纳总结了有关数据的信息，常用方法包括：

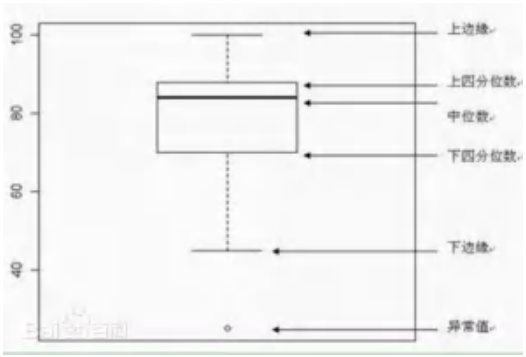
- 数量度量：数据 **X** 的条数 **n** 。
- 中心性度量：包括*算术平均值、几何平均值、修整平均值、中位数和众数。*

❖ 离散性度量：数据离散度是指数据值在其平均值附近的分散程度，常用方法包括方差、标准差。



柱状图

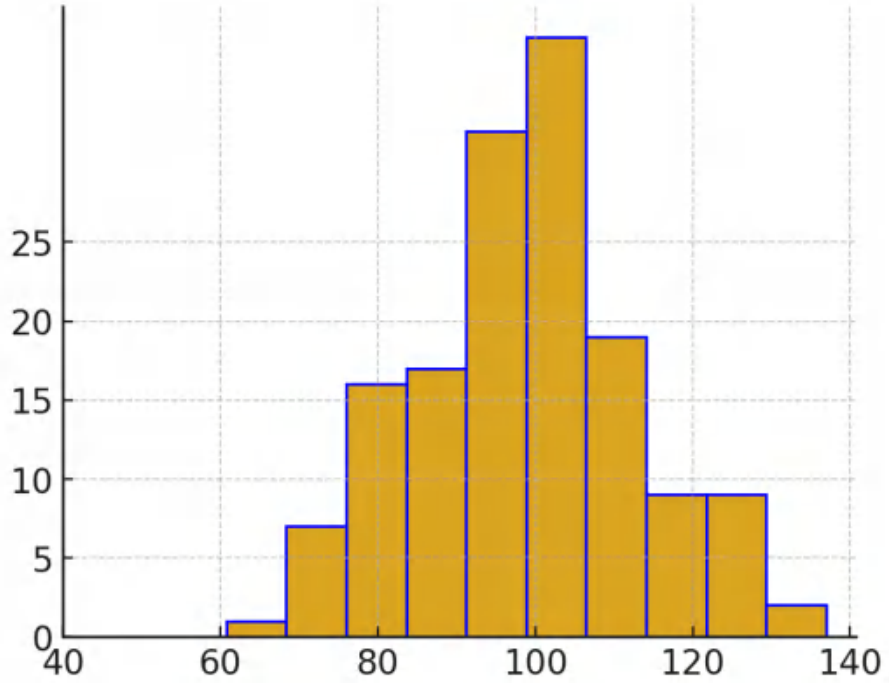




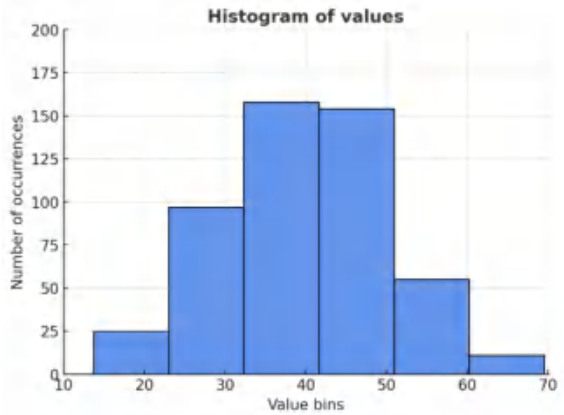
箱型图

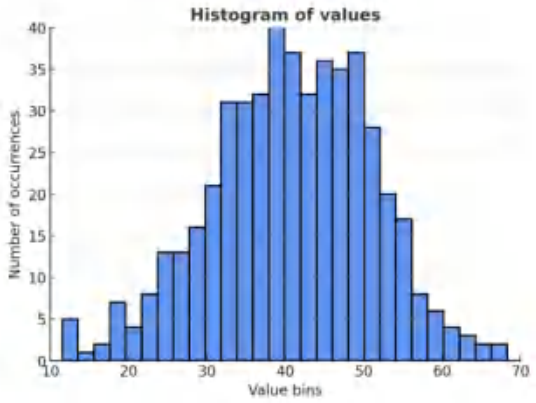
单变量数据分析

❖ **数据分布：**数据分布估计可以用于统计推断，它通过采样数据估计整个群体的属性。



直方图



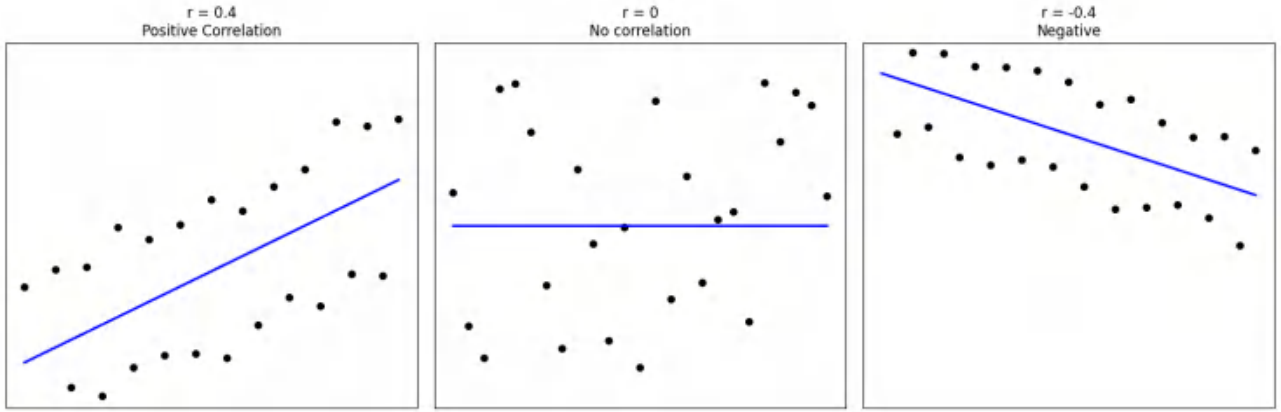


多元统计分析

❖ 相关性分析

- 相关性分析是为了寻找多个变量x之间，以及x和y之间的关系。
- 例如，如果要预测一个城市的GDP，并且有多个与GDP相关的变量时，需要分析哪些变量具有更高的相关性。
- 皮尔森分析：它测量的是两个变量之间的线性相关性。（皮尔森相关性系数ρ）。ρ的值介于 +1 到 −1 之间， +1 代表完全正线性相关，0 代表线性无关，而 −1 代表完全负线性相关。

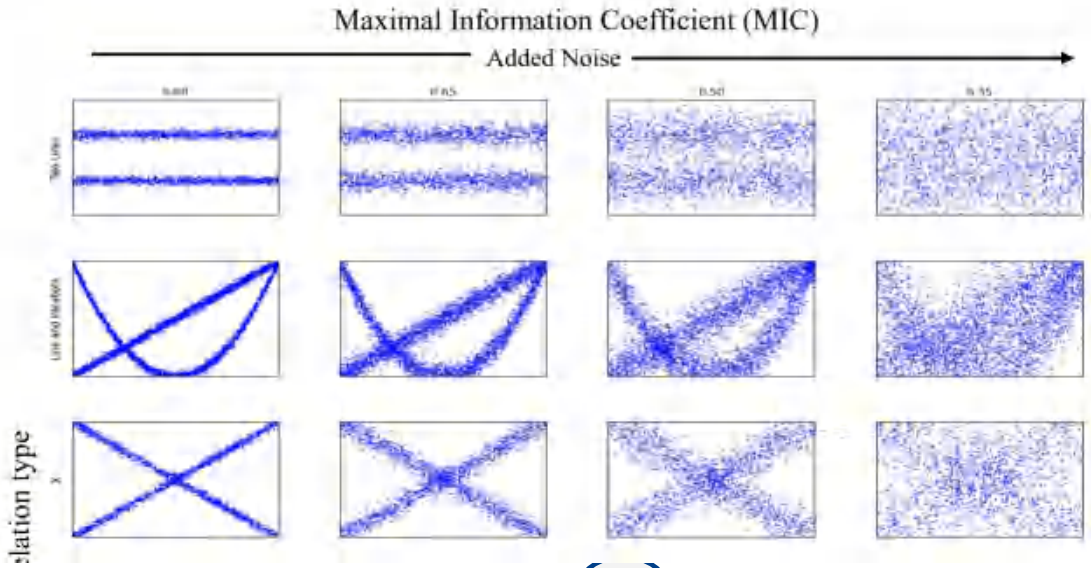
$$\rho = \frac{\mathrm{cov}(X_1, X_2)}{\sigma_{X_1}\sigma_{X_2}}$$



多元统计分析

❖ 相关性分析

- 相关性分析是为了寻找多个变量x之间，以及x和y之间的关系。
- 例如，如果要预测一个城市的GDP，并且有多个与GDP相关的变量时，需要分析哪些变量具有更高的相关性。
- 最大互信息系数（MIC）：MIC 衡量的是两个变量之间的非随机性，其中包括线性相关和非线性相关 。



希望通过这门课程的学习，在同学们心中种下AI的种子，

预祝同学们考试顺利！